



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Análisis radiómico de imágenes de resonancia magnética para la clasificación de la severidad del cáncer de próstata

TRABAJO FIN DE GRADO

Grado en Ciencia de Datos

Autor: Jose Valero Sanchis

Tutor: Elies Fuster i Garcia

Cotutora externa: Mariam de la Iglesia Vayá

Director experimental: Jesús Alzate Grisales

Curso 2024-2025

Resum

????

Paraules clau: ????, ?????????, ????, ?????????????????

Resumen

????

Palabras clave: ?????, ???, ?????????????????

Abstract

????

Key words: ?????, ????? ?????, ?????????????????

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VII

1 Introducción	1
1.1 Motivación	4
1.2 Objetivos	5
1.3 Impacto esperado	5
1.4 Estructura de la memoria	6
2 Marco teórico	7
2.1 Conceptos fundamentales	7
2.2 Estado del arte	7
3 Metodología	9
3.1 Comprensión de los datos	9
3.2 Análisis radiómico	14
3.3 <i>Deep Learning</i>	27
3.4 Comparación del rendimiento	32
3.5 Interpretabilidad de los modelos	33
4 Resultados	37
5 Discusión	39
6 Conclusiones y trabajos futuros	41
6.1 Legado	41
6.2 Relación del trabajo desarrollado con los estudios cursados	41
6.3 Trabajos futuros	41

Apéndices	
A Glosario de acrónimos	49
B Configuraciones experimentales en <i>Deep Learning</i>	51
C Objetivos de Desarrollo Sostenible	55

Índice de figuras

3.1	Resumen del enfoque metodológico propuesto	9
3.2	Distribución del tamaño de imagen por secuencia de resonancia magnética	11
3.3	Distribución del espaciado de imagen por secuencia	12
3.4	Ejemplo de segmentación en imagen T2W	13
3.5	Distribución de casos en función del grado ISUP	13
3.6	Distribución de casos según la presencia o ausencia de csPCa	14
3.7	Resumen del enfoque metodológico propuesto en el análisis radiómico . .	15
3.8	Efecto de la corrección del campo de sesgo en imágenes T2W	16
3.9	Efecto del suavizado por difusión anisotrópica en imágenes DWI	17
3.10	Ejemplo de segmentación en imagen DWI	18
3.11	Ejemplo de aplicación de filtros en una imagen T2W	21
3.12	Resumen del enfoque metodológico propuesto en el análisis con DL . . .	27

Índice de tablas

3.1	Configuración de PyRadiomics por modalidad	20
3.2	Ejemplo de salida del proceso de selección de variables	24
3.3	Espacio de búsqueda de hiperparámetros definido para cada modelo. . . .	26
3.4	Resumen de los modelos utilizados en <i>Deep Learning</i>	31
C.1	Grado de relación del trabajo con los ODS	55

CAPÍTULO 1

Introducción

El cáncer de próstata (PCa, por sus siglas en inglés) es uno de los tumores más prevalentes y representa un desafío significativo para la salud masculina a nivel mundial. Según las estadísticas de Global Cancer Statistics (Bray et al. 2024), en 2022 se diagnosticaron aproximadamente 1.4 millones de nuevos casos en hombres, posicionándolo como el segundo cáncer más frecuente entre esta población. En términos de mortalidad, ocupó el quinto lugar con casi 400 000 muertes, consolidándose como una de las principales causas de fallecimiento relacionadas con el cáncer en hombres.

Estos casos presentan una evolución clínica muy diversa, formando un amplio espectro que abarca desde tumores «clínicamente insignificantes» (o indolentes), de crecimiento lento y una baja probabilidad de progresión o de causar complicaciones graves durante la vida del paciente, hasta los cánceres de próstata «clínicamente significativos» (csPCa, por sus siglas en inglés) con un comportamiento agresivo, capaces de progresar rápidamente, provocar metástasis y con un mayor riesgo de mortalidad (Matoso y Epstein 2019).

Debido a esta variabilidad en las consecuencias clínicas, distinguir entre estos tipos de cáncer de próstata es crucial para guiar las decisiones terapéuticas y evitar intervenciones innecesarias. Tradicionalmente, los métodos de cribado y diagnóstico han incluido el análisis sanguíneo del antígeno prostático específico (PSA, por sus siglas en inglés), el tacto rectal y la biopsia de próstata guiada por ecografía transrectal (TRUS, por sus siglas en inglés) (Lomas y D. J. Ahmed 2020).

El cribado mediante la determinación del PSA se adoptó de forma generalizada en la década de 1990 y se le atribuye un descenso de más del 50 % en la mortalidad por cáncer de próstata (Alpert 2018, Lomas y D. J. Ahmed 2020). Sin embargo, su falta de especificidad frecuentemente conduce a falsos positivos y a la detección de tumores indolentes que nunca habrían causado daños (Merriel et al. 2022). Este sobrediagnóstico conlleva frecuentemente el sobretratamiento, es decir, intervenciones médicas innecesarias como cirugía o radioterapia, que pueden producir efectos adversos significativos, tales como incontinencia urinaria o disfunción eréctil (Matoso y Epstein 2019). Frente a tumores indolentes, estos tratamientos podrían evitarse en favor de métodos menos invasivos como la vigilancia activa, que implica un seguimiento clínico regular mediante análisis del PSA, exámenes clínicos periódicos y repetición selectiva de biopsias, con el objetivo de detectar tempranamente signos de progresión sin exponer al paciente a los efectos adversos asociados a tratamientos más agresivos (Dall'Era et al. 2012).

Más allá del PSA, otros procedimientos convencionales como el tacto rectal presentan también importantes limitaciones. Aunque se realiza de manera rutinaria, el tacto rectal tiene una sensibilidad (51 %) y especificidad (59 %) limitadas, lo que implica que muchos tumores no sean detectados y que frecuentemente se sospechen tumores en pacientes que

realmente no los tienen (Naji et al. 2018). Cuando existe sospecha de cáncer, el método estándar para confirmarlo es la biopsia de próstata guiada por ecografía transrectal (TRUS), que obtiene muestras del tejido prostático. Aunque son esenciales, las biopsias de próstata presentan limitaciones significativas. Un estudio indicó que la biopsia tuvo una alta sensibilidad (98 %) y una baja especificidad (49 %) para tumores indolentes, mientras que presentó una baja sensibilidad (26 %) y una alta especificidad (99 %) para tumores clínicamente significativos (Nieto-Morales et al. 2014). Esto implica que las biopsias pueden no detectar algunos tumores agresivos y, al mismo tiempo, identificar como cánceres casos que podrían no requerir tratamiento inmediato. Además, las biopsias son procedimientos invasivos que conllevan riesgos como hemorragias, dolor e infecciones, incluida la sepsis (H. U. Ahmed et al. 2017).

Estos desafíos —la limitada especificidad del análisis del PSA, la sensibilidad y especificidad insuficientes del tacto rectal y las biopsias, junto con su naturaleza invasiva y riesgo de efectos adversos— han impulsado la búsqueda de herramientas diagnósticas más fiables y menos invasivas, entre las que destaca la resonancia magnética multiparamétrica (RMmp). En la última década, la RMmp ha revolucionado el diagnóstico del cáncer de próstata al combinar imágenes anatómicas ponderadas en T2 (T2W) con secuencias funcionales como la imagen ponderada por difusión (DWI), que mide la restricción en el movimiento del agua, y la imagen dinámica con contraste intravenoso (DCE), que evalúa la perfusión, estructura vascular y permeabilidad, generando así información precisa sobre la anatomía y las características biológicas del tejido prostático (Demirel y Davis 2018).

Diversos estudios, como los realizados por H. U. Ahmed et al. (2017) y Boesen (2017), han demostrado que la RMmp mejora notablemente la detección del cáncer de próstata clínicamente significativo en comparación con la biopsia sistemática a ciegas, técnica en la que se obtienen múltiples muestras prostáticas de forma aleatoria, sin la guía específica proporcionada por imágenes diagnósticas. Por ejemplo, el ensayo PROMIS —un estudio prospectivo de validación de cohortes emparejadas realizado por H. U. Ahmed et al. (2017), que cumple los criterios del nivel 1 de evidencia en la evaluación de pruebas diagnósticas— informó que el uso de la RMmp como prueba de cribado antes de la biopsia incrementó la sensibilidad para detectar cáncer significativo al 93 % (en comparación con el 48 % de la biopsia mediante TRUS). Como resultado, el uso de la RMmp como prueba de cribado inicial podría permitir que aproximadamente el 27 % de los pacientes evite una primera biopsia y que se diagnosticaran un 5 % menos de cánceres clínicamente insignificantes. Además, si las biopsias mediante TRUS posteriores se dirigiesen según los hallazgos de la RMmp, podrían detectarse hasta un 18 % más de casos de cáncer clínicamente significativo en comparación con la estrategia convencional de biopsia sistemática mediante TRUS para todos los pacientes. Por tanto, las estrategias basadas en RMmp antes de la primera biopsia prostática reducirían en aproximadamente una cuarta parte las biopsias innecesarias, mitigando así el sobrediagnóstico de cánceres clínicamente insignificantes y mejorando simultáneamente la detección de tumores agresivos.

Sin embargo, la RMmp no está exenta de limitaciones. Entre ellas destacan las barreras económicas y logísticas que dificultan el acceso generalizado a equipos de RMmp de alta calidad, limitando así su adopción en la práctica clínica (Schoots 2018). Además, la interpretación de los resultados de la RMmp es compleja y requiere una gran experiencia por parte de los radiólogos para evaluar correctamente las imágenes, determinar con precisión la agresividad tumoral y seleccionar las estrategias terapéuticas más apropiadas. Esta tarea puede complicarse aún más debido a factores humanos como la fatiga o la sobrecarga cognitiva, que reducen la precisión diagnóstica y aumentan la probabilidad de falsos positivos o negativos (Stec et al. 2018). Estos errores pueden provocar tratamientos

innecesarios o retrasar intervenciones oportunas, afectando negativamente los resultados clínicos del paciente.

Para hacer frente a estas limitaciones y complementar la interpretación clínica tradicional, han surgido técnicas computacionales avanzadas basadas en Inteligencia Artificial (IA), que incluyen, por un lado, la combinación de radiómica y *Machine Learning* (ML), y por otro, el *Deep Learning* (DL). Ambas estrategias permiten potenciar el diagnóstico del cáncer de próstata mediante la extracción y el análisis de la abundante información contenida en las imágenes de RMmp.

La radiómica consiste en la extracción automatizada de características cuantitativas —denominadas características radiómicas— a partir de imágenes médicas, convirtiendo estas imágenes en datos medibles. En lugar de depender únicamente de la evaluación subjetiva del radiólogo, el análisis radiómico calcula cientos o incluso miles de descriptores que caracterizan la forma, la intensidad y la textura de las lesiones (Mayerhoefer et al. 2020). En una etapa posterior, se emplean algoritmos de *Machine Learning* para identificar patrones en estas características radiómicas. Por su parte, el *Deep Learning* emplea redes neuronales con múltiples capas para extraer automáticamente información relevante a partir de las imágenes y generar predicciones clínicas basadas en ella. En imagen médica, las Redes Neuronales Convolucionales (CNN, por sus siglas en inglés) son la arquitectura más común, capaces de generar un diagnóstico directamente desde los píxeles de la imagen (Li et al. 2014). A diferencia de la radiómica, que se basa en características obtenidas «manualmente», las CNN aprenden automáticamente sus propias representaciones abstractas, optimizadas en este caso para predecir el grado de agresividad tumoral.

En la última década, numerosos estudios han demostrado la eficacia de la radiómica y del DL para mejorar la detección del cáncer de próstata en imágenes de RMmp. Los modelos basados en características radiómicas han mostrado un rendimiento notable a la hora de distinguir cánceres agresivos. Por ejemplo, en un estudio realizado por Woźnicki et al. (2020) se utilizó un conjunto de características cuantitativas obtenidas a partir de imágenes de RMmp, combinado con datos clínicos como la densidad del PSA, para clasificar las lesiones prostáticas. Este modelo logró un área bajo la curva ROC (AUC, por sus siglas en inglés) de 0.889 para la detección de cáncer de próstata y de 0.844 para la distinción entre cáncer clínicamente significativo y clínicamente insignificante. En comparación, la evaluación visual basada en criterios convencionales obtuvo un AUC de 0.779 para la detección de cáncer y de 0.688 para la clasificación de csPCa.

A su vez, los enfoques basados en *Deep Learning* también han demostrado resultados prometedores. Las CNN, entrenadas con imágenes de RMmp, han alcanzado un rendimiento comparable al de radiólogos en la detección de tumores. Por ejemplo, en un estudio reciente realizado por Cai et al. (2024), un modelo de DL mostró un rendimiento comparable al de radiólogos expertos en la detección de cáncer de próstata clínicamente significativo mediante RMmp. En el conjunto de prueba interno —compuesto por exploraciones del mismo centro utilizado para entrenar el modelo—, ambos alcanzaron un AUC de 0.89, mientras que en el conjunto de prueba externo —procedente de un centro distinto— el modelo obtuvo un AUC de 0.86 frente a 0.84 de los radiólogos, sin diferencias estadísticamente significativas.

Pese a estos prometedores resultados, la adopción de modelos de *Machine Learning* o *Deep Learning* en diagnóstico médico requiere más que simple precisión. La interpretabilidad se ha convertido en un requisito fundamental, especialmente en aplicaciones clínicas donde comprender el razonamiento detrás de cada predicción es tan crucial como la precisión misma (Holzinger et al. 2017). Los modelos predictivos deben ser capaces no solo de ofrecer resultados precisos, sino de explicar de manera transparente cómo se

ha llegado a una conclusión diagnóstica, permitiendo a los profesionales médicos validar, confiar y, si es necesario, cuestionar la decisión propuesta.

Precisamente por esta necesidad de transparencia, es importante señalar que estas herramientas no pretenden reemplazar a los radiólogos, sino actuar como dispositivos de asistencia para apoyar la toma de decisiones clínicas. En un futuro, un sistema de IA podría desempeñar el papel de un «segundo lector», proporcionando una segunda opinión inmediata sobre las exploraciones por RMmp (Alqahtani 2024). Esto podría ayudar a detectar cánceres que podrían pasar desapercibidos para el ojo humano —reduciendo así los errores diagnósticos—. Al automatizar aspectos rutinarios del análisis de imágenes, la IA puede reducir la carga de trabajo del radiólogo, permitiéndole centrarse en los casos más complejos.

En última instancia, la integración de la radiómica y el *Deep Learning* en el diagnóstico del cáncer de próstata persigue mejorar los resultados clínicos: detectar antes los tumores clínicamente significativos, diferenciar con mayor precisión entre enfermedad agresiva e indolente, y evitar procedimientos innecesarios a los pacientes. Con una validación y perfeccionamiento continuos —especialmente en el desarrollo de modelos más transparentes y explicables—, la IA tiene el potencial de transformar el diagnóstico del cáncer de próstata, haciéndolo más preciso, consistente y personalizado. Esto no solo reforzará la confianza del radiólogo en su interpretación, sino que también se traducirá en decisiones terapéuticas mejor adaptadas a cada paciente y en una mejora de la supervivencia y la calidad de vida a largo plazo.

Para facilitar la comprensión del contenido, los acrónimos empleados a lo largo del documento —como csPCa o RMmp—, junto con otros términos técnicos y médicos, se recogen y definen en el glosario de acrónimos (Apéndice A).

1.1 Motivación

La motivación de este trabajo responde a la necesidad de desarrollar herramientas más precisas y explicables que puedan asistir en la identificación del cáncer de próstata mediante técnicas avanzadas de Inteligencia Artificial. En concreto, este proyecto busca desarrollar y comparar sistemas de apoyo al diagnóstico basados en radiómica y en técnicas de *Deep Learning*, evaluando no solo su capacidad para diferenciar entre tumores clínicamente significativos y tumores indolentes, sino también el grado en que los resultados pueden ser interpretados por los radiólogos. Al analizar y comparar distintos métodos diagnósticos se espera que esta investigación permita identificar fortalezas y limitaciones de cada enfoque en relación con su capacidad diagnóstica e interpretabilidad clínica.

Desde una perspectiva puramente personal, este Trabajo de Fin de Grado representa una oportunidad para contribuir a la mejora de la calidad de vida de las personas mediante la aplicación de la ciencia de datos y la IA en medicina, un área que siempre me ha resultado especialmente atractiva. Fue precisamente esta motivación la que hizo que me matriculara en la asignatura *Biomedical Data Science*. Aunque antes de cursarla ya tenía claro que quería orientar mi Trabajo de Fin de Grado hacia este campo, esta asignatura no hizo más que reforzar mi convicción, ya que me permitió comprender con mayor profundidad el potencial de las técnicas de Inteligencia Artificial aplicadas a la salud para mejorar el diagnóstico y tratamiento de enfermedades. Además, considero que este TFG constituye un primer paso fundamental hacia una futura carrera profesional en Inteligencia Artificial aplicada a la salud, permitiéndome adquirir experiencia práctica y profundizar en un ámbito científico con gran potencial para generar beneficios importantes para pacientes y profesionales sanitarios.

1.2 Objetivos

El objetivo principal de este trabajo es comparar el análisis radiómico con técnicas de *Deep Learning* en la clasificación de la severidad del cáncer de próstata a partir de imágenes de resonancia magnética multiparamétrica (RMmp), evaluando su rendimiento y explicabilidad.

Para alcanzar este objetivo, se proponen los siguientes objetivos específicos, que detallan las acciones necesarias para su desarrollo:

- Extraer características radiómicas de las imágenes de RMmp.
- Entrenar modelos de *Machine Learning* utilizando las características radiómicas extraídas.
- Entrenar modelos de *Deep Learning* directamente a partir de las imágenes originales de RMmp.
- Comparar el rendimiento de los modelos de análisis radiómico y DL en la detección de cáncer de próstata clínicamente significativo.
- Evaluar la interpretabilidad de los modelos empleados mediante técnicas de *Explainable Artificial Intelligence* (XAI).

1.3 Impacto esperado

Los resultados de este trabajo podrían tener un impacto relevante en distintos perfiles de usuarios, tanto en el ámbito clínico como en el investigador.

Para los profesionales sanitarios, especialmente los radiólogos, se espera que estas herramientas actúen como sistemas de apoyo al diagnóstico, proporcionando una segunda opinión que complemente la interpretación visual de las imágenes. Esto podría facilitar la detección de tumores clínicamente significativos que podrían pasar desapercibidos en la lectura convencional, al tiempo que reduciría la carga de trabajo derivada del análisis manual. La incorporación de técnicas de XAI permitiría, además, generar explicaciones comprensibles de las predicciones realizadas por los modelos, lo que contribuiría a aumentar la confianza en su uso y facilitar su integración progresiva en la práctica clínica.

Desde la perspectiva del paciente, una mejora en la precisión del diagnóstico puede tener implicaciones relevantes para su salud y calidad de vida. Una mejor diferenciación entre tumores agresivos e indolentes permitiría evitar tanto el sobreatamiento innecesario —con sus efectos adversos asociados— como el infradiagnóstico de lesiones que requieren intervención. De este modo, se favorecería una atención médica más personalizada, basada en el riesgo real, con decisiones terapéuticas más ajustadas a las características individuales de cada caso.

Por último, en el ámbito científico, este trabajo puede aportar valor al comparar enfoques basados en radiómica y en *Deep Learning*, permitiendo identificar fortalezas y limitaciones de cada estrategia en términos de rendimiento y explicabilidad. Además, la identificación de las características radiómicas más relevantes para la clasificación de la severidad tumoral puede aportar evidencia sobre posibles marcadores de agresividad, lo que podría servir de base para mejorar los enfoques actuales en diagnóstico por imagen y orientar futuras investigaciones centradas en la caracterización del cáncer de próstata.

1.4 Estructura de la memoria

Esta memoria se estructura en varios capítulos. A continuación, se presenta un resumen de su contenido (IR REVISANDO):

- **Capítulo 1: Introducción.** Se expone el contexto y la motivación del trabajo, justificando la importancia de aplicar técnicas de Inteligencia Artificial, en particular el análisis radiómico y el *Deep Learning*, en la clasificación del cáncer de próstata. Se presentan los objetivos principales y específicos, así como el impacto esperado del estudio.
- **Capítulo 2: Marco teórico.**
- **Capítulo 3: Metodología.** Se presenta el enfoque metodológico seguido, comenzando por la descripción y análisis del conjunto de datos. A continuación, se desarrollan los dos enfoques considerados: análisis radiómico y *Deep Learning*. Finalmente, se expone la estrategia de comparación entre modelos y las técnicas de interpretabilidad aplicadas.

Además, la memoria incluye los siguientes anexos:

- **Apéndice A. Glosario.**
- **Apéndice C. Objetivos de Desarrollo Sostenible (ODS).**

CAPÍTULO 2

Marco teórico

2.1 Conceptos fundamentales

2.1.1. Cáncer de próstata

2.1.2. Fundamentos de resonancia magnética

2.1.3. Radiómica

2.1.4. Inteligencia Artificial: ML, DL y XAI

2.2 Estado del arte

Realizar investigación de la utilización de la radiómica para ..., centrarse si existe literatura suficiente en cáncer de próstata.

Estructurar en: DL para detección de cáncer de próstata, radiómica para la detección de cáncer de próstata, comparación entre enfoques para la detección del cáncer de próstata en un mismo corpus

COSAS QUE SE HAN HECHO EN CANCER DE PROSTATA

- **Machine learning-based analysis of MR radiomics can help to improve the diagnostic performance of PI-RADS v2 in clinically relevant prostate cancer.** El objetivo del artículo es comparar el desempeño diagnóstico de PI-RADS v2, radiomics y su combinación mediante aprendizaje automático, para mejorar la detección y evaluación del cáncer de próstata clínicamente relevante.
- **Classification of Clinically Significant Prostate Cancer on Multi-Parametric MRI: A Validation Study Comparing Deep Learning and Radiomics.** El objetivo del artículo es comparar el rendimiento de modelos de aprendizaje profundo y radiomics en la clasificación del cáncer de próstata clínicamente significativo ($ISUP \geq 2$) utilizando imágenes multiparamétricas de resonancia magnética (mpMRI) y evaluar su capacidad de generalización en (varios, aquí es donde introducen la novedad) conjuntos de datos externos heterogéneos.

Conclusión: La comparación muestra que mientras que el rendimiento del modelo de aprendizaje profundo fue superior en la cohorte de entrenamiento, el modelo radiómico superó al modelo de aprendizaje profundo en todas las cohortes de prueba, lo que lo convierte en un modelo más herramienta más precisa para detectar el cáncer de próstata clínicamente significativo.

- **A hybrid classification model with radiomics and CNN for high and low grading of prostate cancer Gleason score on mp-MRI.** Este artículo desarrolla un modelo híbrido que combine radiómica y redes neuronales convolucionales (CNN) para clasificar de forma precisa el cáncer de próstata según la puntuación de Gleason en imágenes de resonancia magnética multiparamétrica (mp-MRI), diferenciando entre riesgo bajo ($GS \leq 3+4$) y alto ($GS \geq 4+3$) → clasificación binaria.

2.2.1. Crítica al estado del arte

Identificar cualquier fallo, ineficacia, laguna, aspecto no abordado en la literatura que justifique el desarrollo del TFG.

A FALTA DE INVESTIGAR MÁS: existe una falta de pruebas científicas que comparen, sobre un mismo corpus, técnicas de DL (CNN, transformers...) con técnicas basadas en radiómica para predecir la severidad del cáncer de próstata. Además, son incluso menos los que incluyan conceptos de interpretabilidad.

Castillo T. et al. clasifican simplemente si el cancer es CS o no, no los niveles de severidad: "PCa with an ISUP grade ≥ 2 (Gleason Score (GS) 3 + 4 and higher) was classified as significant"

2.2.2. Propuesta

Resumir, aclarar y justificar cual es el espacio de conocimiento y tecnológico que va a llenar este trabajo.

CAPÍTULO 3

Metodología

La metodología seguida en este trabajo se resume en la Figura 3.1, que muestra las principales etapas del enfoque propuesto. Tras una fase de comprensión de los datos (Sección 3.1), se desarrollan dos enfoques de modelado: uno basado en análisis radiómico (Sección 3.2), que emplea las características radiómicas extraídas de las imágenes para entrenar modelos de *Machine Learning*, y otro basado en *Deep Learning* (Sección 3.3), que utiliza directamente las imágenes. A continuación, se realiza una comparación del rendimiento de ambos enfoques mediante pruebas estadísticas (Sección 3.4) y, finalmente, se examina la interpretabilidad de los modelos (Sección 3.5) para identificar los factores que influyen en sus predicciones.




Figura 3.1: Resumen del enfoque metodológico propuesto.
Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

3.1 Comprensión de los datos

Los datos utilizados en este estudio provienen del *Public Training and Development Dataset* del reto PI-CAI (A. Saha et al. 2024), compuesto por 1.500 casos de pacientes con sospecha de cáncer de próstata clínicamente significativo, habitualmente motivada por niveles elevados de antígeno prostático específico (PSA) o hallazgos anormales en el tacto

rectal (DRE) —siempre que no hubieran sido tratados previamente ni diagnosticados con un cáncer clínicamente significativo en evaluaciones anteriores—. Todos los casos han sido completamente anonimizados y están disponibles bajo una licencia de uso no comercial.

Cada caso incluye, como mínimo, tres secuencias de resonancia magnética adquiridas en plano axial: imágenes ponderadas en T2 (T2W), imágenes ponderadas por difusión (DWI) y mapas del coeficiente de difusión aparente (ADC). Adicionalmente, algunos casos incorporan imágenes T2W en planos sagital y/o coronal, de forma opcional. Ninguno de los casos incluye imágenes obtenidas mediante contraste dinámico (DCE).

Junto con las imágenes, se proporciona una segmentación automática de la glándula prostática completa para los 1.500 casos, generada mediante un modelo de *Deep Learning* entrenado para ofrecer segmentaciones robustas. Este modelo, desarrollado por Anindo Saha et al. (2022), se basa en un ensamblado de cinco redes nnU-Net y alcanza un coeficiente de Dice medio de 0.8968 y un índice de Jaccard medio de 0.8169. También se incluyen segmentaciones zonales de la próstata, que distinguen entre la zona periférica (PZ) y la zona transicional (TZ). Por último, en 220 de los casos positivos se han anotado manualmente las lesiones correspondientes al cáncer clínicamente significativo, utilizando información radiológica, patológica y, en algunos casos, histológica. Para el resto de los 1.280 casos, se han proporcionado anotaciones automáticas mediante una estrategia de aprendizaje semisupervisado.

Además, el conjunto de datos incluye variables clínicas asociadas a cada caso, como la fecha del estudio, la edad del paciente, el valor del PSA, la densidad del PSA, el volumen prostático y el grado ISUP. A partir de este último, se construye una variable binaria que indica la presencia o ausencia de cáncer clínicamente significativo, considerando como positivos aquellos casos con un grado ISUP igual o superior a 2.

3.1.1. Secuencias de resonancia magnética y segmentaciones

De entre las modalidades de imagen y segmentaciones descritas en la introducción de esta sección, en este trabajo se emplean exclusivamente las secuencias de resonancia magnética en plano axial —T2W, DWI y ADC— junto con la segmentación de la glándula prostática completa. Esta segmentación permite excluir tejidos potencialmente no relevantes para el análisis, lo que contribuye a reducir el ruido en la entrada de los modelos. Esto posibilita evaluar, en condiciones comparables, el rendimiento de los modelos cuando se entrena con la imagen completa frente a cuando se restringe el análisis a la región prostática.

Se descartan, por el contrario, aquellos recursos del conjunto de datos que no están disponibles de forma sistemática o que no se ajustan al objetivo del estudio. Es el caso de las secuencias T2W en planos sagital y coronal, ya que no están disponibles en todos los casos y no existen secuencias complementarias en dichos planos para DWI y ADC, lo que complicaría la integración de todas las secuencias en un mismo esquema de entrada. También se omiten las segmentaciones zonales (PZ y TZ), que, si bien podrían aportar valor clínico al análisis —dado que ciertas regiones de la próstata presentan mayor frecuencia de aparición tumoral—, requerirían un procesamiento adicional no contemplado dentro del alcance temporal del presente trabajo. Del mismo modo, las anotaciones de las lesiones no se utilizan en este estudio, ya que están diseñadas para tareas de segmentación, y no resultan adecuadas para abordar el problema planteado.

Definidas las secuencias y segmentaciones a emplear, se procede a analizar sus características principales y su función dentro del flujo de trabajo.

Secuencias de resonancia magnética

Las imágenes de resonancia magnética constituyen la base fundamental de este estudio, ya que se utilizan para dos propósitos principales: como base para la extracción de descriptores cuantitativos en radiómica, los cuales se emplean posteriormente en modelos de *Machine Learning*; y como entrada directa de los modelos de *Deep Learning*. En este contexto, resulta fundamental conocer las dimensiones y el espaciado de las imágenes, ya que condicionan distintas etapas del flujo de trabajo. En radiómica, el espaciado afecta directamente al cálculo de las características y la relación entre las dimensiones puede requerir adaptar la estrategia de extracción, mientras que en *Deep Learning* es necesario alinear y redimensionar las secuencias para adaptarlas a la entrada del modelo.

De acuerdo con los valores representados en la Figura 3.2, las dimensiones promedio de las imágenes (en píxeles) varían según la secuencia de resonancia magnética. En el caso de las imágenes ponderadas en T2, el ancho y el alto son de aproximadamente 549 ± 230 píxeles, mientras que la profundidad es de 22 ± 3 cortes. Por su parte, las secuencias DWI y ADC presentan dimensiones espaciales idénticas —con anchos y altos de aproximadamente 139 ± 57 y 152 ± 49 píxeles, respectivamente, y una profundidad de 22 ± 4 cortes—, lo cual es esperable dado que el mapa ADC se deriva directamente de la secuencia DWI. Además de las diferencias entre secuencias, es importante destacar la disparidad existente entre el tamaño en plano axial (es decir, a lo largo del ancho y del alto) y el reducido número de cortes en profundidad (≈ 22) —debido al mayor espaciado entre ellos, como se verá a continuación—, lo que refleja la anisotropía de las imágenes y hace recomendable una extracción bidimensional de las características radiómicas.




Figura 3.2: Distribución de las dimensiones espaciales de las imágenes en función de la secuencia de resonancia magnética.

Por su parte, en cuanto al espaciado entre vóxeles (expresado en milímetros), según se muestra en la Figura 3.3, las secuencias DWI y ADC presentan valores idénticos en las tres dimensiones espaciales, con medias aproximadas de $1.86 \pm 0.29\text{mm}$ en ancho y alto, y de $3.25 \pm 0.36\text{mm}$ en profundidad. En cambio, la secuencia T2W muestra un espaciado considerablemente más reducido en las dos primeras dimensiones, con valores cercanos a $0.42 \pm 0.10\text{mm}$, y un espaciado de $3.19 \pm 0.28\text{mm}$ en la profundidad. Esta diferencia implica que las imágenes T2W ofrecen una resolución anatómica mucho más alta, mientras que las secuencias DWI y ADC se perciben como más «pixeladas», ya que presentan un espaciado aproximadamente 4.4 veces mayor en el plano axial.




Figura 3.3: Distribución del espaciado de las imágenes por secuencia.

Las diferencias en tamaño y espaciado, junto con la marcada anisotropía de las imágenes, tienen implicaciones directas en el procesamiento posterior. En radiómica, el espaciado debe homogeneizarse para garantizar la coherencia en el cálculo de características, y la falta de isotropía entre planos justifica la extracción de características basada en cortes bi-dimensionales. En *Deep Learning*, por su parte, las dimensiones espaciales condicionan el preprocesamiento necesario para adaptar las imágenes al tamaño de entrada del modelo. Estos aspectos se describirán en detalle en las secciones posteriores de la metodología.

Segmentaciones

Las segmentaciones de la glándula prostática tienen un papel fundamental en este estudio, ya que permiten restringir el análisis a la región anatómica de interés, excluyendo el tejido circundante potencialmente irrelevante. Para evaluar el impacto de esta estrategia, se comparan dos configuraciones de entrada: una basada en las imágenes axiales completas y otra en la que se aplica la máscara de segmentación para limitar el análisis exclusivamente a la glándula prostática. Se espera que esta reducción del ruido en las imágenes de entrada contribuya a mejorar el rendimiento de los modelos, al centrar el aprendizaje en las áreas anatómicamente más relevantes para la clasificación de la severidad del cáncer de próstata.

Cada segmentación se representa mediante una máscara binaria, donde los vóxeles que pertenecen a la glándula prostática toman el valor 1 y los vóxeles restantes el valor 0. Estas máscaras presentan las mismas dimensiones espaciales que las secuencias T2W. Para asegurar la correspondencia espacial con el resto de secuencias, se aplica un remuestreo que adapta las máscaras al espacio de cada imagen –como en la extracción de características radiómicas– o, alternativamente, todas las imágenes y la máscara a un espacio común de referencia –como en el enfoque de *Deep Learning*–.

En la Figura 3.4 se muestra un ejemplo visual del proceso de segmentación. A la izquierda, se presenta una imagen T2W, en la que se visualiza la imagen original completa. En el centro, se muestra la correspondiente máscara binaria de segmentación, donde los vóxeles pertenecientes a la próstata aparecen destacados en blanco. A la derecha, se representa el resultado de aplicar la máscara sobre la imagen T2W original, dejando visibles únicamente los tejidos pertenecientes a la glándula prostática y eliminando el resto de la anatomía.




Figura 3.4: Ejemplo visual del proceso de segmentación en una imagen T2W. Se representa la imagen original, la máscara de la segmentación y la imagen resultante tras aplicar la máscara.

3.1.2. Datos clínicos

De entre las variables clínicas disponibles en el conjunto de datos, en este trabajo se utiliza exclusivamente la variable binaria que indica la presencia o ausencia de cáncer de próstata clínicamente significativo, que servirá como variable objetivo. Aunque otras variables como la edad del paciente, el valor del PSA, la densidad del PSA o el volumen prostático podrían aportar información relevante para la estratificación diagnóstica, su incorporación queda fuera del alcance de este estudio, orientado a evaluar la capacidad de los modelos para discriminar entre cáncer clínicamente significativo e indolente basándose exclusivamente en las imágenes de resonancia magnética, sin apoyo de información clínica adicional.

Por su parte, el grado ISUP, que clasifica la severidad del cáncer de próstata en una escala de 0 a 5, se descartó como variable objetivo debido al elevado desbalanceo en su distribución. Como se muestra en la Figura 3.5, la mayoría de los casos se concentran en el nivel 0, mientras que los niveles superiores presentan un número muy reducido de muestras, lo que afectaría negativamente al proceso de entrenamiento y dificultaría la construcción de modelos robustos para la clasificación multiclase.




Figura 3.5: Distribución de casos en función del grado ISUP.

Por este motivo, se adopta un enfoque de clasificación binaria, distinguiendo entre casos negativos (ISUP 0 o 1) y casos positivos (ISUP ≥ 2). Aunque esta nueva variable mantiene un cierto desequilibrio entre clases —como se observa en la Figura 3.6—, la distribución es más equilibrada que en la clasificación original por grados ISUP, lo que facilita el entrenamiento de los modelos de clasificación. No obstante, este desequilibrio sigue suponiendo un desafío que será tenido en cuenta tanto en la configuración experimental como en la interpretación de los resultados.




Figura 3.6: Distribución de casos en función de la presencia o ausencia de csPCa.

3.2 Análisis radiómico

El enfoque radiómico desarrollado en este trabajo sigue las recomendaciones propuestas por la European Society of Medical Imaging Informatics (EuSoMII), desarrolladas en la guía *ESR Essentials: Radiomics—Practice Recommendations*, elaborada por Santinha et al. (2025). Este documento recoge un conjunto de recomendaciones metodológicas orientadas a garantizar la reproducibilidad de los análisis basados en radiómica, abarcando todas las etapas del flujo de trabajo: desde el preprocesamiento de las imágenes y la extracción de características, hasta el desarrollo, validación y explicación de los modelos predictivos. Adicionalmente, para asegurar una adecuada implementación de estas directrices, parte del código original publicado junto con la guía se ha empleado como punto de partida, adaptándolo posteriormente para ajustarse a las elecciones metodológicas y objetivos específicos del presente estudio.

Siguiendo este marco de referencia, la metodología aplicada se estructura en varias fases, que se resumen de forma esquemática en la Figura 3.7. La primera etapa corresponde al preprocesamiento de las imágenes (Sección 3.2.1), donde se aplican técnicas orientadas a mejorar la calidad de los datos y a garantizar la correcta localización de las segmentaciones en cada secuencia. A continuación, se lleva a cabo la extracción de características radiómicas (Sección 3.2.2), que se realiza por separado para cada una de las tres secuencias de resonancia magnética. Esta etapa se aborda mediante dos enfoques: uno que considera únicamente la glándula prostática y otro que emplea la imagen completa.

En ambos casos, se aplican distintos filtros y se generan conjuntos de características que describen cuantitativamente la información presente en las imágenes. Finalmente, en la fase de modelado (Sección 3.2.3), se construyen y validan distintos modelos de *Machine Learning* utilizando la concatenación de los conjuntos de características extraídos de cada secuencia de resonancia magnética, manteniendo por separado los enfoques de imagen completa y glándula prostática. La optimización se realiza únicamente sobre el modelo que presenta el mejor rendimiento.




Figura 3.7: Resumen del enfoque metodológico propuesto en el análisis radiómico. Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

3.2.1. Preprocesamiento de las imágenes

El preprocesamiento constituye una etapa fundamental en el flujo de trabajo radiómico, ya que permite minimizar las fuentes de variabilidad presentes en las imágenes de resonancia magnética, mejorando así la reproducibilidad de las características extraídas. En este estudio se han aplicado dos pasos fundamentales: la corrección del campo de sesgo (*bias field correction*) y la reducción de ruido mediante filtrado anisotrópico (*anisotropic diffusion*). Adicionalmente, se realizó un remuestreo espacial de las máscaras para garantizar su correcta correspondencia con la geometría de cada secuencia.

Corrección del campo de sesgo

La corrección del campo de sesgo tiene como objetivo eliminar una señal suave de baja frecuencia no deseada, conocida como *bias field*, que afecta a las imágenes de resonancia magnética y que se origina debido a inhomogeneidades en los campos magnéticos del escáner. Esta señal difumina la imagen, reduce el contenido de alta frecuencia —como bordes y contornos— y altera la distribución de niveles de gris, haciendo que un mismo tejido presente distintas intensidades según su localización espacial (Juntu et al. 2005).

Para mitigar estas inhomogeneidades, en este trabajo se ha aplicado el algoritmo *N4 Bias Field Correction*, disponible en la librería *SimpleITK*. Tras su aplicación, las intensidades de las imágenes se vuelven más homogéneas para un mismo tipo de tejido, reduciendo el impacto de artefactos inducidos por el escáner, lo que tiene un impacto significativo en la estabilidad de las características radiómicas (Stamoulou et al. 2022).

A modo ilustrativo, en la Figura 3.8 se muestra el efecto de la corrección del campo de sesgo sobre imágenes T2 ponderadas. Aunque visualmente las diferencias entre la imagen original y la homogeneizada son sutiles, la imagen de diferencia permite apreciar mejor la corrección aplicada. Este mismo preprocesamiento se ha aplicado a las otras dos secuencias utilizadas en el estudio.




Figura 3.8: Efecto de la corrección del campo de sesgo en imágenes T2W.

Reducción de ruido mediante filtrado anisotrópico

Sobre las imágenes homogeneizadas, se aplica un proceso de reducción de ruido basado en difusión anisotrópica, que actúa como un filtro de paso bajo selectivo: suaviza las regiones homogéneas eliminando el ruido de alta frecuencia, pero preserva los bordes y detalles estructurales (Insight Toolkit 2023). De este modo, evita la pérdida de información relevante como los contornos de lesiones o límites anatómicos. Este método resulta especialmente adecuado para secuencias de resonancia magnética propensas al ruido, como DWI y ADC, aunque también puede mejorar la nitidez general en imágenes T2W.

En este trabajo, se ha utilizado el filtro *CurvatureAnisotropicDiffusionImageFilter* de la librería *SimpleITK*, que implementa una variante de la difusión anisotrópica clásica. A diferencia del método tradicional de Perona-Malik, esta implementación basada en curvatura ofrece menor sensibilidad al contraste, lo que permite preservar estructuras y detalles más finos en las imágenes. Aunque cada iteración requiere aproximadamente el doble de tiempo de procesamiento que la difusión anisotrópica basada en gradiente, este algoritmo generalmente necesita menos iteraciones para alcanzar resultados aceptables, lo que compensa parcialmente esta desventaja computacional (Insight Toolkit 2025).

Como ejemplo representativo de este proceso, la Figura 3.9 muestra el resultado del suavizado mediante difusión anisotrópica por curvatura aplicado a imágenes DWI. Se presentan la imagen homogeneizada, la suavizada y la imagen de diferencia, donde se aprecian las regiones en las que se ha eliminado ruido de alta frecuencia.




Figura 3.9: Efecto del suavizado por difusión anisotrópica por curvatura en imágenes DWI.

Remuestreo espacial de las máscaras

Una vez preprocesadas las imágenes, es necesario garantizar también la correcta correspondencia espacial entre las máscaras de segmentación y las distintas secuencias de resonancia magnética. Dado que las máscaras originales presentan las dimensiones de las imágenes T2W, su uso directo sobre secuencias con diferente resolución espacial —como DWI o ADC— provocaría un desajuste entre la región segmentada y el tejido correspondiente en la imagen, lo que introduciría errores en la extracción de características radiómicas.

Para evitar esta incoherencia espacial, en los experimentos basados en la glándula prostática se aplica un proceso de remuestreo que adapta cada máscara a la resolución y tamaño de la secuencia correspondiente. Este remuestreo se realiza mediante interpolación por vecino más cercano (utilizando la función *sitkNearestNeighbor* de la librería *SimpleITK*), una técnica que garantiza la preservación de los valores discretos de la máscara (0 para el fondo y 1 para la glándula), evitando la aparición de valores no binarios que podrían distorsionar los contornos o modificar el volumen de la región de interés.

El efecto de este proceso puede observarse en la Figura 3.10, donde se representa una imagen DWI junto con la máscara original —definida sobre la secuencia T2W—, la versión remuestreada a la resolución de la DWI, y el resultado final tras aplicar dicha máscara sobre la imagen original. Se aprecia cómo el remuestreo permite mantener la coherencia espacial entre la segmentación y la secuencia analizada, lo que resulta fundamental para garantizar una extracción precisa y localizada de las características radiómicas.

En cambio, cuando se emplea el enfoque basado en la imagen completa, este remuestreo no resulta necesario, ya que no se emplea una segmentación anatómica explícita. En su lugar, se utiliza una máscara binaria de unos con las dimensiones exactas de cada secuencia, de forma que todo el volumen visible se considera región de interés para la extracción de características.




Figura 3.10: Ejemplo visual del proceso de segmentación en una imagen DWI. Se representa la imagen original, la máscara de la segmentación, la máscara de la segmentación remuestreada y la imagen resultante tras aplicar la máscara.

3.2.2. Extracción de características radiómicas

Tras el preprocesamiento de las imágenes se procede a la extracción de características radiómicas. Esta etapa busca transformar la información contenida en las imágenes preprocesadas en descriptores cuantitativos que caracterizan las propiedades morfológicas y texturales de los tejidos. Para ello, se ha utilizado la librería PyRadiomics (Griethuysen et al. 2017), ampliamente empleada en estudios de radiómica por su flexibilidad y conformidad con las directrices del *Image Biomarker Standardisation Initiative* (Zwanenburg et al. 2016), lo que garantiza la estandarización y reproducibilidad de los descriptores generados.

Como se ha mencionado anteriormente, el proceso de extracción se ha implementado considerando dos configuraciones de entrada: la imagen completa y la glándula prostática exclusivamente, con el fin de evaluar la influencia de limitar el análisis únicamente al tejido anatómico relevante. Cada configuración se aplica de forma independiente sobre las tres modalidades de resonancia magnética consideradas en este trabajo, dando como resultado un total de seis conjuntos de características (2 configuraciones $\times$ 3 secuencias). A continuación, se detallan los parámetros utilizados en la extracción, así como los filtros aplicados a las imágenes y los tipos de características extraídas.

Configuración de la extracción de características

La configuración del proceso de extracción de características radiómicas requiere definir diversos parámetros que influyen directamente en la calidad y reproducibilidad de los descriptores obtenidos. En este trabajo, dichos parámetros se han adaptado individualmente para cada una de las tres modalidades de resonancia magnética, teniendo en cuenta las particularidades inherentes a cada tipo de imagen.

En la Tabla 3.1 se presenta un resumen de los principales parámetros empleados en este estudio, diferenciados por modalidad. A continuación, se justifica su configuración, profundizando en aquellos parámetros que requieren cálculos específicos para su determinación.

Normalización y ajuste de intensidades

- Normalización (normalize): Aplicada a DWI y T2W debido a que presentan intensidades relativas que varían entre diferentes escáneres y configuraciones de adquisición. No se aplica en ADC, ya que sus valores reflejan magnitudes físicas absolutas que deben preservarse sin alteración.

- Escala de normalización (`normalizeScale`) y desplazamiento (`voxelArrayShift`): Para las imágenes DWI y T2W, después de la normalización, las intensidades se multiplican por 100 para ampliar el rango y permitir la selección de un *binWidth* que genere un número adecuado de intervalos. Posteriormente, se aplica un desplazamiento positivo de 300 unidades con el fin de eliminar valores negativos y evitar problemas en el cálculo de descriptores sensibles a este tipo de valores.

Extracción en 2D

Dada la marcada anisotropía de las imágenes —observada previamente en la Figura 3.2— la extracción de características se ha realizado de forma bidimensional sobre cortes axiales (`force2D` activado con `force2Ddimension = 0`), sin realizar remuestreo isotrópico en 3D —proceso que puede introducir artefactos de interpolación y alterar la textura original de la imagen—, lo que permite preservar con mayor fidelidad la información contenida en cada corte.

Remuestreo espacial

Las imágenes se remuestrean a un espaciado uniforme definido mediante el parámetro `resampledPixelSpacing`, calculado a partir de la resolución media observada para cada modalidad (Figura 3.3). En concreto, se utiliza un espaciado más fino para T2W (en torno a $[0.42, 0.42, 0]$ mm), dada su mayor resolución anatómica, y un espaciado de aproximadamente $[1.85, 1.85, 0]$ mm para ADC y DWI, acorde a su menor resolución espacial. El valor 0 en la tercera dimensión indica que no se aplica remuestreo entre cortes, en línea con la extracción bidimensional establecida. En todos los casos, la interpolación se realiza mediante el método B-Spline (`interpolator`), que ofrece un buen equilibrio entre calidad y eficiencia (Meijering 2002).

Discretización de intensidades

El ancho de discretización (`binWidth`) define el tamaño de los intervalos utilizados para construir histogramas y discretizar los niveles de intensidad de la imagen. Se calculó a partir del rango promedio de intensidades (`firstorder:Range`) de cada modalidad, seleccionando un valor que produjera aproximadamente 64 bins, dentro del rango sugerido en la literatura (16–128 bins), el cual ha mostrado una buena reproducibilidad sin diferencias significativas en las características extraídas dentro de este intervalo (Santinha et al. 2025 cit. Tixier et al. 2011). De acuerdo con este criterio, los valores finales de `binWidth` utilizados fueron 61.27 para ADC, 37.05 para DWI y 11.93 para T2W.

Validación de la máscara y eficiencia computacional

- Pre-recorte (`preCrop`): Se activa para todas las modalidades, limitando la imagen al área cubierta por la máscara de segmentación. Esto optimiza notablemente el rendimiento computacional al reducir la memoria utilizada y agilizar el procesamiento posterior.
- Corrección de máscara (`correctMask`) y tolerancia geométrica (`geometryTolerance`): Estos parámetros aseguran la coherencia espacial entre la máscara y la imagen. Se ha habilitado la corrección automática de pequeñas incoherencias y establecido una tolerancia geométrica de 10^3 . Este valor elevado no afecta a la precisión del análisis, ya que se realiza un remuestreo previo y la extracción de características se fuerza en cortes 2D, lo que asegura la coherencia espacial entre la máscara y la imagen.

Parámetro	ADC	DWI	T2W
normalize	false	true	true
normalizeScale	–	100	100
voxelArrayShift	–	300	300
preCrop	true	true	true
resampledPixelSpacing	[1.85, 1.85, 0]	[1.85, 1.85, 0]	[0.42, 0.42, 0]
interpolator	B-Spline	B-Spline	B-Spline
force2D	true	true	true
force2Ddimension	0	0	0
geometryTolerance	10 ³	10 ³	10 ³
correctMask	true	true	true
binWidth	61.27	37.05	11.93

Tabla 3.1: Configuración de los parámetros de PyRadiomics para cada modalidad de imagen.

Aplicación de filtros de imágenes

En este trabajo, se han aplicado diversos filtros a las imágenes, con el objetivo de mejorar la cuantificación de características y patrones clínicamente relevantes antes de la extracción de descriptores (Santinha et al. 2025 cit. Whybra et al. 2024). Este proceso permite resaltar estructuras específicas como bordes, texturas o regiones homogéneas, facilitando la detección de patrones que podrían no ser evidentes en las imágenes originales.

Aunque la aplicación de filtros incrementa considerablemente el número de características extraídas, resultados recientes de Demircioğlu (2022) han mostrado que combinar características extraídas de imágenes originales y filtradas puede ser beneficioso, ya que este enfoque logra un rendimiento predictivo similar o incluso superior al obtenido utilizando únicamente las características de las imágenes originales.

Los filtros aplicados en este estudio se ilustran en la Figura 3.11, mostrando su efecto sobre una imagen T2W, y se describen a continuación:

- **Original:** Imagen sin modificaciones; las características se extraen directamente de los valores originales de intensidad.
- **LoG (Laplacian of Gaussian):** Filtro que resalta bordes y estructuras pequeñas mediante una convolución Gaussiana seguida de un operador Laplaciano, con valores de sigma de 0.6, 2 y 3 para detectar estructuras en distintos tamaños y niveles de detalle.
- **Wavelet:** Aplicación de transformada wavelet con descomposición en dos niveles, capturando simultáneamente patrones de textura en distintas frecuencias (altas frecuencias para detalles finos y bajas frecuencias para estructuras más globales).
- **Square y SquareRoot:** Transformaciones no lineales que modifican el contraste local y ajustan el rango dinámico de intensidades. Square potencia las regiones de alta intensidad y SquareRoot resalta detalles en zonas de baja intensidad.
- **Logarithm:** Compresión de los rangos altos de intensidad, aumentando la visibilidad de detalles en zonas oscuras y de menor contraste.
- **Exponential:** Amplifica las diferencias en valores de intensidad más elevados, resaltando áreas brillantes y generando mayor contraste en zonas con valores de gris más altos.




Figura 3.11: Ejemplo del efecto de los filtros aplicados sobre una imagen T2W. Se muestran la imagen original y los resultados tras aplicar los filtros LoG, Exponential, Logarithm, Square, SquareRoot y Wavelet.

Tipos de características extraídas

Una vez finalizadas las etapas previas del flujo de trabajo, se realizó la extracción de características radiómicas tanto sobre las imágenes originales como sobre las transformadas mediante los filtros aplicados. Estas características se agrupan en seis categorías según la clasificación de la librería PyRadiomics, y sus descripciones se han sintetizado a partir de las definiciones establecidas por la *Image Biomarker Standardisation Initiative* (Zwanenburg et al. 2016):

- **Shape Features:** Describen las propiedades geométricas de la región de interés, como volumen, área de superficie, esfericidad o compacidad. Se calculan directamente sobre la forma de la máscara segmentada, sin considerar intensidades de la imagen.

- **First-Order Features:** Calculan estadísticas basadas únicamente en la distribución de intensidades de la imagen, sin tener en cuenta la relación espacial entre píxeles. Incluyen medidas como la media, desviación estándar, curtosis, asimetría y entropía.
- **GLCM (Grey Level Co-occurrence Matrix):** Evalúan la frecuencia con la que ocurren combinaciones de intensidades discretizadas en píxeles adyacentes.
- **GLRLM (Grey Level Run Length Matrix):** Analizan la longitud de secuencias consecutivas de píxeles con la misma intensidad en una dirección determinada.
- **GLSZM (Grey Level Size Zone Matrix):** Evalúan las zonas homogéneas de intensidades discretizadas, considerando su tamaño y la frecuencia con que aparecen.
- **NGTDM (Neighbouring Grey Tone Difference Matrix):** Calculan la diferencia de intensidad entre un píxel central y la media de sus vecinos.
- **GLDM (Grey Level Dependence Matrix):** Miden la dependencia entre intensidades de píxeles, evaluando cuántos vecinos de un píxel central presentan valores de intensidad similares.

3.2.3. Entrenamiento, evaluación y optimización de modelos

La etapa de modelado parte de la construcción de una estructura de datos unificada que integra las características extraídas de las tres secuencias de resonancia magnética (T2W, DWI y ADC), manteniendo por separado los enfoques de imagen completa y glándula prostática. Esta estrategia permite garantizar una comparación rigurosa entre los enfoques de radiómica y *Deep Learning*, asegurando que los modelos evaluados en cada enfoque trabajen con la misma información de entrada.

Como posible alternativa, se contempló entrenar modelos independientes para cada secuencia y combinar sus salidas mediante técnicas de *ensemble*. Sin embargo, esta opción no solo ofreció un rendimiento ligeramente inferior en una evaluación inicial, sino que además complicaba la interpretabilidad de las predicciones. Con base en estas consideraciones, se descartó dicha alternativa y se adoptó la concatenación directa de las características.

Una vez establecida la estrategia de concatenación, se procede al entrenamiento, validación y optimización de los modelos de *Machine Learning*. La fase inicial incluye el entrenamiento y evaluación de distintos clasificadores mediante validación cruzada estratificada por paciente, utilizando la estructura de características previamente descrita. Posteriormente, se procede a la optimización de los hiperparámetros del modelo que, según los resultados obtenidos en la comparación descrita en la Sección 3.4, presente el mejor rendimiento, empleando técnicas de búsqueda bayesiana y realizando, además, un análisis de calibración de las probabilidades estimadas. La metodología aplicada para abordar la explicabilidad de las predicciones se detalla en la Sección 3.5.

Entrenamiento y evaluación de modelos

Selección de variables

Como resultado de la concatenación de las características extraídas de las tres secuencias de resonancia magnética, y considerando la aplicación de múltiples filtros durante la fase de extracción, se obtiene un conjunto de datos de elevada dimensionalidad. Este gran número de variables (más de 4000), en relación con el tamaño de la muestra (1500

casos), puede inducir problemas de sobreajuste y afectar negativamente a la capacidad de generalización de los modelos.

Para estudiar cómo afecta la elevada dimensionalidad al rendimiento de los clasificadores, se plantean dos escenarios experimentales:

- **Uso de todas las características:** se entrenan modelos utilizando la totalidad de las variables disponibles, con el objetivo de evaluar la capacidad de los modelos para gestionar directamente la alta dimensionalidad sin aplicar técnicas de reducción.
- **Selección de las características más discriminativas:** se realiza una selección basada en pruebas estadísticas, con el objetivo de reducir la dimensionalidad y limitar el riesgo de sobreajuste.

En caso de aplicar la selección de variables, se lleva a cabo un procedimiento univariante que evalúa de forma independiente la capacidad de cada característica para discriminar entre las clases. Este procedimiento sigue los siguientes pasos:

1. **Prueba de normalidad.** Como primer paso, se analiza la distribución de cada variable mediante el test de Shapiro–Wilk. Esta prueba permite determinar si es adecuado utilizar un test paramétrico o no paramétrico en la comparación de grupos:
 - Si el p-valor es superior a 0.05, se asume normalidad en la variable y se aplica un test paramétrico, más adecuado cuando los datos siguen una distribución normal.
 - Si el p-valor es igual o inferior a 0.05, se considera que la variable no sigue una distribución normal y se recurre a una prueba no paramétrica.
2. **Comparación de grupos.** Una vez establecida la naturaleza de la distribución, se analiza la capacidad de cada variable para diferenciar entre los grupos no-cSPCa y cSPCa.
 - En variables con distribución normal, se aplica el test t de Student, que permite comparar las medias entre ambos grupos.
 - Si no se cumple la normalidad, se utiliza el test de Mann–Whitney U, adecuado para comparar medianas sin requerir supuestos sobre la forma de la distribución.

El p-valor obtenido en esta fase cuantifica la evidencia estadística de que la variable presenta diferencias entre los grupos.

3. **Selección final de variables.** Las variables se ordenan según su p-valor, obteniendo así un listado como el mostrado en la Tabla 3.2, que presenta un extracto con las cinco primeras variables más discriminativas obtenidas en un caso concreto. Ciertas métricas calculadas junto con el p-valor, como el umbral de decisión óptimo, la sensibilidad, la especificidad y el AUC de cada variable, no se muestran en la tabla ya que no se utilizan en el proceso de selección de variables, aunque pueden tener relevancia clínica o ser de interés en análisis complementarios.

Una vez ordenadas, se seleccionan las variables que presentan mayor evidencia de diferenciación entre grupos (menores p-valores), aplicando un límite máximo de una variable por cada 15 observaciones disponibles. Dado que el conjunto de datos incluye 1500 casos, este criterio permite seleccionar como máximo 100 variables.

Variable	...	p-value
dwi_square_ngtdm_Strength	...	1.85E-48
dwi_log-sigma-3-mm-3D_firstorder_Skewness	...	7.79E-41
dwi_exponential_glcml_Imc1	...	1.13E-38
dwi_exponential_ngtdm_Strength	...	1.19E-37
dwi_exponential_glszm_GrayLevelNonUniformityNormalized	...	2.14E-37
...	...	...

Tabla 3.2: Ejemplo de salida del proceso de selección de variables (extracto con las 5 primeras variables ordenadas por p-valor).

Modelos evaluados

Independientemente de si se utilizan todas las variables disponibles o se aplica previamente un proceso de selección, se consideran distintos modelos de *Machine Learning* para abordar la tarea de clasificación a partir de las características radiómicas extraídas. En concreto, se entrenan y evalúan los siguientes algoritmos: *Support Vector Machine*, Regresión Logística, *Random Forest*, *Naive Bayes*, *K-Nearest Neighbors* y *Gradient Boosting*.

Para asegurar que estos modelos trabajen con datos adecuados y evitar que factores como la disparidad de escalas o la falta de variabilidad en algunas características afecten al proceso de aprendizaje, se aplican las siguientes transformaciones sobre los datos:

- **Estandarización de características.** Las características radiómicas extraídas pueden presentar escalas de magnitud muy diferentes, lo que puede afectar negativamente a determinados algoritmos de clasificación. Por este motivo, se aplica una estandarización mediante normalización *z-score*, transformando las variables para que presenten media cero y desviación estándar unitaria. De este modo, se garantiza que todas las características contribuyan de forma comparable al ajuste de los modelos, evitando que aquellas con rangos numéricos mayores dominen el comportamiento del clasificador.
- **Eliminación de variables con varianza nula.** Se descartan aquellas variables que presentan varianza nula, es decir, que tienen un valor constante en todos los casos. Estas variables no aportan información relevante para la discriminación entre clases y su inclusión no solo es irrelevante, sino que puede introducir redundancia en los datos y afectar negativamente a la eficiencia computacional.

Procedimiento de validación

El rendimiento de los modelos se evalúa mediante validación cruzada estratificada por paciente, utilizando la función *StratifiedGroupKFold*, de la librería *scikit-learn*. Este procedimiento asegura que cada fold mantenga una distribución de clases similar a la del conjunto de datos completo y, además, que los casos correspondientes a un mismo paciente no se distribuyan entre los conjuntos de entrenamiento y validación. Esta restricción es especialmente importante, ya que un mismo paciente puede aportar más de un caso al conjunto de datos, y su separación entre particiones podría inducir un sesgo optimista en la evaluación debido a la posible similitud entre sus muestras.

Siguiendo esta metodología, se aplica un esquema de 5 particiones ($K=5$), repitiendo el proceso un total de 10 veces con distintas semillas de aleatorización. De este modo, se entrenan 50 clasificadores por cada modelo considerado, lo que permite obtener estimaciones más estables y robustas del rendimiento, reduciendo la influencia de particiones específicas.

Para cada uno de los clasificadores entrenados, se calculan y registran las siguientes métricas de evaluación:

- Área bajo la curva ROC (AUC).
- *F1-Score* (binario y macro).
- *Accuracy* y *balanced accuracy*.
- Coeficiente de correlación de Matthews (MCC).
- Kappa de Cohen.
- Sensibilidad y especificidad.
- Valores predictivos positivo (PPV) y negativo (NPV).
- Métricas por clase: precisión, recall, F1-Score y *accuracy*.

Además, se almacenan las predicciones y probabilidades estimadas por los modelos, permitiendo la posterior generación de análisis complementarios. En particular, se construyen curvas ROC tanto para el fold con mejor AUC (fold óptimo) como para el fold cuyo AUC es más cercano a la mediana (fold representativo).

Optimización del modelo seleccionado

Una vez entrenados todos los modelos y comparados sus resultados mediante las técnicas descritas en la Sección 3.4, se selecciona el clasificador que presenta el mejor rendimiento global, atendiendo a criterios como el AUC, la sensibilidad, la especificidad y el análisis de las curvas ROC. Sobre este modelo se aplica un proceso de optimización, evaluación y calibración con el objetivo de mejorar su desempeño final y ajustar adecuadamente sus probabilidades de predicción.

Optimización de hiperparámetros

Tras seleccionar el modelo a optimizar, se procede a ajustar sus hiperparámetros con el objetivo de mejorar su capacidad predictiva. Para este fin, se recurre a la búsqueda bayesiana, una estrategia que modela de forma probabilística la función de evaluación de los hiperparámetros y utiliza esta información para seleccionar de forma eficiente las configuraciones más prometedoras (Wu et al. 2019). A diferencia de métodos como la búsqueda exhaustiva (*grid search*), que evalúan de forma sistemática todas las combinaciones posibles, o la búsqueda aleatoria, que explora el espacio sin un criterio dirigido, la búsqueda bayesiana aprovecha el conocimiento adquirido en las iteraciones previas para guiar de forma inteligente la exploración. Esto permite encontrar configuraciones óptimas con un menor número de evaluaciones.

Siguiendo este planteamiento, la optimización de hiperparámetros se realiza con la función *BayesSearchCV* de la librería *scikit-optimize*, aplicando validación cruzada estratificada por paciente para asegurar la robustez del proceso. La métrica principal de referencia es el AUC, aunque se calculan y monitorizan otras métricas complementarias. El espacio de búsqueda definido para cada modelo se detalla en la Tabla 3.3.

Modelo	Hiperparámetro	Rango/Valores
SVM	C (Regularización)	$[10^{-4}, 10^3]$
	kernel	{linear, rbf, poly}
	gamma	$[10^{-4}, 10^3]$
	coef0	[0, 1]
Regresión Logística	C (Regularización)	$[10^{-4}, 10^3]$
	penalty	{l1, l2, elasticnet}
	l1_ratio	[0.1, 0.9]
Random Forest	n_estimators	{50, ..., 1024}
	max_depth	{1, ..., 10}
	max_features	{sqrt, log2, None}
	min_samples_split	{2, ..., 20}
Naive Bayes	-	No aplica
KNN	n_neighbors	{2, ..., 8}
	weights	{uniform, distance}
Gradient Boosting	n_estimators	{50, ..., 1024}
	learning_rate	$[10^{-4}, 0.1]$
	max_depth	{1, ..., 10}
	subsample	[0.5, 1.0]
	max_features	{sqrt, log2, None}

Tabla 3.3: Espacio de búsqueda de hiperparámetros definido para cada modelo.

Evaluación en el conjunto de test

Una vez optimizados los hiperparámetros, se evalúa el modelo resultante sobre el conjunto de validación, calculando métricas como el AUC, exactitud, sensibilidad, especificidad, F1-score, Kappa de Cohen, coeficiente de correlación de Matthews (MCC) y valores predictivos positivo y negativo. Además, se genera la correspondiente matriz de confusión para analizar visualmente los aciertos y errores de clasificación. Esta evaluación se realiza antes de aplicar cualquier proceso de calibración, permitiendo comparar posteriormente el impacto de dicho ajuste en las probabilidades de predicción.

Calibración del modelo

Tras evaluar el modelo optimizado, se lleva a cabo un proceso de calibración con el objetivo de ajustar las probabilidades estimadas y mejorar su utilidad en la toma de decisiones clínicas. Una adecuada calibración permite que las probabilidades predichas reflejen de forma precisa la probabilidad real de que un caso pertenezca a la clase positiva o a la clase negativa, facilitando así la correcta interpretación de los resultados y la toma de decisiones diagnósticas.

Con este objetivo, se aplica la técnica de Platt Scaling, que ajusta una función sigmoide sobre las salidas del clasificador y ha demostrado ser eficaz, especialmente en contextos con tamaños de muestra limitados, donde métodos más complejos como la calibración isotónica pueden inducir sobreajuste (Niculescu-Mizil y Caruana 2005). En consecuen-

cia, la calibración se lleva a cabo mediante la función *CalibratedClassifierCV* de la librería *scikit-learn* empleando el método *sigmoid*, utilizando validación cruzada interna con 5 particiones para estimar los parámetros de la función de calibración.

Como parte de este procedimiento, se generan curvas de calibración antes y después de la aplicación de la técnica, permitiendo visualizar de forma gráfica la mejora en la correspondencia entre las probabilidades predichas y las frecuencias observadas. Además, se determina el umbral de decisión óptimo mediante la maximización del F1-score, lo que permite equilibrar la sensibilidad y la especificidad del modelo en función del comportamiento observado en los datos de validación.

Por último, se reevalúa el modelo sobre el conjunto de validación utilizando el umbral óptimo calculado y se genera la matriz de confusión correspondiente, facilitando la interpretación visual del comportamiento del modelo tras la calibración.

3.3 Deep Learning

La metodología seguida para el desarrollo de modelos basados en *Deep Learning*, implementada con la librería *MONAI* (Cardoso et al. 2022), se resume en la Figura 3.12, que presenta las principales etapas del proceso. El flujo de trabajo comienza con el preprocesamiento de las imágenes (Sección 3.3.1), donde, inicialmente, se aplican técnicas de homogeneización espacial sobre cada secuencia de forma independiente, como el remuestreo y el ajuste de dimensiones, seguidas de la normalización de intensidades. Una vez completadas estas transformaciones, las diferentes modalidades se concatenan en un único tensor multicanal. Finalmente, en determinados casos, se aplica aumento de datos para mejorar la capacidad de generalización de los modelos. Además, de la misma manera que en el análisis radiómico, se consideran dos configuraciones en función de la región de la imagen utilizada: imagen completa o exclusivamente la glándula prostática. A continuación, se presentan las arquitecturas consideradas (Sección 3.3.2) y el procedimiento de entrenamiento y validación aplicado (Sección 3.3.3), siguiendo un esquema de validación cruzada muy similar al empleado en el análisis radiómico.




Figura 3.12: Resumen del enfoque metodológico propuesto en el análisis con *Deep Learning*.

Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

Las siguientes fuentes, en orden, corresponden a las imágenes de las arquitecturas: Huang et al. (2018), Insightful TScript (s.f.), Dosovitskiy et al. (2021), T. Ahmed y Sabab (2020)

3.3.1. Preprocesamiento de las imágenes

De la misma manera que en radiómica, el preprocesamiento de las imágenes constituye un paso fundamental en la metodología de *Deep Learning*. Durante este proceso, se aplican de forma secuencial las transformaciones necesarias sobre cada secuencia, con el objetivo de estandarizar su resolución y escala de intensidades antes del entrenamiento. A continuación, según la estrategia experimental, se restringe o no la región de interés a la glándula prostática, se concatenan las modalidades y, en algunos casos, se incorporan técnicas de aumento de datos para enriquecer el conjunto de entrenamiento.

Remuestreo espacial: `ResampleToMatchd`

El primer paso consiste en alinear las secuencias de resonancia magnética ADC y DWI con la secuencia T2W, que se toma como referencia espacial. Esta operación garantiza que todas las secuencias compartan el mismo sistema de coordenadas físicas, permitiendo que la información anatómica contenida en cada una de ellas se corresponda de forma precisa en el espacio. La interpolación utilizada es de tipo bilineal, ya que ofrece un compromiso adecuado entre calidad de imagen y eficiencia computacional, generando transiciones más graduales entre píxeles que el método de vecino más cercano sin requerir los cálculos extensos de técnicas más complejas como la interpolación spline (Patil 2018).

Redimensionado de las imágenes: `Resized`

Una vez remuestreadas, las imágenes se redimensionan a un tamaño común de $128 \times 128 \times 32$ voxels, mediante la operación `Resized`. Esta transformación tiene como objetivo adaptar las dimensiones de entrada al tamaño requerido por las arquitecturas de *Deep Learning*, garantizando que todas las muestras presenten el mismo tamaño espacial.

La elección de estas dimensiones permite conservar la información estructural necesaria para el aprendizaje de patrones discriminativos, evitando al mismo tiempo la generación de tensores excesivamente grandes que dificulten la eficiencia del proceso. Esta configuración se ajusta a las dimensiones promedio observadas en las imágenes T2W (véase Figura 3.2), aplicando una reducción axial y un aumento moderado en la profundidad que asegura la cobertura completa del volumen prostático incluso en los casos con mayor número de cortes.

Normalización de intensidades: `ScaleIntensityd`

Tras ser ajustadas espacialmente, las imágenes se someten a una normalización de intensidades mediante la transformación `ScaleIntensityd`, que reescala todos los valores al rango unitario $[0, 1]$. Esta operación es fundamental para garantizar la coherencia en los datos de entrada, ya que cada secuencia de resonancia magnética presenta rangos y distribuciones de intensidad distintas. Además, esta etapa del preprocesado es especialmente útil en escenarios con conjuntos de datos pequeños —como el utilizado en el presente estudio—, donde se ha observado una mejora en el rendimiento de los modelos de *Deep Learning* al aplicar técnicas de normalización (Albert et al. 2023).

Aplicación de la máscara prostática: `MaskIntensityd`

Para aquellos experimentos en los que el análisis se restringe exclusivamente a la glándula prostática, se aplica la transformación `MaskIntensityd`, utilizando como referencia la segmentación de dicha región, previamente remuestreada y redimensionada

para garantizar su correspondencia espacial con las imágenes procesadas. Esta operación consiste en anular los valores de intensidad fuera de la glándula, lo que permite eliminar información irrelevante de los tejidos circundantes. Al limitar el análisis a la región anatómica de interés, se reduce el ruido en las imágenes y se favorece que los modelos aprendan patrones discriminativos específicos del tejido prostático.

Concatenación de secuencias: ConcatItemsd

Finalmente, tras completar los pasos anteriores, las tres secuencias de resonancia magnética (T2W, ADC y DWI) se combinan mediante la transformación `ConcatItemsd`, dando lugar a un único tensor multicanal con dimensiones $3 \times 128 \times 128 \times 32$, que se emplea como entrada directa para los modelos de *Deep Learning*. Este enfoque permite a los modelos procesar de forma conjunta las distintas secuencias, mejorando su capacidad predictiva al explotar la información anatómica y funcional complementaria que aportan.

Aumento de datos

Con el objetivo de aumentar la variabilidad del conjunto de entrenamiento y reducir el riesgo de sobreajuste, algunas configuraciones experimentales incluyen una fase adicional de aumento de datos, tal como se recoge en la Tabla 3.4. Esta etapa se basa en la aplicación de transformaciones aleatorias sobre las imágenes —como rotaciones, traslaciones, alteraciones de intensidad o adición de ruido— que, al introducir variaciones sintéticas, permiten simular escenarios de adquisición diversos y mejorar la capacidad del modelo para generalizar a nuevos casos.

3.3.2. Arquitecturas de los modelos entrenados

En este trabajo se han evaluado seis arquitecturas de *Deep Learning* implementadas en la librería MONAI, todas ellas compatibles con imágenes tridimensionales gracias al parámetro `spatial_dims=3`. La Tabla 3.4 recoge los modelos utilizados en cada configuración experimental. A continuación, se describe brevemente la estructura de cada modelo.

DenseNet121

DenseNet121, propuesta por Huang et al. (2018), es una red neuronal convolucional profunda de 121 capas, organizada en cuatro bloques densos conectados mediante capas de transición. Su principal característica es la conectividad densa, mediante la cual cada capa recibe como entrada la concatenación de todos los mapas de características generados por las capas anteriores, en lugar de limitarse a la salida de la capa inmediatamente anterior. Así, la capa ℓ integra la información de todas las capas desde la 0 hasta la $\ell - 1$, y aporta nuevas representaciones —reguladas por una tasa de crecimiento— que se transmiten a las siguientes. Las capas de transición, compuestas por convoluciones 1×1 y operaciones de *average pooling*, permiten reducir progresivamente la dimensionalidad de los mapas de activación y controlar el crecimiento del número de parámetros. Esta arquitectura fomenta una reutilización eficiente de las características y un flujo de gradientes más estable, lo que da lugar a modelos más compactos, menos propensos al desvanecimiento del gradiente y con una menor carga computacional que otras redes convolucionales profundas de rendimiento equivalente.

ResNet

ResNet, desarrollada por He et al. (2015), introduce el aprendizaje residual mediante conexiones de salto (*skip connections*), que permiten construir redes profundas sin comprometer la estabilidad del entrenamiento. En su variante básica —la empleada en este estudio— cada bloque está compuesto por dos capas convolucionales consecutivas: la primera va seguida de una operación de *Batch Normalization* y una activación ReLU, mientras que la segunda solo se acompaña de una normalización. A esto se añade una *skip connection* que suma directamente la entrada del bloque, x , a la salida tras la segunda convolución. La activación ReLU se aplica después de esta suma, completando la operación residual. De este modo, el bloque aprende una función $F(x)$ que se combina con la entrada original, dando lugar a una salida final de la forma $F(x) + x$. Esta estructura facilita la optimización de redes profundas y permite mejorar el rendimiento a medida que aumenta la profundidad, superando problemas como el desvanecimiento del gradiente, la dificultad de convergencia y la degradación del rendimiento observados en arquitecturas convencionales sin *skip connections*.

EfficientNet-B0

EfficientNet-B0, planteada por Tan y Le (2020), es el modelo base de la familia EfficientNet, que introdujo un enfoque de escalado compuesto (*compound scaling*) para ampliar redes convolucionales de forma equilibrada en profundidad, anchura y resolución. Esta arquitectura fue obtenida mediante búsqueda automática (*neural architecture search*), una técnica que explora de forma sistemática distintas configuraciones arquitectónicas para optimizar el rendimiento en tareas específicas. Su estructura se basa en bloques MBConv (*Mobile Inverted Bottleneck Convolution*), desarrollados por Sandler et al. (2019), a los que se integran módulos de atención Squeeze-and-Excitation (SE), introducidos por Hu et al. (2019).

EfficientNet-B7 y B8

EfficientNet-B7 y EfficientNet-B8 son variantes ampliadas de la arquitectura base EfficientNet-B0, obtenidas mediante el mismo principio de escalado compuesto. Ambas mantienen la estructura basada en bloques MBConv con atención Squeeze-and-Excitation, pero incorporan un mayor número de capas, canales y resolución de entrada.

EfficientNet-B7 representa una ampliación sustancial del modelo base, mientras que EfficientNet-B8 incrementa aún más la resolución y la anchura respecto a B7, lo que permite capturar patrones más complejos a costa de un mayor número de parámetros y mayor demanda computacional.

Vision Transformer (ViT)

El modelo Vision Transformer (ViT), propuesto por Dosovitskiy et al. (2021), adapta el esquema de codificación de los Transformers al dominio de las imágenes. Para ello, divide la imagen en pequeños parches de tamaño fijo (por ejemplo, 16×16), aplana cada parche y lo proyecta a un espacio de embeddings mediante una transformación lineal. A estos vectores se les añade una codificación posicional que preserva la información espacial, y el conjunto se introduce en un codificador Transformer estándar compuesto por capas de atención múltiple y bloques MLP con normalización y conexiones residuales.

Configuración	Modelo	Transformaciones
base-densenet	DenseNet121	-
base-resnet	ResNet	-
base-vit	ViT	-
base-efficientnet	EfficientNetBN (b0)	-
base-efficientnet-b7	EfficientNetBN (b7)	-
base-efficientnet-b8	EfficientNetBN (b8)	-
config1	DenseNet121	Flip, Rotate90, Affine, GaussianNoise
config2	ResNet	Flip, Rotate90, Affine, ScaleIntensity
config3	ViT	Flip, Affine, GaussianSmooth, ShiftIntensity
config4	EfficientNetBN (b0)	Flip, Rotate90, ScaleIntensity, GaussianSmooth
config5	EfficientNetBN (b7)	GaussianNoise, AdjustContrast, HistogramShift
config6	EfficientNetBN (b8)	BiasField, ScaleIntensity, GaussianSmooth
config7	ResNet	GaussianSmooth, ShiftIntensity, AdjustContrast
config8	DenseNet121	AdjustContrast, GaussianNoise, ScaleIntensity

Tabla 3.4: Resumen de las arquitecturas de *Deep Learning* consideradas y las transformaciones de *data augmentation* aplicadas en cada configuración experimental. Para una descripción completa de las configuraciones y sus parámetros, véase el Anexo B.

3.3.3. Entrenamiento y evaluación de los modelos

A partir del conjunto de tensores multicanal generados al final del preprocesamiento, se procede al entrenamiento y evaluación de los modelos de *Deep Learning*. Aunque se ha intentado mantener una estrategia metodológica alineada con la empleada en el análisis radiómico —utilizando las mismas métricas de evaluación y una validación cruzada estratificada por paciente—, el elevado coste computacional asociado al entrenamiento de redes profundas ha obligado a reducir el número de ejecuciones.

Entrenamiento de los modelos

El entrenamiento de los modelos se realiza siguiendo un esquema de validación cruzada estratificada por paciente con $K = 5$ particiones mediante la función *StratifiedGroupKFold* de *scikit-learn*. Cada uno de los cinco folds se entrena durante un máximo de 100 épocas, aplicando un mecanismo de *early stopping* con una paciencia de 30 épocas, que permite detener el proceso si no se observa mejora en el AUC de validación. El tamaño de lote se fija en 2 muestras y se emplea el optimizador Adam con una tasa de aprendizaje de 1×10^{-5} . Como función de pérdida se utiliza *CrossEntropyLoss*, ajustando manualmente los pesos asignados a cada clase en función de su frecuencia en el conjunto de entrenamiento, con el objetivo de mitigar el desbalanceo presente en la variable objetivo (véase Figura 3.6).

Durante el entrenamiento, se registra el modelo con mejor AUC en validación para cada fold, que posteriormente se guarda como modelo óptimo para ese split. Al finalizar el proceso completo de validación cruzada, se selecciona como modelo global el que haya obtenido el mejor AUC en cualquiera de los folds, y se almacena como modelo representativo de la configuración evaluada.

Evaluación de los modelos

El conjunto de métricas empleadas para evaluar el rendimiento de los modelos de *Deep Learning* coincide exactamente con el utilizado en el análisis radiómico (véase Sección 3.2.3). Esta decisión permite garantizar la comparabilidad entre ambos enfoques.

3.4 Comparación del rendimiento

Tras el entrenamiento de los modelos de *Machine Learning* y *Deep Learning*, se procede a una evaluación comparativa de sus rendimientos. Este análisis se basa en recomendaciones metodológicas ampliamente aceptadas para la comparación de clasificadores, como las propuestas por Demšar (2006) y Rainio et al. (2024), que aconsejan el uso de técnicas estadísticas no paramétricas cuando se comparan valores de la métrica de evaluación obtenidos en distintos subconjuntos de prueba —por ejemplo, los folds de la validación cruzada—.

La evaluación se organiza en tres niveles: (i) la comparación entre modelos dentro de cada enfoque, (ii) el análisis del impacto de la región anatómica considerada —imagen completa frente a glándula prostática—, y (iii) la comparación global entre los enfoques metodológicos de radiómica y *Deep Learning*.

3.4.1. Comparación entre modelos de radiómica

Con el objetivo de evaluar si existen diferencias significativas en el rendimiento de los clasificadores considerados en el enfoque radiómico, se ha utilizado el test de Friedman como prueba global, calculado sobre los valores del AUC en validación obtenidos en los distintos folds de la validación cruzada. Este procedimiento se alinea con las recomendaciones metodológicas previamente mencionadas, según las cuales la comparación de múltiples modelos de clasificación binaria basada en valores del AUC calculados sobre varios subconjuntos de prueba debe abordarse mediante dicho test.

Si el resultado del test de Friedman indica la existencia de diferencias significativas, se procede a identificar qué pares de modelos difieren entre sí mediante comparaciones post-hoc. Para ello, se aplica el test de Wilcoxon para muestras pareadas, junto con una corrección de Holm para controlar el error asociado a las comparaciones múltiples.

3.4.2. Comparación entre modelos de *Deep Learning*

El análisis estadístico realizado para comparar los modelos de *Deep Learning* sigue el mismo procedimiento descrito en la sección anterior. Sin embargo, debido a la menor cantidad de observaciones disponibles por modelo —resultado de emplear una validación cruzada sin repetición con cinco folds—, en este caso para las comparaciones post-hoc se incorpora además el cálculo del tamaño del efecto mediante la *d* de Cohen. Esta medida permite cuantificar la magnitud de las diferencias entre modelos en relación con la desviación típica de sus valores pareados, proporcionando una estimación independiente del tamaño muestral (Sullivan y Feinn 2012). Aun así, la escasa cantidad de datos por modelo obliga a interpretar los resultados con prudencia, dada la posible inestabilidad de las estimaciones.

Adicionalmente, ante la ya mencionada escasez de observaciones por modelo, y con el objetivo de obtener una visión complementaria al análisis basado en métricas de rendimiento, se realiza también una comparación estadística sobre las probabilidades estimadas por cada modelo, que permite identificar posibles diferencias significativas en la forma en que estos asignan probabilidades a cada clase. Con este fin, utilizando los modelos guardados durante el entrenamiento de cada fold, se generan predicciones sobre los correspondientes conjuntos de validación; a partir de las cuales se obtienen las probabilidades estimadas para cada muestra, sobre las que se aplican los mismos procedimientos estadísticos que en los análisis anteriores.

3.4.3. Impacto de la región anatómica

Con el objetivo de evaluar si restringir la información a la glándula prostática repercute en el rendimiento de los modelos, se compara, para cada configuración de *Deep Learning* y cada clasificador radiómico, el AUC en validación obtenido al utilizar la imagen completa frente al obtenido con la región prostática.

Para ello, se aplica el test de Wilcoxon para muestras pareadas, tanto en su versión bilateral —que permite detectar diferencias significativas sin asumir a priori cuál de los dos enfoques ofrece un mejor rendimiento— como en su versión unilateral, formulada con la hipótesis alternativa de que el rendimiento al emplear únicamente la glándula es superior al obtenido con la imagen completa, con el objetivo de valorar si esta restricción permite mejorar los resultados. En el caso de los modelos de *Deep Learning*, dado el reducido número de observaciones disponibles por configuración, se añade también el cálculo del tamaño del efecto mediante la *d* de Cohen sobre las diferencias pareadas del AUC. No obstante, al igual que en la comparación entre modelos de *Deep Learning*, estos valores deben interpretarse con cautela, ya que las estimaciones pueden resultar inestables en contextos con tan pocos datos.

3.4.4. Comparación entre enfoques metodológicos

Por último, se realiza una comparación entre los dos enfoques metodológicos considerados —radiómica y *Deep Learning*—, seleccionando para cada uno el modelo que ha obtenido la mejor mediana de AUC en validación. Dado que en radiómica se llevan a cabo múltiples repeticiones de la validación cruzada, mientras que en *Deep Learning* solo se ejecuta una, la comparación se restringe al primer *repeat* del enfoque radiómico, que emplea la misma semilla y, por tanto, genera las mismas particiones que se utilizan en los modelos de *Deep Learning*, lo que permite garantizar la comparabilidad directa entre los resultados de cada fold.

Una vez determinados los modelos a comparar, con el fin de aportar una primera aproximación estadística a la comparación entre enfoques, se aplica el test de Wilcoxon para muestras pareadas con dos colas sobre los cinco pares de valores de AUC obtenidos en validación —uno por fold—, con el objetivo de evaluar si existen diferencias estadísticamente significativas entre ellos. Además, dada la limitada cantidad de observaciones disponibles, se calcula el tamaño del efecto mediante la *d* de Cohen sobre las diferencias pareadas, como estimación complementaria del grado de discrepancia entre enfoques. No obstante, de nuevo, conviene ser prudente al interpretar los resultados debido al bajo número de observaciones disponibles.

De forma complementaria, y con un carácter puramente exploratorio, se incluye también una comparación entre enfoques basada en la observación de distintas métricas de evaluación —como la sensibilidad, la especificidad o el propio AUC, entre otros— con el objetivo de analizar de forma general las diferencias en el rendimiento de los modelos representativos de ambos enfoques.

3.5 Interpretabilidad de los modelos

La última etapa metodológica del presente estudio aborda la interpretabilidad de las predicciones generadas por los modelos entrenados. Este aspecto constituye un elemento clave en sistemas de apoyo al diagnóstico, ya que permite comprender qué características o regiones específicas de las imágenes influyen en las decisiones de los modelos, facilitando así su aceptación y uso en el contexto clínico.

Este análisis se aplica sobre los modelos seleccionados tras la evaluación completa de ambos enfoques. En radiómica, el análisis se realiza sobre el modelo elegido para el proceso de optimización final, mientras que en el enfoque basado en *Deep Learning* se utiliza el modelo que ha obtenido la mejor mediana del AUC.

A continuación, se detallan las técnicas específicas de XAI empleadas para realizar este análisis en cada enfoque.

Técnicas de XAI aplicadas al enfoque radiómico

Para el análisis del modelo radiómico, se emplean dos técnicas complementarias de explicabilidad, aplicadas de forma independiente sobre los conjuntos de entrenamiento y test con el fin de evaluar la consistencia de los resultados obtenidos: SHAP (*SHapley Additive exPlanations*) y LIME (*Local Interpretable Model-agnostic Explanations*).

En primer lugar, se aplica SHAP, un método basado en la teoría de juegos cooperativos que asigna a cada característica una importancia específica para cada predicción individual. La aplicación de SHAP sigue los siguientes pasos:

1. **Selección del *explainer*.** Se escoge el objeto *explainer* adecuado en función del clasificador empleado en el modelo radiómico: *TreeExplainer* para modelos basados en árboles, *LinearExplainer* para modelos lineales, o *KernelExplainer* como alternativa general.
2. **Cálculo de valores SHAP.** A partir del *explainer* seleccionado, se calculan los valores SHAP para cada instancia del conjunto de datos, obteniendo un vector que cuantifica la contribución individual de cada característica a la probabilidad asignada por el modelo a la clase positiva.
3. **Análisis estadístico entre valores SHAP y clase.** Se realiza un análisis estadístico mediante el test no paramétrico de Mann-Whitney U para comparar la distribución de los valores SHAP entre la clase positiva y la negativa para cada característica. Para mitigar el efecto de las comparaciones múltiples, se aplica la corrección de Holm.
4. **Visualización de resultados.** Finalmente, se generan diversas representaciones gráficas para facilitar la interpretación de los resultados. En primer lugar, se crea un *beeswarm plot*, que muestra la distribución de los valores SHAP por característica junto con un código de color que indica el valor original de cada variable, revelando cómo su magnitud influye en la predicción. A continuación, se emplea un *heatmap* para representar, por instancia, los valores SHAP de las características más relevantes, organizando las muestras por clase. Esto permite identificar diferencias en la contribución de dichas variables entre ambos grupos.

Como técnica complementaria y confirmatoria, se aplica LIME, que proporciona explicaciones locales y permite identificar de forma individual qué características específicas influyen en cada predicción. A partir de estas explicaciones locales generadas para cada instancia, se construye una visualización global —similar al *beeswarm plot*— en la que se aplica una normalización logarítmica intra-variable. Esta transformación permite ajustar la escala de los valores originales de cada característica, de modo que la codificación de color refleje su magnitud relativa dentro de cada variable, lo que facilita la comparación con los resultados obtenidos mediante SHAP.

Técnicas de XAI aplicadas al enfoque de Deep Learning

En el caso del modelo basado en *Deep Learning*, se han explorado distintas técnicas de interpretabilidad visual, incluyendo GradCAM, Guided Backpropagation y variantes combinadas. Sin embargo, finalmente solo se ha empleado *Occlusion Sensitivity*, al ser la única que ha ofrecido resultados clínicamente interpretables.

Esta técnica genera dos tipos de visualizaciones. Por un lado, se crean mapas individuales para cada muestra, que permiten identificar las regiones anatómicas cuya oclusión provoca un mayor descenso en la probabilidad asignada por el modelo a la clase verdadera. Esto permite interpretar, caso por caso, qué zonas han sido más relevantes en la toma de decisiones. Por otro lado, se construyen mapas agregados por clase, obtenidos como el promedio de los mapas individuales correspondientes a cada grupo, con el objetivo de identificar las regiones anatómicas que muestran una mayor sensibilidad a la oclusión de forma consistente en cada clase.

CAPÍTULO 4

Resultados

CAPÍTULO 5

Discusión

CAPÍTULO 6

Conclusiones y trabajos futuros

Conclusiones, yendo objetivo por objetivo viendo el grado de cumplimiento... Incluir en algún punto que he aprendido (quizá estructurarlo como conclusiones profesionales [buscar palabra exacta], y conclusiones personales [que he aprendido y que he utilizado del grado en el TFG])

6.1 Legado

Destacar que contribuye este proyecto y cómo los beneficiarios sacarán partido de él.

6.2 Relación del trabajo desarrollado con los estudios cursados

Realizar un ejercicio de introspección que incluya un análisis de la relación de los estudios realizados con el trabajo desarrollado por el alumno.

competencias transversales

6.3 Trabajos futuros

En este apartado se puede presentar una lista de: - Fleclos que le hubiera gustado al alumno acabar en este trabajo pero que no ha podido ser porque se acababa el tiempo disponible para la realización del TFG. - Líneas de desarrollo que se abren para aplicar estos resultados a otras áreas. - Ampliaciones o mejoras tanto de eficiencia como de funcionalidades del trabajo realizado

Cosas:

- Modelos híbridos - Relación entre las características abstractas generadas por las CNN (capas ocultas) y las características radiómicas

Bibliografía

- Ahmed, Hashim U et al. (feb. de 2017). «Diagnostic accuracy of multiparametric MRI and TRUS biopsy in prostate cancer (PROMIS): a paired validating confirmatory study». En: *The Lancet* 389.10071, págs. 815-822. ISSN: 0140-6736. DOI: 10.1016/S0140-6736(16)32401-1 (cit. en p. 2).
- Ahmed, Tashin y Noor Sabab (sep. de 2020). *Classification and Understanding of Cloud Structures via Satellite Images with EfficientUNet*. Preprint, ESSOAr. DOI: 10.1002/essoar.10507423.1. URL: <https://doi.org/10.1002/essoar.10507423.1> (cit. en p. 27).
- Albert, Steffen et al. (2023). «Comparison of Image Normalization Methods for Multi-Site Deep Learning». En: *Applied Sciences* 13.15, pág. 8923. ISSN: 2076-3417. DOI: 10.3390/app13158923 (cit. en p. 28).
- Alpert, Paul F. (2018). «New Evidence for the Benefit of Prostate-specific Antigen Screening: Data From 400,887 Kaiser Permanente Patients». En: *Urology* 118, págs. 119-126. ISSN: 0090-4295. DOI: <https://doi.org/10.1016/j.urology.2018.02.049>. URL: <https://www.sciencedirect.com/science/article/pii/S0090429518303765> (cit. en p. 1).
- Alqahtani, Saeed (nov. de 2024). «Systematic Review of AI-Assisted MRI in Prostate Cancer Diagnosis: Enhancing Accuracy Through Second Opinion Tools». En: *Diagnostics* 14.22, pág. 2576. ISSN: 2075-4418. DOI: 10.3390/diagnostics14222576. URL: <https://doi.org/10.3390/diagnostics14222576> (cit. en p. 4).
- Boesen, Lars (feb. de 2017). «Multiparametric MRI in detection and staging of prostate cancer». En: *Danish Medical Journal* 64.2, B5327. ISSN: 2245-1919 (cit. en p. 2).
- Bray, F. et al. (mayo de 2024). «Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries». En: *CA: A Cancer Journal for Clinicians* 74.3, págs. 229-263. DOI: 10.3322/caac.21834 (cit. en p. 1).
- Cai, Jason C. et al. (2024). «Fully Automated Deep Learning Model to Detect Clinically Significant Prostate Cancer at MRI». En: *Radiology* 312.2, e232635. DOI: 10.1148/radiol.232635. eprint: <https://doi.org/10.1148/radiol.232635>. URL: <https://doi.org/10.1148/radiol.232635> (cit. en p. 3).
- Cardoso, M. Jorge et al. (2022). *MONAI: An Open-Source Framework for Deep Learning in Healthcare*. arXiv: 2211.02701 [cs.LG]. URL: <https://arxiv.org/abs/2211.02701> (cit. en p. 27).
- Dall'Era, Marc A. et al. (2012). «Active Surveillance for Prostate Cancer: A Systematic Review of the Literature». En: *European Urology* 62.6, págs. 976-983. ISSN: 0302-2838.

- DOI: <https://doi.org/10.1016/j.eururo.2012.05.072>. URL: <https://www.sciencedirect.com/science/article/pii/S0302283812006914> (cit. en p. 1).
- Demircioğlu, Aydin (sep. de 2022). «The Effect of Preprocessing Filters on Predictive Performance in Radiomics». En: *European Radiology Experimental* 6.1, pág. 40. ISSN: 2509-9280. DOI: 10.1186/s41747-022-00294-w. URL: <https://doi.org/10.1186/s41747-022-00294-w> (cit. en p. 20).
- Demirel, Hüseyin Cihan y John Warren Davis (mar. de 2018). «Multiparametric magnetic resonance imaging: Overview of the technique, clinical applications in prostate biopsy and future directions». En: *Turkish Journal of Urology* 44.2, págs. 93-102. ISSN: 2149-3235. DOI: 10.5152/tud.2018.56056. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5832385/> (cit. en p. 2).
- Demšar, Janez (2006). «Statistical Comparisons of Classifiers over Multiple Data Sets». En: *Journal of Machine Learning Research* 7.1, págs. 1-30. URL: <http://jmlr.org/papers/v7/demsar06a.html> (cit. en p. 32).
- Dosovitskiy, Alexey et al. (2021). *An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale*. arXiv: 2010.11929 [cs.CV]. URL: <https://arxiv.org/abs/2010.11929> (cit. en pp. 27, 30).
- Griethuysen, J. J. M. van et al. (2017). «Computational Radiomics System to Decode the Radiographic Phenotype». En: *Cancer Research* 77.21, e104-e107. DOI: 10.1158/0008-5472.CAN-17-0339. URL: <https://doi.org/10.1158/0008-5472.CAN-17-0339> (cit. en p. 18).
- He, Kaiming et al. (2015). *Deep Residual Learning for Image Recognition*. arXiv: 1512.03385 [cs.CV]. URL: <https://arxiv.org/abs/1512.03385> (cit. en p. 30).
- Holzinger, Andreas et al. (2017). *What do we need to build explainable AI systems for the medical domain?* arXiv: 1712.09923 [cs.AI]. URL: <https://arxiv.org/abs/1712.09923> (cit. en p. 3).
- Hu, Jie et al. (2019). *Squeeze-and-Excitation Networks*. arXiv: 1709.01507 [cs.CV]. URL: <https://arxiv.org/abs/1709.01507> (cit. en p. 30).
- Huang, Gao et al. (2018). *Densely Connected Convolutional Networks*. arXiv: 1608.06993 [cs.CV]. URL: <https://arxiv.org/abs/1608.06993> (cit. en pp. 27, 29).
- Insight Toolkit (2023). *itk::AnisotropicDiffusionFunction — ITK 5.3.0 Doxygen Documentation*. Consultado el 04 de mayo de 2025. URL: https://docs.itk.org/projects/doxygen/en/v5.3.0/classitk_1_1AnisotropicDiffusionFunction.html (cit. en p. 16).
- Insight Toolkit (2025). *itk::CurvatureNDAnisotropicDiffusionFunction — ITK Doxygen Documentation*. Consultado el 04 de mayo de 2025. URL: https://docs.itk.org/projects/doxygen/en/stable/classitk_1_1CurvatureNDAnisotropicDiffusionFunction.html (cit. en p. 16).
- Insightful TScript (s.f.). *ResNet - Understanding the Revolutionary Neural Network Architecture for Deep Learning*. Consultado el 18 de mayo de 2025. URL: <https://insightfultscript.com/collections/programming/neural-network/resnet/> (cit. en p. 27).

- Juntu, Jaber et al. (2005). «Bias Field Correction for MRI Images». En: *Computer Recognition Systems*. Ed. por Marek Kurzyński et al. Berlin, Heidelberg: Springer Berlin Heidelberg, págs. 543-551. ISBN: 978-3-540-32390-7. DOI: 10.1007/3-540-32390-2_64 (cit. en p. 15).
- Li, Qing et al. (2014). «Medical image classification with convolutional neural network». En: *2014 13th International Conference on Control Automation Robotics & Vision (ICARCV)*, págs. 844-848. DOI: 10.1109/ICARCV.2014.7064414 (cit. en p. 3).
- Lomas, D. J. y D. J. Ahmed (jun. de 2020). «All change in the prostate cancer diagnostic pathway». En: *Nature Reviews Clinical Oncology*. DOI: 10.1038/s41571-020-0332-z. URL: <https://doi.org/10.1038/s41571-020-0332-z> (cit. en p. 1).
- Matoso, A. y J. I. Epstein (ene. de 2019). «Defining clinically significant prostate cancer on the basis of pathological findings». En: *Histopathology* 74.1, págs. 135-145. DOI: 10.1111/his.13712 (cit. en p. 1).
- Mayerhoefer, Marius E et al. (2020). «Introduction to radiomics». En: *Journal of Nuclear Medicine* 61.4, págs. 488-495 (cit. en p. 3).
- Meijering, Erik (2002). «A Chronology of Interpolation: From Ancient Astronomy to Modern Signal and Image Processing». En: *Proceedings of the IEEE* 90.3, págs. 319-342. DOI: 10.1109/5.993400 (cit. en p. 19).
- Merriel, Samuel W. D. et al. (feb. de 2022). «Systematic review and meta-analysis of the diagnostic accuracy of prostate-specific antigen (PSA) for the detection of prostate cancer in symptomatic patients». En: *BMC Medicine* 20.1, pág. 54. DOI: 10.1186/s12916-021-02230-y. URL: <https://doi.org/10.1186/s12916-021-02230-y> (cit. en p. 1).
- Naji, Leen et al. (2018). «Digital Rectal Examination for Prostate Cancer Screening in Primary Care: A Systematic Review and Meta-Analysis». En: *The Annals of Family Medicine* 16.2, págs. 149-154. DOI: 10.1370/afm.2205. eprint: <https://www.annfammed.org/content/16/2/149.full.pdf>. URL: <https://www.annfammed.org/content/16/2/149> (cit. en p. 2).
- Niculescu-Mizil, Alexandru y Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». En: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*. ICML '05. Bonn, Germany: Association for Computing Machinery, págs. 625-632. ISBN: 1595931805. DOI: 10.1145/1102351.1102430. URL: <https://doi.org/10.1145/1102351.1102430> (cit. en p. 26).
- Nieto-Morales, M.L. et al. (2014). «El esquema de biopsia transrectal puede predecir la gradación histológica incorrecta del cáncer de próstata». En: *Radiología* 56.4, págs. 322-327. ISSN: 0033-8338. DOI: 10.1016/j.rx.2012.05.009. URL: <https://www.elsevier.es/es-revista-radiologia-119-articulo-el-esquema-biopsia-transrectal-puede-S003383381200183X> (cit. en p. 2).
- Patil, Malini (sep. de 2018). «Interpolation Techniques in Image Resampling». En: *International Journal of Engineering and Technology* 7, págs. 567-570. DOI: 10.14419/ijet.v7i3.34.19383 (cit. en p. 28).
- Rainio, Oona et al. (2024). «Evaluation Metrics and Statistical Tests for Machine Learning». En: *Scientific Reports* 14.1, pág. 6086. DOI: 10.1038/s41598-024-56706-x. URL: <https://doi.org/10.1038/s41598-024-56706-x> (cit. en p. 32).

- Saha, A. et al. (jul. de 2024). «Artificial intelligence and radiologists in prostate cancer detection on MRI (PI-CAI): an international, paired, non-inferiority, confirmatory study». En: *The Lancet Oncology* 25.7, págs. 879-887. DOI: 10.1016/S1470-2045(24)00220-1. URL: [https://doi.org/10.1016/S1470-2045\(24\)00220-1](https://doi.org/10.1016/S1470-2045(24)00220-1) (cit. en p. 9).
- Saha, Anindo et al. (2022). *Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge (Study Protocol)*. DOI: 10.5281/zenodo.6667655. URL: <https://doi.org/10.5281/zenodo.6667655> (cit. en p. 10).
- Sandler, Mark et al. (2019). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. arXiv: 1801.04381 [cs.CV]. URL: <https://arxiv.org/abs/1801.04381> (cit. en p. 30).
- Santinha, João et al. (mar. de 2025). «ESR Essentials: Radiomics—Practice Recommendations by the European Society of Medical Imaging Informatics». En: *European Radiology* 35.3, págs. 1122-1132. DOI: 10.1007/s00330-024-11093-9 (cit. en pp. 14, 19, 20).
- Schoots, Ivo G (feb. de 2018). «MRI in early prostate cancer detection: how to manage indeterminate or equivocal PI-RADS 3 lesions?» En: *Translational Andrology and Urology* 7.1, págs. 70-82. ISSN: 2223-4691. DOI: 10.21037/tau.2017.12.31. URL: <https://doi.org/10.21037/tau.2017.12.31> (cit. en p. 2).
- Stamoulou, Elisavet et al. (nov. de 2022). «Harmonization Strategies in Multicenter MRI-Based Radiomics». En: *Journal of Imaging* 8.11, pág. 303. DOI: 10.3390/jimaging8110303 (cit. en p. 15).
- Stec, Nadia et al. (abr. de 2018). «A Systematic Review of Fatigue in Radiology: Is It a Problem?» En: *AJR. American Journal of Roentgenology* 210.4, págs. 799-806. ISSN: 1546-3141. DOI: 10.2214/AJR.17.18613. URL: <https://doi.org/10.2214/AJR.17.18613> (cit. en p. 2).
- Sullivan, Gail M y Richard Feinn (2012). «Using effect size—or why the P value is not enough». En: *Journal of graduate medical education* 4.3, págs. 279-282. DOI: 10.4300/JGME-D-12-00156.1 (cit. en p. 32).
- Tan, Mingxing y Quoc V. Le (2020). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. arXiv: 1905.11946 [cs.LG]. URL: <https://arxiv.org/abs/1905.11946> (cit. en p. 30).
- Tixier, Florent et al. (2011). «Intratumor Heterogeneity Characterized by Textural Features on Baseline ¹⁸F-FDG PET Images Predicts Response to Concomitant Radiochemotherapy in Esophageal Cancer». En: *Journal of Nuclear Medicine* 52.3, págs. 369-378. ISSN: 0161-5505. DOI: 10.2967/jnumed.110.082404. eprint: <https://jnm.snmjournals.org/content/52/3/369.full.pdf>. URL: <https://jnm.snmjournals.org/content/52/3/369> (cit. en p. 19).
- Whybra, Philip et al. (2024). «The Image Biomarker Standardization Initiative: Standardized Convolutional Filters for Reproducible Radiomics and Enhanced Clinical Insights». En: *Radiology* 310.2, e231319. DOI: 10.1148/radiol.231319. eprint: <https://doi.org/10.1148/radiol.231319>. URL: <https://doi.org/10.1148/radiol.231319> (cit. en p. 20).
- Woźnicki, Piotr et al. (jul. de 2020). «Multiparametric MRI for Prostate Cancer Characterization: Combined Use of Radiomics Model with PI-RADS and Clinical Parameters».

En: *Cancers* 12.7, pág. 1767. ISSN: 2072-6694. DOI: 10.3390/cancers12071767. URL: <https://doi.org/10.3390/cancers12071767> (cit. en p. 3).

Wu, Jia et al. (2019). «Hyperparameter Optimization for Machine Learning Models Based on Bayesian Optimization». En: *Journal of Electronic Science and Technology* 17.1, págs. 26-40. ISSN: 1674-862X. DOI: 10.11989/JEST.1674-862X.80904120. URL: <https://www.sciencedirect.com/science/article/pii/S1674862X19300047> (cit. en p. 25).

Zwanenburg, Alex et al. (2016). «Image Biomarker Standardisation Initiative: Feature Definitions». En: *arXiv preprint abs/1612.07003*. arXiv: 1612.07003. URL: <http://arxiv.org/abs/1612.07003> (cit. en pp. 18, 21).

APÉNDICE A

Glosario de acrónimos

- AUC** *Area Under the ROC Curve.* 3
- CNN** *Convolutional Neural Networks.* 3
- csPCa** *Clinically Significant Prostate Cancer.* 1, 4
- DCE** *Dynamic Contrast-Enhanced Imaging.* 2
- DL** *Deep Learning.* 3, 5
- DWI** *Diffusion-weighted imaging.* 2
- IA** *Inteligencia Artificial.* 3, 4
- ML** *Machine Learning.* 3
- PCa** *Prostate Cancer.* 1
- PSA** *Prostate Specific Antigen.* 1–3
- RMmp** *Resonancia Magnética Multiparamétrica.* 2–5
- T2W** *T2 weighted image.* 2
- TRUS** *Transrectal Ultrasound guided prostate biopsy.* 1, 2
- XAI** *Explainable Artificial Intelligence.* 5

APÉNDICE B

Configuraciones experimentales en *Deep Learning*

Este anexo recoge los detalles completos de cada una de las configuraciones empleadas en el entrenamiento de modelos de *Deep Learning*, incluyendo la arquitectura utilizada y las transformaciones de aumento de datos aplicadas, junto con sus parámetros específicos.

base-densenet

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2

base-resnet

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]

base-vit

Modelo	ViT
Parámetros del modelo	spatial_dims=3, in_channels=3, img_size=[128,128,32], patch_size=[16,16,8], classification=True, num_classes=2

base-efficientnet

Modelo	EfficientNetBN (b0)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b0

base-efficientnet-b7

Modelo	EfficientNetBN (b7)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b7

base-efficientnet-b8

Modelo	EfficientNetBN (b8)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b8

config1

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2
Transformación	Parámetros
RandFlipd	prob=0.2, spatial_axis=0
RandRotate90d	prob=0.2
RandAffined	prob=0.2, rotate_range=[0.1, 0.1, 0.1], translate_range=[0.1, 0.1, 0.1]
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1

config2

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]
Transformación	Parámetros
RandFlipd	prob=0.4, spatial_axis=1
RandRotate90d	prob=0.4
RandAffined	prob=0.2, rotate_range=[0.05, 0.05, 0.05], translate_range=[0.05, 0.05, 0.05]
RandScaleIntensityd	prob=0.3, factors=0.1

config3

Modelo	ViT
Parámetros del modelo	spatial_dims=3, in_channels=3, img_size=[128,128,32], patch_size=[16,16,8], classification=True, num_classes=2
Transformación	Parámetros
RandFlipd	prob=0.4, spatial_axis=2
RandAffined	prob=0.3, rotate_range=[0.1, 0.1, 0.1], translate_range=[0.1, 0.1, 0.1]
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]
RandShiftIntensityd	prob=0.2, offsets=[-0.05, 0.05]

config4

Modelo	EfficientNetBN (b0)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b0
Transformación	Parámetros
RandFlipd	prob=0.3, spatial_axis=0
RandRotate90d	prob=0.3
RandScaleIntensityd	prob=0.3, factors=0.1
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]

config5

Modelo	EfficientNetBN (b7)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b7
Transformación	Parámetros
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1
RandAdjustContrastd	prob=0.3, gamma=[0.7,1.5]
RandHistogramShiftd	prob=0.3, num_control_points=5

config6

Modelo	EfficientNetBN (b8)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b8
Transformación	Parámetros
RandBiasFieldd	prob=0.3, coeff_range=[0.0, 0.5]
RandScaleIntensityd	prob=0.3, factors=0.1
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]

config7

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]
Transformación	Parámetros
RandGaussianSmoothd	prob=0.3, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]
RandShiftIntensityd	prob=0.3, offsets=[-0.1, 0.1]
RandAdjustContrastd	prob=0.3, gamma=[0.8,1.2]

config8

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2
Transformación	Parámetros
RandAdjustContrastd	prob=0.4, gamma=[0.5,1.5]
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1
RandScaleIntensityd	prob=0.3, factors=0.1

APÉNDICE C

Objetivos de Desarrollo Sostenible

Grado de relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS)

En 2015, la Organización de las Naciones Unidas aprobó la Agenda 2030 para el Desarrollo Sostenible, un marco global compuesto por 17 Objetivos de Desarrollo Sostenible (ODS) que buscan hacer frente a retos como la pobreza, la desigualdad y el cambio climático. La Universitat Politècnica de València (UPV), en su compromiso con estos objetivos, promueve su incorporación en la investigación y la formación académica. En este contexto, la memoria del Trabajo Fin de Grado representa una oportunidad para analizar la relación del trabajo realizado con los ODS.

A continuación, se presenta una tabla que relaciona este trabajo con los ODS, indicando el grado de contribución en cada caso:

Objetivos de Desarrollo Sostenible	Alto	Medio	Bajo	No procede
ODS 1. Fin de la pobreza.				X
ODS 2. Hambre cero.				X
ODS 3. Salud y bienestar.	X			
ODS 4. Educación de calidad.				X
ODS 5. Igualdad de género.				X
ODS 6. Agua limpia y saneamiento.				X
ODS 7. Energía asequible y no contaminante.				X
ODS 8. Trabajo decente y crecimiento económico.				X
ODS 9. Industria, innovación e infraestructuras.		X		
ODS 10. Reducción de las desigualdades.			X	
ODS 11. Ciudades y comunidades sostenibles.				X
ODS 12. Producción y consumo responsables.				X
ODS 13. Acción por el clima.				X
ODS 14. Vida submarina.				X
ODS 15. Vida de ecosistemas terrestres.				X
ODS 16. Paz, justicia e instituciones sólidas.				X
ODS 17. Alianzas para lograr objetivos.		X		

Tabla C.1: Grado de relación del trabajo con los ODS

Reflexión sobre la relación del TFG con los ODS

Empieza a escribir aquí tu reflexión. Aproximadamente entre 500 y 1500 palabras. Se espera que puedas relacionar tu TFG con alguno (o varios) ODS. En el caso de no poder relacionarse, deberás explicar por qué no es posible hacerlo y/o identificar aquellos ODS que en menor grado podrían tener alguna relación con el trabajo. Recuerda borrar toda esta frase.

ODS 3: Salud y bienestar → Este trabajo tiene un impacto directo en la mejora de la salud y el bienestar al desarrollar herramientas para la clasificación de la severidad del cáncer de próstata. La optimización de modelos radiómicos y de Deep Learning puede contribuir a diagnósticos más precisos y a una mejor toma de decisiones clínicas, favoreciendo el acceso a tecnologías avanzadas en el ámbito de la salud.

ODS 9: Industria, innovación e infraestructuras → La aplicación de inteligencia artificial en el análisis de imágenes médicas representa un avance en innovación tecnológica dentro del sector sanitario.

ODS 17: Alianzas para lograr los objetivos → La integración de modelos de IA en el ámbito clínico requiere colaboración entre investigadores, profesionales médicos y desarrolladores de tecnología. Este trabajo fomenta la cooperación interdisciplinaria para mejorar la eficacia de los sistemas de diagnóstico.

ODS 10: Reducción de las desigualdades → Aunque el trabajo no aborda directamente la reducción de desigualdades, el desarrollo de herramientas accesibles y explicables en el ámbito de la salud podría facilitar el acceso a diagnósticos avanzados en distintos entornos médicos.