



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Análisis radiómico de imágenes de resonancia magnética para la clasificación de la severidad del cáncer de próstata

TRABAJO FIN DE GRADO

Grado en Ciencia de Datos

Autor: Jose Valero Sanchis

Tutor: Elies Fuster i Garcia

Cotutora externa: Mariam de la Iglesia Vayá

Director experimental: Jesús Alzate Grisales

Curso 2024-2025

Resum

????

Paraules clau: ????, ?????????, ????, ?????????????????

Resumen

????

Palabras clave: ?????, ???, ?????????????????

Abstract

????

Key words: ?????, ????? ?????, ?????????????????

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VII

1	Introducción	1
1.1	Motivación	4
1.2	Objetivos	5
1.3	Impacto esperado	5
1.4	Estructura de la memoria	6
2	Marco teórico	7
2.1	Conceptos fundamentales	7
2.2	Estado del arte	16
3	Metodología	21
3.1	Comprensión de los datos	21
3.2	Análisis radiómico	26
3.3	<i>Deep Learning</i>	39
3.4	Comparación del rendimiento	44
3.5	Interpretabilidad de los modelos	45
4	Resultados	49
4.1	Resultados del análisis radiómico	49
4.2	Resultados del enfoque de <i>Deep Learning</i>	56
4.3	Comparación entre enfoques	61
4.4	Resultados del análisis de interpretabilidad	62
5	Discusión	63
6	Conclusiones y trabajos futuros	65
6.1	Legado	65
6.2	Relación del trabajo desarrollado con los estudios cursados	65
6.3	Trabajos futuros	65

Apéndices		
A	Glosario de acrónimos	77
B	Configuraciones experimentales en <i>Deep Learning</i>	79
C	Objetivos de Desarrollo Sostenible	83

Índice de figuras

2.1	Esquema simplificado de las etapas de la resonancia magnética.	8
2.2	Visualización de una misma lesión en diferentes secuencias.	10
2.3	Esquema de una red neuronal convolucional aplicada a imágenes médicas	13
3.1	Resumen del enfoque metodológico propuesto	21
3.2	Distribución del tamaño de imagen por secuencia de resonancia magnética	23
3.3	Distribución del espaciado de imagen por secuencia	24
3.4	Ejemplo de segmentación en imagen T2W	25
3.5	Distribución de casos en función del grado ISUP	25
3.6	Distribución de casos según la presencia o ausencia de csPCa	26
3.7	Resumen del enfoque metodológico propuesto en el análisis radiómico . .	27
3.8	Efecto de la corrección del campo de sesgo en imágenes T2W	28
3.9	Efecto del suavizado por difusión anisotrópica en imágenes DWI	29
3.10	Ejemplo de segmentación en imagen DWI	30
3.11	Ejemplo de aplicación de filtros en una imagen T2W	33
3.12	Resumen del enfoque metodológico propuesto en el análisis con DL . . .	39
4.1	Curvas ROC (fold óptimo y mediano) de modelos radiómicos	51
4.2	Distribución del AUC en validación por clasificador radiómico.	52
4.3	Matriz de confusión del modelo sin calibrar	54
4.4	Curvas de calibración antes y después del ajuste	55
4.5	Distribución del AUC de validación por modelo de <i>Deep Learning</i>	58
4.6	Comparación entre configuraciones de DL mediante tamaños del efecto .	58
4.7	Distribución de probabilidades predichas por modelo de <i>Deep Learning</i> . .	59
4.8	Comparación de las probabilidades predichas entre configuraciones de DL	60

Índice de tablas

3.1	Configuración de PyRadiomics por modalidad	32
3.2	Ejemplo de salida del proceso de selección de variables	36
3.3	Espacio de búsqueda de hiperparámetros definido para cada modelo. . . .	38
3.4	Resumen de los modelos utilizados en <i>Deep Learning</i>	43
4.1	Comparación del rendimiento mediano con y sin selección de variables . .	49
4.2	Distribución de las variables seleccionadas por secuencia, filtro y familia .	50
4.3	AUC mediano en modelos radiómicos según la región de entrada	51
4.4	Comparación de clasificadores radiómicos según AUC (Wilcoxon-Holm) .	52
4.5	Métricas de evaluación medianas para los distintos clasificadores radiómicos	53

4.6	Comparación de métricas antes y después del ajuste completo	56
4.7	AUC en modelos de <i>Deep Learning</i> según la región de entrada	57
4.8	Métricas de evaluación medianas para las distintas configuraciones de DL	61
C.1	Grado de relación del trabajo con los ODS	83

CAPÍTULO 1

Introducción

El cáncer de próstata (PCa, por sus siglas en inglés) es uno de los tumores más prevalentes y representa un desafío significativo para la salud masculina a nivel mundial. Según las estadísticas de Global Cancer Statistics (Bray et al. 2024), en 2022 se diagnosticaron aproximadamente 1.4 millones de nuevos casos en hombres, posicionándolo como el segundo cáncer más frecuente entre esta población. En términos de mortalidad, ocupó el quinto lugar con casi 400 000 muertes, consolidándose como una de las principales causas de fallecimiento relacionadas con el cáncer en hombres.

Estos casos presentan una evolución clínica muy diversa, formando un amplio espectro que abarca desde tumores «clínicamente insignificantes» (o indolentes), de crecimiento lento y una baja probabilidad de progresión o de causar complicaciones graves durante la vida del paciente, hasta los cánceres de próstata «clínicamente significativos» (csPCa, por sus siglas en inglés) con un comportamiento agresivo, capaces de progresar rápidamente, provocar metástasis y con un mayor riesgo de mortalidad (Matoso y J. I. Epstein 2019).

Debido a esta variabilidad en las consecuencias clínicas, distinguir entre estos tipos de cáncer de próstata es crucial para guiar las decisiones terapéuticas y evitar intervenciones innecesarias. Tradicionalmente, los métodos de cribado y diagnóstico han incluido el análisis sanguíneo del antígeno prostático específico (PSA, por sus siglas en inglés), el tacto rectal y la biopsia de próstata guiada por ecografía transrectal (TRUS, por sus siglas en inglés) (Lomas y D. J. Ahmed 2020).

El cribado mediante la determinación del PSA se adoptó de forma generalizada en la década de 1990 y se le atribuye un descenso de más del 50 % en la mortalidad por cáncer de próstata (Alpert 2018, Lomas y D. J. Ahmed 2020). Sin embargo, su falta de especificidad frecuentemente conduce a falsos positivos y a la detección de tumores indolentes que nunca habrían causado daños (Merriel et al. 2022). Este sobrediagnóstico conlleva frecuentemente el sobretratamiento, es decir, intervenciones médicas innecesarias como cirugía o radioterapia, que pueden producir efectos adversos significativos, tales como incontinencia urinaria o disfunción eréctil (Matoso y J. I. Epstein 2019). Frente a tumores indolentes, estos tratamientos podrían evitarse en favor de métodos menos invasivos como la vigilancia activa, que implica un seguimiento clínico regular mediante análisis del PSA, exámenes clínicos periódicos y repetición selectiva de biopsias, con el objetivo de detectar tempranamente signos de progresión sin exponer al paciente a los efectos adversos asociados a tratamientos más agresivos (Dall’Era et al. 2012).

Más allá del PSA, otros procedimientos convencionales como el tacto rectal presentan también importantes limitaciones. Aunque se realiza de manera rutinaria, el tacto rectal tiene una sensibilidad (51 %) y especificidad (59 %) limitadas, lo que implica que muchos tumores no sean detectados y que frecuentemente se sospechen tumores en pacientes que

realmente no los tienen (Naji et al. 2018). Cuando existe sospecha de cáncer, el método estándar para confirmarlo es la biopsia de próstata guiada por ecografía transrectal (TRUS), que obtiene muestras del tejido prostático. Aunque son esenciales, las biopsias de próstata presentan limitaciones significativas. Un estudio indicó que la biopsia tuvo una alta sensibilidad (98 %) y una baja especificidad (49 %) para tumores indolentes, mientras que presentó una baja sensibilidad (26 %) y una alta especificidad (99 %) para tumores clínicamente significativos (Nieto-Morales et al. 2014). Esto implica que las biopsias pueden no detectar algunos tumores agresivos y, al mismo tiempo, identificar como cánceres casos que podrían no requerir tratamiento inmediato. Además, las biopsias son procedimientos invasivos que conllevan riesgos como hemorragias, dolor e infecciones, incluida la sepsis (H. U. Ahmed et al. 2017).

Estos desafíos —la limitada especificidad del análisis del PSA, la sensibilidad y especificidad insuficientes del tacto rectal y las biopsias, junto con su naturaleza invasiva y riesgo de efectos adversos— han impulsado la búsqueda de herramientas diagnósticas más fiables y menos invasivas, entre las que destaca la resonancia magnética multiparamétrica (RMmp). En la última década, la RMmp ha revolucionado el diagnóstico del cáncer de próstata al combinar imágenes anatómicas ponderadas en T2 (T2W) con secuencias funcionales como la imagen ponderada por difusión (DWI), que mide la restricción en el movimiento del agua, y la imagen dinámica con contraste intravenoso (DCE), que evalúa la perfusión, estructura vascular y permeabilidad, generando así información precisa sobre la anatomía y las características biológicas del tejido prostático (Demirel y Davis 2018).

Diversos estudios, como los realizados por H. U. Ahmed et al. (2017) y Boesen (2017), han demostrado que la RMmp mejora notablemente la detección del cáncer de próstata clínicamente significativo en comparación con la biopsia sistemática a ciegas, técnica en la que se obtienen múltiples muestras prostáticas de forma aleatoria, sin la guía específica proporcionada por imágenes diagnósticas. Por ejemplo, el ensayo PROMIS —un estudio prospectivo de validación de cohortes emparejadas realizado por H. U. Ahmed et al. (2017), que cumple los criterios del nivel 1 de evidencia en la evaluación de pruebas diagnósticas— informó que el uso de la RMmp como prueba de cribado antes de la biopsia incrementó la sensibilidad para detectar cáncer significativo al 93 % (en comparación con el 48 % de la biopsia mediante TRUS). Como resultado, el uso de la RMmp como prueba de cribado inicial podría permitir que aproximadamente el 27 % de los pacientes evite una primera biopsia y que se diagnosticaran un 5 % menos de cánceres clínicamente insignificantes. Además, si las biopsias mediante TRUS posteriores se dirigiesen según los hallazgos de la RMmp, podrían detectarse hasta un 18 % más de casos de cáncer clínicamente significativo en comparación con la estrategia convencional de biopsia sistemática mediante TRUS para todos los pacientes. Por tanto, las estrategias basadas en RMmp antes de la primera biopsia prostática reducirían en aproximadamente una cuarta parte las biopsias innecesarias, mitigando así el sobrediagnóstico de cánceres clínicamente insignificantes y mejorando simultáneamente la detección de tumores agresivos.

Sin embargo, la RMmp no está exenta de limitaciones. Entre ellas destacan las barreras económicas y logísticas que dificultan el acceso generalizado a equipos de RMmp de alta calidad, limitando así su adopción en la práctica clínica (Schoots 2018). Además, la interpretación de los resultados de la RMmp es compleja y requiere una gran experiencia por parte de los radiólogos para evaluar correctamente las imágenes, determinar con precisión la agresividad tumoral y seleccionar las estrategias terapéuticas más apropiadas. Esta tarea puede complicarse aún más debido a factores humanos como la fatiga o la sobrecarga cognitiva, que reducen la precisión diagnóstica y aumentan la probabilidad de falsos positivos o negativos (Stec et al. 2018). Estos errores pueden provocar tratamientos

innecesarios o retrasar intervenciones oportunas, afectando negativamente los resultados clínicos del paciente.

Para hacer frente a estas limitaciones y complementar la interpretación clínica tradicional, han surgido técnicas computacionales avanzadas basadas en Inteligencia Artificial (IA), que incluyen, por un lado, la combinación de radiómica y *Machine Learning* (ML), y por otro, el *Deep Learning* (DL). Ambas estrategias permiten potenciar el diagnóstico del cáncer de próstata mediante la extracción y el análisis de la abundante información contenida en las imágenes de RMmp.

La radiómica consiste en la extracción automatizada de características cuantitativas —denominadas características radiómicas— a partir de imágenes médicas, convirtiendo estas imágenes en datos medibles. En lugar de depender únicamente de la evaluación subjetiva del radiólogo, el análisis radiómico calcula cientos o incluso miles de descriptores que caracterizan la forma, la intensidad y la textura de las lesiones (Mayerhoefer et al. 2020). En una etapa posterior, se emplean algoritmos de *Machine Learning* para identificar patrones en estas características radiómicas. Por su parte, el *Deep Learning* emplea redes neuronales con múltiples capas para extraer automáticamente información relevante a partir de las imágenes y generar predicciones clínicas basadas en ella. En imagen médica, las Redes Neuronales Convolucionales (CNN, por sus siglas en inglés) son la arquitectura más común, capaces de generar un diagnóstico directamente desde los píxeles de la imagen (Li et al. 2014). A diferencia de la radiómica, que se basa en características obtenidas «manualmente», las CNN aprenden automáticamente sus propias representaciones abstractas, optimizadas en este caso para predecir el grado de agresividad tumoral.

En la última década, numerosos estudios han demostrado la eficacia de la radiómica y del DL para mejorar la detección del cáncer de próstata en imágenes de RMmp. Los modelos basados en características radiómicas han mostrado un rendimiento notable a la hora de distinguir cánceres agresivos. Por ejemplo, en un estudio realizado por Woźnicki et al. (2020) se utilizó un conjunto de características cuantitativas obtenidas a partir de imágenes de RMmp, combinado con datos clínicos como la densidad del PSA, para clasificar las lesiones prostáticas. Este modelo logró un área bajo la curva ROC (AUC, por sus siglas en inglés) de 0.889 para la detección de cáncer de próstata y de 0.844 para la distinción entre cáncer clínicamente significativo y clínicamente insignificante. En comparación, la evaluación visual basada en criterios convencionales obtuvo un AUC de 0.779 para la detección de cáncer y de 0.688 para la clasificación de csPCa.

A su vez, los enfoques basados en *Deep Learning* también han demostrado resultados prometedores. Las CNN, entrenadas con imágenes de RMmp, han alcanzado un rendimiento comparable al de radiólogos en la detección de tumores. Por ejemplo, en un estudio reciente realizado por Cai et al. (2024), un modelo de DL mostró un rendimiento comparable al de radiólogos expertos en la detección de cáncer de próstata clínicamente significativo mediante RMmp. En el conjunto de prueba interno —compuesto por exploraciones del mismo centro utilizado para entrenar el modelo—, ambos alcanzaron un AUC de 0.89, mientras que en el conjunto de prueba externo —procedente de un centro distinto— el modelo obtuvo un AUC de 0.86 frente a 0.84 de los radiólogos, sin diferencias estadísticamente significativas.

Pese a estos prometedores resultados, la adopción de modelos de *Machine Learning* o *Deep Learning* en diagnóstico médico requiere más que simple precisión. La interpretabilidad se ha convertido en un requisito fundamental, especialmente en aplicaciones clínicas donde comprender el razonamiento detrás de cada predicción es tan crucial como la precisión misma (Holzinger et al. 2017). Los modelos predictivos deben ser capaces no solo de ofrecer resultados precisos, sino de explicar de manera transparente cómo se

ha llegado a una conclusión diagnóstica, permitiendo a los profesionales médicos validar, confiar y, si es necesario, cuestionar la decisión propuesta.

Precisamente por esta necesidad de transparencia, es importante señalar que estas herramientas no pretenden reemplazar a los radiólogos, sino actuar como dispositivos de asistencia para apoyar la toma de decisiones clínicas. En un futuro, un sistema de IA podría desempeñar el papel de un «segundo lector», proporcionando una segunda opinión inmediata sobre las exploraciones por RMmp (Alqahtani 2024). Esto podría ayudar a detectar cánceres que podrían pasar desapercibidos para el ojo humano —reduciendo así los errores diagnósticos—. Al automatizar aspectos rutinarios del análisis de imágenes, la IA puede reducir la carga de trabajo del radiólogo, permitiéndole centrarse en los casos más complejos.

En última instancia, la integración de la radiómica y el *Deep Learning* en el diagnóstico del cáncer de próstata persigue mejorar los resultados clínicos: detectar antes los tumores clínicamente significativos, diferenciar con mayor precisión entre enfermedad agresiva e indolente, y evitar procedimientos innecesarios a los pacientes. Con una validación y perfeccionamiento continuos —especialmente en el desarrollo de modelos más transparentes y explicables—, la IA tiene el potencial de transformar el diagnóstico del cáncer de próstata, haciéndolo más preciso, consistente y personalizado. Esto no solo reforzará la confianza del radiólogo en su interpretación, sino que también se traducirá en decisiones terapéuticas mejor adaptadas a cada paciente y en una mejora de la supervivencia y la calidad de vida a largo plazo.

Para facilitar la comprensión del contenido, los acrónimos empleados a lo largo del documento —como csPCa o RMmp—, junto con otros términos técnicos y médicos, se recogen y definen en el glosario de acrónimos (Apéndice A).

1.1 Motivación

La motivación de este trabajo responde a la necesidad de desarrollar herramientas más precisas y explicables que puedan asistir en la identificación del cáncer de próstata mediante técnicas avanzadas de Inteligencia Artificial. En concreto, este proyecto busca desarrollar y comparar sistemas de apoyo al diagnóstico basados en radiómica y en técnicas de *Deep Learning*, evaluando no solo su capacidad para diferenciar entre tumores clínicamente significativos y tumores indolentes, sino también el grado en que los resultados pueden ser interpretados por los radiólogos. Al analizar y comparar distintos métodos diagnósticos se espera que esta investigación permita identificar fortalezas y limitaciones de cada enfoque en relación con su capacidad diagnóstica e interpretabilidad clínica.

Desde una perspectiva puramente personal, este Trabajo de Fin de Grado representa una oportunidad para contribuir a la mejora de la calidad de vida de las personas mediante la aplicación de la ciencia de datos y la IA en medicina, un área que siempre me ha resultado especialmente atractiva. Fue precisamente esta motivación la que hizo que me matriculara en la asignatura *Biomedical Data Science*. Aunque antes de cursarla ya tenía claro que quería orientar mi Trabajo de Fin de Grado hacia este campo, esta asignatura no hizo más que reforzar mi convicción, ya que me permitió comprender con mayor profundidad el potencial de las técnicas de Inteligencia Artificial aplicadas a la salud para mejorar el diagnóstico y tratamiento de enfermedades. Además, considero que este TFG constituye un primer paso fundamental hacia una futura carrera profesional en Inteligencia Artificial aplicada a la salud, permitiéndome adquirir experiencia práctica y profundizar en un ámbito científico con gran potencial para generar beneficios importantes para pacientes y profesionales sanitarios.

1.2 Objetivos

El objetivo principal de este trabajo es comparar el análisis radiómico con técnicas de *Deep Learning* en la clasificación de la severidad del cáncer de próstata a partir de imágenes de resonancia magnética multiparamétrica (RMmp), evaluando su rendimiento y explicabilidad.

Para alcanzar este objetivo, se proponen los siguientes objetivos específicos, que detallan las acciones necesarias para su desarrollo:

- Extraer características radiómicas de las imágenes de RMmp.
- Entrenar modelos de *Machine Learning* utilizando las características radiómicas extraídas.
- Entrenar modelos de *Deep Learning* directamente a partir de las imágenes originales de RMmp.
- Comparar el rendimiento de los modelos de análisis radiómico y DL en la detección de cáncer de próstata clínicamente significativo.
- Evaluar la interpretabilidad de los modelos empleados mediante técnicas de *Explainable Artificial Intelligence* (XAI).

1.3 Impacto esperado

Los resultados de este trabajo podrían tener un impacto relevante en distintos perfiles de usuarios, tanto en el ámbito clínico como en el investigador.

Para los profesionales sanitarios, especialmente los radiólogos, se espera que estas herramientas actúen como sistemas de apoyo al diagnóstico, proporcionando una segunda opinión que complemente la interpretación visual de las imágenes. Esto podría facilitar la detección de tumores clínicamente significativos que podrían pasar desapercibidos en la lectura convencional, al tiempo que reduciría la carga de trabajo derivada del análisis manual. La incorporación de técnicas de XAI permitiría, además, generar explicaciones comprensibles de las predicciones realizadas por los modelos, lo que contribuiría a aumentar la confianza en su uso y facilitar su integración progresiva en la práctica clínica.

Desde la perspectiva del paciente, una mejora en la precisión del diagnóstico puede tener implicaciones relevantes para su salud y calidad de vida. Una mejor diferenciación entre tumores agresivos e indolentes permitiría evitar tanto el sobretratamiento innecesario —con sus efectos adversos asociados— como el infradiagnóstico de lesiones que requieren intervención. De este modo, se favorecería una atención médica más personalizada, basada en el riesgo real, con decisiones terapéuticas más ajustadas a las características individuales de cada caso.

Por último, en el ámbito científico, este trabajo puede aportar valor al comparar enfoques basados en radiómica y en *Deep Learning*, permitiendo identificar fortalezas y limitaciones de cada estrategia en términos de rendimiento y explicabilidad. Además, la identificación de las características radiómicas más relevantes para la clasificación de la severidad tumoral puede aportar evidencia sobre posibles marcadores de agresividad, lo que podría servir de base para mejorar los enfoques actuales en diagnóstico por imagen y orientar futuras investigaciones centradas en la caracterización del cáncer de próstata.

1.4 Estructura de la memoria

Esta memoria se estructura en varios capítulos. A continuación, se presenta un resumen de su contenido (IR REVISANDO):

- **Capítulo 1: Introducción.** Se expone el contexto y la motivación del trabajo, justificando la importancia de aplicar técnicas de Inteligencia Artificial, en particular el análisis radiómico y el *Deep Learning*, en la clasificación del cáncer de próstata. Se presentan los objetivos principales y específicos, así como el impacto esperado del estudio.
- **Capítulo 2: Marco teórico.** Se introducen los fundamentos teóricos necesarios para comprender el trabajo, seguido de una revisión crítica del estado del arte que identifica sus principales limitaciones y justifica la contribución del presente estudio.
- **Capítulo 3: Metodología.** Se presenta el enfoque metodológico seguido, comenzando por la descripción y análisis del conjunto de datos. A continuación, se desarrollan los dos enfoques considerados: análisis radiómico y *Deep Learning*. Finalmente, se expone la estrategia de comparación entre modelos y las técnicas de interpretabilidad aplicadas.

Además, la memoria incluye los siguientes anexos:

- **Apéndice A. Glosario.**
- **Apéndice B. Configuraciones experimentales en *Deep Learning***
- **Apéndice C. Objetivos de Desarrollo Sostenible (ODS).**

CAPÍTULO 2

Marco teórico

2.1 Conceptos fundamentales

2.1.1. Cáncer de próstata

El cáncer de próstata es un tumor maligno que se origina en la glándula prostática, y que suele desarrollarse a partir de las células que recubren internamente dicha glándula, conocidas como células epiteliales prostáticas (Oh et al. 2003, NCI 2025). Cuando estas células se malignizan, forman lo que se denomina un adenocarcinoma (término que significa «cáncer que se desarrolla en el tejido glandular» (NCI 2025)).

Una de las características más relevantes de esta enfermedad es su marcada heterogeneidad, ya que el riesgo asociado al tumor varía considerablemente entre pacientes. Mientras algunos tumores presentan un comportamiento indolente —de crecimiento lento y baja agresividad—, otros exhiben un comportamiento clínicamente significativo, con capacidad para diseminarse, generar metástasis y provocar mortalidad si no se tratan adecuadamente (Matoso y J. I. Epstein 2019).

Esta necesidad de distinguir entre perfiles de riesgo ha motivado el desarrollo de sistemas de clasificación histopatológica como la puntuación de Gleason —propuesta por Gleason y Mellinger (1974)—, más tarde revisada por la *International Society of Urological Pathology* (ISUP), que en 2014 introdujo una nueva clasificación conocida como «grupos de grado de la ISUP» (Srigley et al. 2016). Ambos sistemas se basan en el patrón general de crecimiento tumoral observado al microscopio, es decir, en la disposición de las glándulas tumorales respecto a la arquitectura típica de la próstata sana.

A partir de estos sistemas se ha establecido uno de los criterios más extendidos para definir el cáncer de próstata clínicamente significativo, que considera como tal cualquier tumor con una puntuación de Gleason igual o superior a 7, es decir, perteneciente al grupo de grado ISUP 2 o superior (Jonathan I. Epstein et al. 2005). Esta es también la definición adoptada por la base de datos utilizada en este trabajo.

2.1.2. Fundamentos de resonancia magnética

La resonancia magnética multiparamétrica (RMmp) se basa en la combinación de múltiples secuencias de resonancia magnética que incluyen tanto imágenes anatómicas de alta resolución como técnicas funcionales —estas últimas destinadas a aportar información sobre aspectos fisiológicos o moleculares del tejido—. Esta combinación permite lograr una caracterización más precisa de los tejidos que la que se obtendría con cada secuencia por separado (Demirel y Davis 2018).

Visión general de la RMmp en el cáncer de próstata

En el contexto del cáncer de próstata, un protocolo estándar de RMmp incluye la secuencia anatómica ponderada en T2 (T2W) y la secuencia funcional de difusión (DWI), junto con sus mapas derivados como el coeficiente de difusión aparente (ADC). Estas secuencias constituyen la base del proceso diagnóstico en la práctica clínica (Ghai y Haider 2015) y serán las utilizadas en el presente trabajo, describiéndose brevemente en la Sección 2.1.2. La secuencia de realce dinámico con contraste (DCE), aunque forma parte de los protocolos completos de RMmp, no ha sido incluida en este estudio por no estar disponible en la base de datos utilizada y porque su uso se reserva habitualmente como herramienta confirmatoria adicional (Turkbey et al. 2019).

Resonancia magnética: principios básicos

El cuerpo humano contiene una gran cantidad de átomos de hidrógeno —especialmente en el agua y la grasa— cuyos núcleos están formados por un único protón con carga eléctrica positiva. Estos protones están en constante rotación, lo que genera pequeños campos magnéticos individuales. En condiciones normales, es decir, en ausencia de un campo magnético externo, la orientación de estos campos es completamente aleatoria (tal y como se representa de forma esquemática en la Figura 2.11). Sin embargo, en presencia del campo magnético del escáner de resonancia magnética, los protones ya no se orientan de forma aleatoria, sino que tienden a alinearse en dos direcciones posibles respecto a dicho campo (Figura 2.12): la mayoría lo hace en la misma dirección (estado de baja energía), mientras que una menor proporción se orienta en sentido opuesto (estado de alta energía), representados en la figura con un borde amarillo. A continuación, se aplica un pulso breve de radiofrecuencia que desvía los protones que se encuentran en el estado de baja energía, provocando que cambien temporalmente a un estado de mayor energía y se desalineen del campo magnético principal (Figura 2.13). Cuando el pulso se interrumpe, estos protones inician un proceso de relajación y regresan gradualmente a su estado original, liberando energía en forma de señales de radio, denominadas señales de resonancia magnética (Figura 2.14) (Pai et al. 2023, Mustafa A. Mafraji 2023).




Figura 2.1: Esquema visual simplificado de las principales etapas de la resonancia magnética. Elaboración propia inspirada en una ilustración de Broadhouse (2019)

Secuencias clave en la RMmp de próstata

Imágenes ponderadas en T2 (T2W)

Las imágenes T2W proporcionan una representación anatómica detallada de la próstata, basada en las diferencias en el comportamiento de los tejidos ante la relajación T_2 (Elmaoğlu y Çelik 2012). En este tipo de secuencias, los tejidos con mayor contenido en agua se visualizan como regiones brillantes, mientras que las estructuras más densas o compactas se muestran como zonas más oscuras (Mustafa A. Mafraji 2023).

La próstata normal, especialmente en su zona periférica —la región donde se origina la mayoría de los cánceres (McNeal et al. 1988)—, se muestra típicamente como una estructura hiperintensa debido a su organización glandular y alto contenido en agua. En cambio, el tejido tumoral tiende a ser más compacto y pobre en agua, por lo que se presenta como una zona hipointensa (Patel y Oto 2016). Por este motivo, la presencia de áreas focales oscuras en la zona periférica se considera un hallazgo sugestivo de malignidad (véase Figura 2.2a).

Imágenes ponderadas por difusión (DWI)

Las imágenes DWI permiten evaluar el movimiento aleatorio de las moléculas de agua dentro de los tejidos, conocido como movimiento browniano (Baliyan et al. 2016). En este tipo de secuencias, los tejidos con mayor libertad de difusión del agua —como las zonas poco celulares— se visualizan como áreas oscuras, mientras que las regiones donde dicha difusión está limitada —como los tejidos densos o altamente celulares— aparecen brillantes (Kele y Jagt 2010).

En el cáncer de próstata, las lesiones suelen presentar una elevada densidad celular que limita el desplazamiento del agua, lo que hace que se manifiesten como áreas hiperintensas frente al tejido prostático sano (Patel y Oto 2016), tal y como se muestra a modo de ejemplo en la Figura 2.2b.

Coeficiente de difusión aparente (ADC)

Las imágenes ADC ofrecen una representación cuantitativa, derivada de las imágenes DWI, que refleja el grado de difusión del agua en cada región del tejido (Herneth et al. 2003). A diferencia de las secuencias T2W y DWI, que proporcionan intensidades de señal relativas que pueden variar según los parámetros de adquisición, las imágenes ADC ofrecen mediciones absolutas, independientes del equipo utilizado (Koh y Collins 2007).

En estos mapas, las áreas de alta difusión aparecen brillantes, mientras que las zonas de difusión restringida se muestran oscuras, generando un patrón inverso al de las imágenes DWI (Koh y Collins 2007). De esta forma, las lesiones prostáticas —caracterizadas por una limitada movilidad del agua— se manifiestan como focos hipointensos frente al tejido sano circundante (Patel y Oto 2016), tal y como se ilustra en la Figura 2.2c.

2.1.3. Radiómica

Concepto de la radiómica

La radiómica, técnica introducida por Lambin et al. (2012), se define como «la extracción de alto rendimiento de grandes cantidades de características a partir de imágenes radiográficas». El origen del término refleja una analogía con disciplinas como la genómica y otras ómicas: todas ellas comparten la premisa de que el análisis simultáneo de un gran número de variables permite caracterizar fenómenos complejos (Rizzo et al. 2018).




Figura 2.2: Visualización de una lesión clínicamente significativa (ISUP 5), marcada con un *bounding box* rojo, en las tres secuencias utilizadas en este estudio.

Esta disciplina concibe las imágenes médicas no solo como representaciones visuales, sino como conjuntos de datos complejos, bajo una premisa fundamental: que estas contienen información fenotípica relevante —a menudo imperceptible al ojo humano— en forma de patrones de textura, forma o intensidad. Esta hipótesis se completa con la suposición de que estos patrones pueden correlacionarse con propiedades biológicas del tumor y con el pronóstico del paciente (Lambin et al. 2012).

La radiómica, como se detallará en la Sección 2.2, ha demostrado un notable potencial para resolver problemas clínicos de diversa índole, incluyendo la detección de tumores, la evaluación de su agresividad y la estadificación previa al tratamiento (Cuocolo et al. 2019). Sin embargo, su integración en la práctica médica presenta un obstáculo importante: la reproducibilidad de las características extraídas, ya que muchas de ellas son sensibles a variaciones en los parámetros de adquisición y en los equipos utilizados (Zwanenburg, Vallières et al. 2020). Para afrontar esta problemática, iniciativas internacionales como la *Image Biomarker Standardisation Initiative* (Zwanenburg, Leger et al. 2016) han desarrollado protocolos y directrices con el objetivo de estandarizar y homogeneizar todo el flujo de trabajo radiómico.

Etapas del flujo de trabajo en radiómica

Según la guía metodológica propuesta por Timmeren et al. (2020) —similar a otras aproximaciones recogidas en la literatura—, el proceso radiómico se organiza en una serie de etapas que permiten transformar una imagen médica en un conjunto de descriptores cuantitativos sobre los que construir modelos predictivos:

1. **Segmentación de la región de interés.** Consiste en delimitar la región anatómica de la que se extraerán las características. Aunque existen herramientas automáticas, en el contexto oncológico la segmentación se suele realizar de forma manual o semi-automática, debido a la heterogeneidad morfológica de los tumores y la dificultad para establecer contornos precisos.
2. **Preprocesamiento de la imagen.** Se aplican transformaciones para reducir la variabilidad inducida por el proceso de adquisición, como la interpolación, la normalización de intensidades, la cuantización de niveles de gris o la corrección de artefactos. Este paso es esencial para asegurar la estabilidad de las características extraídas, ya que su reproducibilidad depende en gran medida del preprocesamiento aplicado (Wichtmann et al. 2023).

3. **Extracción de características.** A partir de la región segmentada —previamente preprocesada— se calculan centenares de descriptores que miden aspectos como la forma, la distribución de intensidades y la textura del tejido. El resultado es un vector de características que representa cuantitativamente la imagen.
4. **Selección y reducción de características.** Dado el alto número de variables generadas, para reducir la dimensionalidad, se aplican técnicas estadísticas y de aprendizaje automático, entre las que se incluyen: análisis univariantes (t-test, Mann–Whitney U); métodos de reducción de dimensionalidad como el análisis de componentes principales (PCA); y técnicas de selección de características como *LASSO* o *recursive feature elimination*.
5. **Modelado y validación.** Las características seleccionadas se utilizan para entrenar modelos de *Machine Learning*, como regresión logística, *Support Vector Machine* o *Random Forest*. Su rendimiento se evalúa mediante validación cruzada o con cohortes externas independientes, con el objetivo de estimar su capacidad de generalización y prevenir el sobreajuste.

Tipos de características radiómicas

Las características radiómicas cuantifican distintos aspectos de las imágenes médicas y suelen agruparse en cuatro grandes categorías: morfológicas, de primer orden, de segundo orden y de orden superior. Esta clasificación, propuesta por Rizzo et al. (2018), aparece también —con ligeras variaciones— en otros trabajos de referencia, como el realizado por Gillies et al. (2016), y está ampliamente aceptada en la literatura.

Cada una de las categorías de esta clasificación se describe brevemente a continuación; los detalles formales y matemáticos pueden consultarse en la guía de la *Image Biomarker Standardisation Initiative* (Zwanenburg, Leger et al. 2016).

- **Características morfológicas.** Describen las propiedades geométricas de la región segmentada, como el volumen, la superficie, el diámetro máximo o la esfericidad. Se calculan a partir de la máscara binaria de la lesión, sin tener en cuenta los valores de intensidad.
- **Características de primer orden.** Capturan la distribución de los valores de intensidad dentro de la región segmentada, sin tener en cuenta la disposición espacial de los vóxeles. Derivadas del histograma de intensidades, estas características incluyen medidas como la media, la mediana, los valores máximo y mínimo, la desviación estándar, la asimetría, la curtosis o la entropía.
- **Características de segundo orden.** Evalúan las relaciones estadísticas entre vóxeles vecinos y permiten cuantificar la heterogeneidad intralesional. Se obtienen mediante distintas matrices estadísticas como la GLCM, GLRLM, GLSZM, NGTDM o GLDM, que capturan aspectos diversos de la distribución espacial de intensidades. Un ejemplo de este tipo de característica es *Coarseness*, derivada de la NGTDM, que mide la variación promedio entre un vóxel central y sus vecinos, lo que permite identificar la presencia de bordes bien definidos.
- **Características de orden superior.** Se obtienen tras aplicar filtros o transformaciones matemáticas a la imagen original, como transformadas wavelet o filtros *Laplacian of Gaussian*. Estas técnicas permiten resaltar elementos estructurales como bordes, texturas o zonas homogéneas, facilitando la identificación de patrones que pueden pasar desapercibidos en la imagen original.

2.1.4. *Deep Learning*

Concepto de *Deep Learning*

El *Deep Learning* es una subdisciplina del *Machine Learning* que se basa en el uso de redes neuronales artificiales con múltiples capas, capaces de aprender representaciones jerárquicas de los datos a distintos niveles de abstracción. A diferencia de los métodos clásicos de *Machine Learning*, que dependen del diseño «manual» de características —como ocurre en el enfoque radiómico—, el *Deep Learning* permite extraer directamente, a partir de los datos originales, representaciones útiles para la tarea a resolver, sin necesidad de definir previamente los atributos de entrada (LeCun, Bengio et al. 2015).

En el ámbito de la imagen médica, el *Deep Learning* —y especialmente las redes neuronales convolucionales— se ha convertido en una de las metodologías más utilizadas y eficaces para abordar tareas como la clasificación o segmentación de imágenes. Su aplicación ha dado lugar a avances significativos y, en muchos casos, a resultados que representan el estado del arte en dichas tareas dentro del análisis computacional de imágenes médicas (Litjens et al. 2017, Zhang y Qie 2023).

Modelos de *Deep Learning*

Redes neuronales convolucionales (CNNs)

Las redes neuronales convolucionales (*Convolutional Neural Networks*, CNNs), introducidas por LeCun, Boser et al. (1989) y descritas en detalle por Goodfellow et al. (2016), constituyen la arquitectura base de la mayoría de modelos de *Deep Learning* aplicados a imágenes médicas. Su arquitectura típica, esquematizada en la Figura 2.3, combina distintos tipos de capas, cada una con una función específica en el proceso de extracción y procesamiento de la información contenida en las imágenes:

- **Capas convolucionales.** Representan el componente fundamental en la arquitectura de una CNN, ya que permiten detectar patrones espaciales como bordes, texturas o formas. Para ello, cada capa realiza una operación de convolución entre la imagen (o mapa de características de entrada) y un conjunto de filtros entrenables (*kernels*), generando como salida un nuevo mapa de activaciones.
Tras esta operación, se aplica una función de activación no lineal, como ReLU, que permite a la red capturar patrones más complejos que los que pueden obtenerse mediante transformaciones lineales.
- **Capas de agrupamiento (*pooling*).** Se intercalan con las capas convolucionales para reducir progresivamente la resolución espacial de los mapas de características. Esto se logra agrupando regiones locales —por ejemplo, de 2×2 píxeles— mediante operaciones como el máximo (*max pooling*) o la media (*average pooling*). Esta reducción mejora la eficiencia computacional y contribuye a mitigar el sobreajuste.
- **Capas completamente conectadas.** Tras varias capas convolucionales y de *pooling* —que permiten capturar progresivamente patrones cada vez más complejos—, los mapas de características generados por la última capa se aplanan en un vector unidimensional, que se transmite a través de una o más capas densas (*fully connected*). Estas capas combinan la información contenida en dicho vector para calcular la salida final del modelo, normalmente un vector de probabilidades obtenido tras aplicar una función de activación como *softmax* o *sigmoide*.




Figura 2.3: Esquema de una red neuronal convolucional aplicada a imágenes médicas. Imagen extraída de Grisales (2024).

Vision Transformers (ViTs)

En los últimos años, los *Vision Transformers* (Dosovitskiy et al. 2021) han surgido como una alternativa prometedora a las CNNs en el análisis de imágenes. A diferencia de las redes convolucionales, los ViTs prescinden de las operaciones de convolución y recurren a mecanismos de *self-attention*, originalmente propuestos en el marco del procesamiento del lenguaje natural a través de arquitecturas *Transformer*.

Diversos estudios han explorado la aplicación de los ViTs en imagen médica, mostrando resultados competitivos en tareas como clasificación o segmentación, especialmente cuando se dispone de suficientes datos y recursos computacionales (Shamshad et al. 2023). No obstante, las CNNs siguen siendo el enfoque predominante en la mayoría de estudios, debido a su eficiencia computacional y buen rendimiento con datos limitados.

2.1.5. Métricas de evaluación en clasificación de imágenes médicas

La evaluación de los modelos constituye un aspecto esencial en cualquier tarea de clasificación, particularmente en el ámbito médico, debido a las implicaciones clínicas que tienen los resultados obtenidos. La literatura propone diversas métricas para evaluar el rendimiento de los modelos, cada una de las cuales aporta información complementaria sobre su capacidad discriminativa. Entre las métricas más relevantes destacan:

- **Sensibilidad y especificidad.** La sensibilidad, también denominada tasa de verdaderos positivos (*True Positive Rate*, TPR) o *recall*, cuantifica la proporción de casos positivos correctamente identificados por el modelo. Por su parte, la especificidad, o tasa de verdaderos negativos (*True Negative Rate*, TNR), mide la proporción de casos negativos correctamente clasificados (Tharwat 2021).

$$\text{Sensibilidad (TPR)} = \frac{TP}{TP + FN} = \frac{TP}{P}, \quad \text{Especificidad (TNR)} = \frac{TN}{TN + FP} = \frac{TN}{N}$$

Estas métricas son especialmente relevantes en el ámbito médico, dado que evalúan tanto la capacidad del modelo para detectar casos positivos (por ejemplo, csPCa) como para identificar correctamente los casos negativos (ausencia de csPCa).

- **Valores predictivos positivo y negativo (PPV y NPV).** El PPV, también denominado precisión en problemas de clasificación binaria, representa la proporción de predicciones positivas que son verdaderamente positivas. Por su parte, el NPV indica la proporción de predicciones negativas que son realmente negativas.

$$\text{PPV} = \frac{TP}{TP + FP}, \quad \text{NPV} = \frac{TN}{TN + FN}$$

Estas métricas también resultan particularmente útiles en contextos clínicos, ya que permiten estimar la fiabilidad de las predicciones. No obstante, su valor puede verse afectado por el desbalanceo de clases, aspecto que debe tenerse en cuenta al interpretarlas (Tharwat 2021).

- ***F1-score macro***. El *F1-score macro* se define como la media aritmética de los *F1-scores* calculados individualmente para cada clase, siendo por ello más adecuado que el *F1-score* tradicional en contextos con clases desbalanceadas (Tharwat 2021). En el caso de la clasificación binaria, se expresa de la siguiente manera:

$$F1\text{-score}_{\text{macro}} = \frac{1}{2} (F1_{\text{positiva}} + F1_{\text{negativa}})$$

donde el *F1-score* de cada clase se calcula como:

$$F1_{\text{clase}} = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

- ***Balanced Accuracy***. Se calcula como la media aritmética entre la sensibilidad y la especificidad (Tharwat 2021):

$$\text{Balanced Accuracy} = \frac{1}{2} (\text{Sensibilidad} + \text{Especificidad})$$

A diferencia del *accuracy* convencional, que en contextos desbalanceados tiende a favorecer la clase mayoritaria, esta métrica no se ve afectada por la distribución desigual entre grupos, resultando más apropiada para evaluar el rendimiento en este tipo de escenarios.

- **Área bajo la curva ROC (AUC)**. La curva ROC representa gráficamente la sensibilidad frente a la tasa de falsos positivos ($1 - \text{especificidad}$) en función del umbral de decisión aplicado. El área bajo esta curva (AUC) resume la capacidad discriminativa del modelo en un único valor numérico, oscilando entre 0.5 (modelo aleatorio) y 1 (clasificador perfecto). Esta métrica es ampliamente utilizada en estudios médicos por su robustez (Hajian-Tilaki 2013).

$$\text{AUC-ROC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(x)) dx$$

donde:

- *TPR* es la tasa de verdaderos positivos.
- *FPR* es la tasa de falsos positivos.

2.1.6. Interpretabilidad de modelos

En el ámbito clínico, la adopción de modelos de Inteligencia Artificial exige no solo precisión, sino también interpretabilidad —entendida como la capacidad de identificar los factores que influyen en las predicciones de los modelos—. Esta necesidad ha impulsado el desarrollo de técnicas de *eXplainable Artificial Intelligence* (XAI), que transforman los algoritmos de «caja negra» en sistemas transparentes cuyas predicciones pueden ser comprendidas y validadas por los profesionales sanitarios. En esta sección se describen las estrategias de interpretabilidad aplicadas en el presente estudio.

Técnicas de explicabilidad en modelos de radiómica

SHAP (SHapley Additive exPlanations)

SHAP es una técnica de referencia para la interpretabilidad de modelos de *Machine Learning*, propuesta por Lundberg y Lee (2017) y descrita en detalle por Molnar (2020). Su fundamento se basa en la teoría de juegos cooperativos, en particular en los valores de Shapley, un método matemático ideado para distribuir de forma justa la recompensa generada por una coalición de jugadores. En el contexto del *Machine Learning*, cada característica del modelo se considera un «jugador» que contribuye a obtener una «recompensa» —la predicción del modelo para una instancia específica—. El objetivo de SHAP es cuantificar la contribución marginal de cada característica a dicha predicción, comparando el resultado obtenido con y sin su presencia en todas las combinaciones posibles del resto de características.

Desde un punto de vista formal, el valor de Shapley para una característica se define como el promedio ponderado de su contribución marginal a lo largo de todas las posibles coaliciones en las que puede participar. En cada coalición, se simula el efecto de añadir dicha característica y se mide cuánto varía la predicción del modelo. La media de todos estos cambios, ponderada por el número de posibles permutaciones, constituye el valor de Shapley asignado a esa característica.

En la práctica, debido al crecimiento exponencial del número de coaliciones con el número de variables, SHAP implementa métodos aproximados de estimación, entre los que se incluyen: *TreeSHAP*, optimizado para modelos basados en árboles; *LinearSHAP*, para modelos lineales; y *KernelSHAP*, un método agnóstico que actúa como alternativa general cuando no se dispone de un explicador específico.

Una vez obtenidos, los valores de Shapley permiten realizar interpretaciones locales —describiendo cómo cada variable ha influido en una predicción concreta— y globales —identificando, mediante agregación, qué variables son más relevantes a lo largo de todo el conjunto de datos.

LIME (Local Interpretable Model-Agnostic Explanations)

LIME, propuesto por Ribeiro et al. (2016) y también detallado por Molnar (2020), es un método de interpretabilidad que genera explicaciones locales para predicciones individuales independientemente del tipo de modelo subyacente, lo que lo convierte en una técnica agnóstica respecto al modelo utilizado.

La idea central de LIME consiste en aproximar el comportamiento del modelo en la vecindad de una instancia específica. Para ello, se generan múltiples variaciones de dicha instancia mediante pequeñas perturbaciones en sus características, creando un nuevo conjunto de datos sintéticos sobre el que se entrena un modelo interpretable. Este modelo explicativo —habitualmente una regresión lineal con regularización tipo Lasso o un árbol de decisión de baja profundidad— se ajusta ponderando cada muestra según su proximidad a la instancia de interés. Una vez ajustado, este modelo local simplificado sirve como una aproximación interpretable del comportamiento del modelo complejo en la vecindad de la instancia analizada, permitiendo identificar qué variables han sido las más determinantes en la predicción de la instancia original.

En este método, el número de variables utilizadas por el modelo interpretable representa un parámetro fundamental: cuanto menor sea el número de variables, mayor será la interpretabilidad del modelo local, pero menor su capacidad de aproximar con precisión al modelo original; mientras que valores más altos pueden mejorar la capacidad de aproximación al modelo original, a costa de generar explicaciones más complejas.

Técnicas de explicabilidad en modelos de *Deep Learning*

En el caso del *Deep Learning*, aunque se han explorado diversas técnicas de interpretabilidad visual —como *Grad-CAM* o *Guided Backpropagation*—, únicamente *Occlusion Sensitivity* ha proporcionado explicaciones satisfactorias.

Esta técnica, propuesta por Zeiler y Fergus (2013), permite identificar las regiones de una imagen que resultan más relevantes en la toma de decisiones del modelo. Su funcionamiento consiste en ocultar pequeñas porciones de la imagen de entrada —habitualmente mediante un parche neutro deslizante— y registrar cómo varía la probabilidad asignada por el modelo a la clase de interés. Cuando la ocultación de una región concreta provoca una caída significativa en la confianza del modelo, se infiere que dicha zona contiene información crítica para la decisión. Al repetir este procedimiento sobre toda la imagen, se obtiene un mapa de sensibilidad (*saliency map*) que representa visualmente la contribución relativa de cada área al resultado final.

En el contexto médico, esta técnica permite verificar si el modelo basa sus predicciones en regiones de la imagen que realmente contienen la alteración patológica, lo que contribuye a validar su comportamiento y aumentar la confianza en sus resultados.

2.2 Estado del arte

Esta sección revisa los principales métodos, resultados y conclusiones publicados en estudios que abordan el análisis del cáncer de próstata mediante imágenes de resonancia magnética multiparamétrica. Se describen, en primer lugar, los métodos basados en radiómica, seguidos de los enfoques fundamentados en *Deep Learning*, y, por último, se revisan estudios que comparan ambas estrategias (Sección 2.2.1). Posteriormente, se examinan las principales limitaciones identificadas en la literatura (Sección 2.2.2) y, finalmente, se presenta la contribución de este trabajo como forma de abordar parte de dichas carencias (Sección 2.2.3).

2.2.1. Revisión del estado del arte

Enfoques basados en radiómica

Aunque aún son limitados, los estudios que aplican radiómica sobre imágenes de resonancia magnética multiparamétrica para clasificar la severidad del cáncer de próstata han mostrado resultados prometedores. A continuación, se revisan los trabajos más destacados, comenzando por aquellos centrados exclusivamente en la construcción de modelos predictivos, y continuando con estudios que profundizan en el análisis de las características más relevantes.

Entre los trabajos que aplican modelos radiómicos a nivel global, destaca el estudio de Woźnicki et al. (2020), quienes desarrollaron modelos a partir de características extraídas tanto de la lesión principal como de la glándula prostática completa, utilizando secuencias T2W y mapas ADC. El modelo combinaba predictores radiómicos con variables clínicas y la puntuación PI-RADS asignada por radiólogos. Este enfoque logró un AUC de 0.844 en la clasificación entre cáncer clínicamente significativo e indolente, mejorando la precisión respecto a métricas tradicionales como el valor medio del coeficiente de difusión aparente ($AUC = 0.571$, $p = 0.022$). Además, el análisis por subgrupos reveló que el modelo fue particularmente efectivo en lesiones voluminosas, con un AUC de 0.873, significativamente superior a la evaluación radiológica mediante PI-RADS ($AUC = 0.619$, $p = 0.03$), y mostró un mejor rendimiento en la zona periférica que en la de transición.

En una línea similar, Chen et al. (2019) evaluaron modelos radiómicos contruidos con características extraídas de imágenes T2W, ADC y su combinación, comparándolos directamente con las puntuaciones PI-RADS v2. Sus modelos, basados en regresión logística, alcanzaron AUCs de hasta 0.999 para distinguir tejido canceroso de tejido sano, y de hasta 0.93 para predecir la agresividad tumoral, superando en ambos casos el rendimiento de la evaluación radiológica estándar.

Por su parte, Fehr et al. (2015) propusieron un enfoque automatizado basado en características texturales extraídas de secuencias T2W y mapas ADC, al que incorporaron técnicas de aumento de datos para mitigar el desbalance de clases. Los autores compararon tres estrategias de clasificación: test t seguido de SVM, *AdaBoost* y *recursive feature elimination* con SVM, siendo esta última la más eficaz. El estudio se realizó sobre una cohorte de 147 pacientes y empleó validación cruzada estratificada con 10 particiones y 100 repeticiones. El modelo radiómico superó claramente a los clasificadores basados únicamente en el valor medio del ADC, elevando la precisión en la discriminación entre cáncer indolente y clínicamente significativo del 58 % al 90 %.

En cuanto a los estudios centrados en el análisis detallado de características, Vignati et al. (2015) evaluaron parámetros derivados de la matriz de coocurrencia de nivel gris (GLCM), concretamente *contrast* y *homogeneity*, extraídos de imágenes T2W y ADC. Estos atributos mostraron un mayor poder discriminativo que las métricas convencionales del ADC en la diferenciación entre cáncer indolente y significativo, con AUCs de hasta 0.962 para *homogeneity* y 0.945 para *contrast*, frente a un máximo de 0.854 alcanzado por los mejores parámetros convencionales.

Wibmer et al. (2015) también realizaron un análisis de textura mediante GLCM sobre imágenes T2W y mapas ADC en una cohorte de 147 pacientes. Los autores constataron que, en las secuencias T2W y ADC, los tumores situados en la zona periférica presentaron valores significativamente más altos de entropía e inercia, y menores de energía, correlación y homogeneidad ($p < 0.0001$ a 0.008). Además, los tumores clínicamente significativos mostraron mayor entropía ($p = 0.0069$) y menor energía ($p = 0.0039$) en los mapas ADC.

Finalmente, Chaddad et al. (2018) analizaron 41 características radiómicas extraídas de regiones tumorales en imágenes T2W y ADC correspondientes a 99 pacientes. Los autores identificaron tres variables derivadas de la matriz de tamaño de zona de nivel gris (GLSZM) —*zone size percentage*, *large zone size emphasis* y *zone size non-uniformity*— que mostraron diferencias significativas entre grupos de Gleason ($p < 0.05$) y correlaciones moderadas con dicha puntuación (valores de 0.42, -0.35 y 0.32 respectivamente; $p_{\text{corregido}} < 0.05$). Además, los investigadores descubrieron que las variables relacionadas con la entropía, cuyos valores más altos se vinculan con una mayor heterogeneidad tumoral, resultaron especialmente relevantes para la detección de tumores agresivos, mientras que las mencionadas anteriormente se asociaron con lesiones de bajo grado.

Enfoques basados en *Deep Learning*

Los estudios que aplican *Deep Learning* para clasificar la severidad del cáncer de próstata mediante imágenes de resonancia magnética multiparamétrica son, en comparación con la literatura centrada en radiómica, más numerosos, recientes y variados. A continuación, se revisan algunos de los trabajos que aplican este enfoque, comenzando por aquellos centrados en desarrollar modelos cuyo rendimiento se compara con la evaluación radiológica mediante PI-RADS, y continuando con estudios que abordan cuestiones complementarias como la robustez, la interpretabilidad o la integración con otras fuentes de información.

Entre los trabajos que comparan el rendimiento de modelos de *Deep Learning* con PI-RADS, destaca una propuesta reciente de Yang et al. (2024). En este estudio, se entrenaron tres modelos independientes utilizando las secuencias T2W, DWI y ADC, todos ellos basados en la arquitectura PBS-ConvNet, construida con bloques *squeeze-and-excitation*. Las salidas probabilísticas de estos modelos se integraron posteriormente mediante un promedio simple para construir un *ensemble*. Los modelos individuales obtuvieron AUCs de 0.872 (DWI), 0.871 (ADC) y 0.788 (T2W), mientras que el *ensemble* alcanzó un AUC de 0.902. En comparación con la evaluación clínica mediante PI-RADS, el modelo combinado alcanzó una mayor especificidad (90.6 % vs. 75.6 %) y AUC (0.902 vs. 0.759), aunque con una sensibilidad algo inferior (72.8 % vs. 76.1 %).

Utilizando las mismas secuencias de resonancia magnética que el estudio anterior, Zhao et al. (2023) desarrollaron varios modelos de *Deep Learning* entrenados con datos procedentes de cuatro hospitales y validados externamente en otros tres, con una cohorte total de 1861 pacientes. Concretamente, evaluaron el rendimiento de cuatro arquitecturas convolucionales tridimensionales (ResNet3D, DenseNet3D, ShuffleNet3D y MobileNet3D), obteniendo resultados comparables a la evaluación mediante PI-RADS, sin diferencias significativas en las curvas ROC obtenidas en las tres cohortes de validación externa ($p > 0.05$). Posteriormente, el modelo con mejor rendimiento se integró con la puntuación PI-RADS para construir un modelo combinado, que alcanzó AUCs de 0.875, 0.914 y 0.887 en cada una de las tres cohortes de validación externa.

Resultados similares fueron obtenidos por Aldoj et al. (2020), quienes presentaron un método semi-automático basado en una red neuronal convolucional tridimensional. Los investigadores evaluaron distintas combinaciones de secuencias de resonancia magnética en un conjunto de 200 pacientes. La combinación más eficaz, compuesta por ADC, DWI y K-trans —un parámetro derivado de DCE—, alcanzó un AUC de 0.897, comparable al rendimiento de radiólogos expertos. Un hallazgo relevante de este trabajo fue que incluir la secuencia T2W apenas aportaba mejora en el rendimiento del modelo.

Utilizando una arquitectura similar, Mehrtash et al. (2017) desarrollaron un modelo diseñado para analizar volúmenes centrados en la lesión, utilizando imágenes ADC, DWI y K-trans. El modelo fue entrenado con datos de 201 pacientes y validado mediante validación cruzada con cinco folds. En el conjunto de prueba del PROSTATEx Challenge, alcanzó un AUC de 0.80, comparable al rendimiento de lectores humanos experimentados: 0.79 y 0.83 para PI-RADS v1 y v2, respectivamente.

Entre los estudios que exploran aspectos complementarios al rendimiento puro, destaca el trabajo de L. Hu et al. (2024), quienes abordaron el impacto de los artefactos rectales en las imágenes de RMmp, un problema habitual que puede comprometer la fiabilidad de los modelos de diagnóstico automático. Para mitigar este efecto, propusieron una estrategia de entrenamiento adversarial dirigida (TPAS), que utiliza ejemplos adversariales diseñados para inmunizar al modelo frente a artefactos visibles e invisibles. Evaluado en una cohorte multicéntrica de 2203 pacientes, el enfoque TPAS mejoró significativamente el rendimiento general (AUC 0.87 vs. 0.81) y aumentó la robustez del modelo frente a artefactos severos (AUC 0.75 vs. 0.57).

Para finalizar, Khosravi et al. (2021) desarrollaron un sistema de *Deep Learning* que integra imágenes T2W con datos histopatológicos, incorporando además mecanismos de interpretabilidad. El modelo se basa en la arquitectura Inception-V1, preentrenada en ImageNet y adaptada mediante aprendizaje por transferencia. Además, para dotar al sistema de capacidad interpretativa, se incorporaron mapas de activación de clase (CAM), que visualizan las regiones relevantes utilizadas por la red durante la inferencia. Entrenado con imágenes de 400 pacientes, el modelo alcanzó un AUC de 0.78 en la estratificación de riesgo.

Comparación entre radiómica y *Deep Learning*

Además de los múltiples estudios que desarrollan exclusivamente técnicas de radiómica o enfoques basados en *Deep Learning*, existen también trabajos —aunque aún escasos— que comparan directamente el rendimiento de ambos métodos.

Entre ellos, destaca el estudio de Castillo et al. (2021), que desarrolló ambos enfoques a partir de imágenes T2W, DWI y sus correspondientes mapas ADC. El modelo basado en *Deep Learning* consistía en una red neuronal convolucional que recibía como entrada las tres secuencias como canales independientes. Por su parte, el modelo radiómico se construyó a partir de 564 características radiómicas, que se emplearon para entrenar múltiples modelos, combinando posteriormente las mejores soluciones en un *ensemble*. El análisis se llevó a cabo utilizando cuatro cohortes: una de entrenamiento ($n = 271$) y tres de validación ($n = 374$ en total). Mientras que la validación cruzada interna mostró un mayor AUC para el modelo de *Deep Learning*, los resultados en las cohortes de prueba revelaron un mejor rendimiento del modelo radiómico, que alcanzó AUCs de 0.88, 0.91 y 0.65, en comparación con los 0.70, 0.73 y 0.44 obtenidos por el modelo de *Deep Learning*.

De forma similar, Bertelli et al. (2021) implementaron diversos modelos de *Machine Learning* y *Deep Learning* utilizando imágenes T2W, mapas ADC y su combinación (T2W+ADC). Para el enfoque de *Machine Learning*, extrajeron 95 características radiómicas 2D y entrenaron distintos clasificadores basados en técnicas de *ensemble*, como *Random Forest*, *Extra-Trees* o *Gradient Boosting*. En el enfoque de *Deep Learning*, diseñaron redes neuronales convolucionales bidimensionales entrenadas con recortes centrados en la lesión. En el conjunto de prueba multi PI-RADS, el modelo de ML entrenado con características radiómicas extraídas de imágenes T2W mostró el mejor rendimiento, alcanzando un AUC de 0.795. Por su parte, el mejor modelo de DL —basado en la combinación de imágenes T2W+ADC— logró un AUC de 0.752, aunque el modelo entrenado únicamente con imágenes T2W obtuvo un rendimiento prácticamente idéntico (AUC de 0.750). En ambos enfoques, los modelos entrenados con mapas ADC de forma aislada no ofrecieron un rendimiento superior al azar.

2.2.2. Crítica al estado del arte

A pesar del creciente desarrollo de técnicas de Inteligencia Artificial aplicadas al análisis del cáncer de próstata mediante imágenes de resonancia magnética multiparamétrica, la literatura actual presenta todavía varias limitaciones relevantes.

Falta de generalización y robustez

Una parte importante de los modelos desarrollados en la literatura se entrena y evalúa sobre conjuntos de datos obtenidos en un número muy reducido de centros. Esta falta de diversidad en los datos impide que los modelos capturen la variabilidad existente en la práctica clínica real, lo que compromete su capacidad de generalización frente a datos obtenidos en otras instituciones, bajo distintos protocolos de adquisición o con equipos de resonancia magnética diferentes.

Dificultades en la integración clínica

Aunque se ha demostrado que muchos modelos pueden superar el rendimiento de las técnicas convencionales, su adopción en la práctica clínica real continúa siendo limitada. Esto se debe, en parte, a la falta de validaciones externas con cohortes amplias y a la escasa evidencia sobre su impacto en el proceso diagnóstico.

Presencia de sesgos y falta de equidad

Los algoritmos de Inteligencia Artificial pueden perpetuar e incluso amplificar sesgos presentes en los datos de entrenamiento, lo que puede afectar negativamente la equidad de los modelos al modificar su rendimiento en función de variables como la edad, el historial clínico o las condiciones técnicas de adquisición. No obstante, son pocos los estudios que abordan esta problemática, y aún menos los que proponen estrategias para mitigar sus efectos.

Falta de interpretabilidad

Los modelos de Inteligencia Artificial suelen actuar como sistemas opacos, dificultando la comprensión de sus predicciones. Esta falta de transparencia representa una barrera importante para su aceptación en entornos clínicos, donde resulta esencial interpretar y justificar cada decisión. Pese a ello, son todavía pocos los estudios que abordan esta necesidad.

Comparación limitada entre enfoques radiómico y de *Deep Learning*

A pesar de la extensa literatura centrada por separado en radiómica o en *Deep Learning*, los estudios que comparan directamente ambos enfoques siguen siendo escasos. Esta falta de comparaciones limita la comprensión de sus respectivas fortalezas y debilidades. Además, hasta donde alcanza la revisión llevada a cabo, no se ha encontrado ningún estudio que evalúe también la interpretabilidad de ambos métodos.

2.2.3. Propuesta

A partir de las limitaciones observadas en la literatura, este trabajo propone comparar modelos basados en radiómica y en *Deep Learning* para clasificar la severidad del cáncer de próstata mediante imágenes de resonancia magnética multiparamétrica, integrando, además, técnicas de explicabilidad que permitan interpretar sus decisiones.

Aunque ambos enfoques han sido explorados por separado, son escasos los estudios que comparan directamente su rendimiento bajo condiciones experimentales homogéneas. Asimismo, gran parte de la literatura no incorpora mecanismos que permitan identificar qué variables o regiones de la imagen influyen en las decisiones de los modelos. Este trabajo aborda de forma conjunta ambas cuestiones.

CAPÍTULO 3

Metodología

La metodología seguida en este trabajo se resume en la Figura 3.1, que muestra las principales etapas del enfoque propuesto. Tras una fase de comprensión de los datos (Sección 3.1), se desarrollan dos enfoques de modelado: uno basado en análisis radiómico (Sección 3.2), que emplea las características radiómicas extraídas de las imágenes para entrenar modelos de *Machine Learning*, y otro basado en *Deep Learning* (Sección 3.3), que utiliza directamente las imágenes. A continuación, se realiza una comparación del rendimiento de ambos enfoques mediante pruebas estadísticas (Sección 3.4) y, finalmente, se examina la interpretabilidad de los modelos (Sección 3.5) para identificar los factores que influyen en sus predicciones.




Figura 3.1: Resumen del enfoque metodológico propuesto.
Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

3.1 Comprensión de los datos

Los datos utilizados en este estudio provienen del *Public Training and Development Dataset* del reto PI-CAI (A. Saha et al. 2024), compuesto por 1.500 casos de pacientes con sospecha de cáncer de próstata clínicamente significativo, habitualmente motivada por niveles elevados de antígeno prostático específico (PSA) o hallazgos anormales en el tacto

rectal (DRE) —siempre que no hubieran sido tratados previamente ni diagnosticados con un cáncer clínicamente significativo en evaluaciones anteriores—. Todos los casos han sido completamente anonimizados y están disponibles bajo una licencia de uso no comercial.

Cada caso incluye, como mínimo, tres secuencias de resonancia magnética adquiridas en plano axial: imágenes ponderadas en T2 (T2W), imágenes ponderadas por difusión (DWI) y mapas del coeficiente de difusión aparente (ADC). Adicionalmente, algunos casos incorporan imágenes T2W en planos sagital y/o coronal, de forma opcional. Ninguno de los casos incluye imágenes obtenidas mediante contraste dinámico (DCE).

Junto con las imágenes, se proporciona una segmentación automática de la glándula prostática completa para los 1.500 casos, generada mediante un modelo de *Deep Learning* entrenado para ofrecer segmentaciones robustas. Este modelo, desarrollado por Anindo Saha et al. (2022), se basa en un ensamblado de cinco redes nnU-Net y alcanza un coeficiente de Dice medio de 0.8968 y un índice de Jaccard medio de 0.8169. También se incluyen segmentaciones zonales de la próstata, que distinguen entre la zona periférica (PZ) y la zona transicional (TZ). Por último, en 220 de los casos positivos se han anotado manualmente las lesiones correspondientes al cáncer clínicamente significativo, utilizando información radiológica, patológica y, en algunos casos, histológica. Para el resto de los 1.280 casos, se han proporcionado anotaciones automáticas mediante una estrategia de aprendizaje semisupervisado.

Además, el conjunto de datos incluye variables clínicas asociadas a cada caso, como la fecha del estudio, la edad del paciente, el valor del PSA, la densidad del PSA, el volumen prostático y el grado ISUP. A partir de este último, se construye una variable binaria que indica la presencia o ausencia de cáncer clínicamente significativo, considerando como positivos aquellos casos con un grado ISUP igual o superior a 2.

3.1.1. Secuencias de resonancia magnética y segmentaciones

De entre las modalidades de imagen y segmentaciones descritas en la introducción de esta sección, en este trabajo se emplean exclusivamente las secuencias de resonancia magnética en plano axial —T2W, DWI y ADC— junto con la segmentación de la glándula prostática completa. Esta segmentación permite excluir tejidos potencialmente no relevantes para el análisis, lo que contribuye a reducir el ruido en la entrada de los modelos. Esto posibilita evaluar, en condiciones comparables, el rendimiento de los modelos cuando se entrena con la imagen completa frente a cuando se restringe el análisis a la región prostática.

Se descartan, por el contrario, aquellos recursos del conjunto de datos que no están disponibles de forma sistemática o que no se ajustan al objetivo del estudio. Es el caso de las secuencias T2W en planos sagital y coronal, ya que no están disponibles en todos los casos y no existen secuencias complementarias en dichos planos para DWI y ADC, lo que complicaría la integración de todas las secuencias en un mismo esquema de entrada. También se omiten las segmentaciones zonales (PZ y TZ), que, si bien podrían aportar valor clínico al análisis —dado que ciertas regiones de la próstata presentan mayor frecuencia de aparición tumoral—, requerirían un procesamiento adicional no contemplado dentro del alcance temporal del presente trabajo. Del mismo modo, las anotaciones de las lesiones no se utilizan en este estudio, ya que están diseñadas para tareas de segmentación, y no resultan adecuadas para abordar el problema planteado.

Definidas las secuencias y segmentaciones a emplear, se procede a analizar sus características principales y su función dentro del flujo de trabajo.

Secuencias de resonancia magnética

Las imágenes de resonancia magnética constituyen la base fundamental de este estudio, ya que se utilizan para dos propósitos principales: como base para la extracción de descriptores cuantitativos en radiómica, los cuales se emplean posteriormente en modelos de *Machine Learning*; y como entrada directa de los modelos de *Deep Learning*. En este contexto, resulta fundamental conocer las dimensiones y el espaciado de las imágenes, ya que condicionan distintas etapas del flujo de trabajo. En radiómica, el espaciado afecta directamente al cálculo de las características y la relación entre las dimensiones puede requerir adaptar la estrategia de extracción, mientras que en *Deep Learning* es necesario alinear y redimensionar las secuencias para adaptarlas a la entrada del modelo.

De acuerdo con los valores representados en la Figura 3.2, las dimensiones promedio de las imágenes (en píxeles) varían según la secuencia de resonancia magnética. En el caso de las imágenes ponderadas en T2, el ancho y el alto son de aproximadamente 549 ± 230 píxeles, mientras que la profundidad es de 22 ± 3 cortes. Por su parte, las secuencias DWI y ADC presentan dimensiones espaciales idénticas —con anchos y altos de aproximadamente 139 ± 57 y 152 ± 49 píxeles, respectivamente, y una profundidad de 22 ± 4 cortes—, lo cual es esperable dado que el mapa ADC se deriva directamente de la secuencia DWI. Además de las diferencias entre secuencias, es importante destacar la disparidad existente entre el tamaño en plano axial (es decir, a lo largo del ancho y del alto) y el reducido número de cortes en profundidad (≈ 22) —debido al mayor espaciado entre ellos, como se verá a continuación—, lo que refleja la anisotropía de las imágenes y hace recomendable una extracción bidimensional de las características radiómicas.




Figura 3.2: Distribución de las dimensiones espaciales de las imágenes en función de la secuencia de resonancia magnética.

Por su parte, en cuanto al espaciado entre vóxeles (expresado en milímetros), según se muestra en la Figura 3.3, las secuencias DWI y ADC presentan valores idénticos en las tres dimensiones espaciales, con medias aproximadas de $1.86 \pm 0.29\text{mm}$ en ancho y alto, y de $3.25 \pm 0.36\text{mm}$ en profundidad. En cambio, la secuencia T2W muestra un espaciado considerablemente más reducido en las dos primeras dimensiones, con valores cercanos a $0.42 \pm 0.10\text{mm}$, y un espaciado de $3.19 \pm 0.28\text{mm}$ en la profundidad. Esta diferencia implica que las imágenes T2W ofrecen una resolución anatómica mucho más alta, mientras que las secuencias DWI y ADC se perciben como más «pixeladas», ya que presentan un espaciado aproximadamente 4.4 veces mayor en el plano axial.




Figura 3.3: Distribución del espaciado de las imágenes por secuencia.

Las diferencias en tamaño y espaciado, junto con la marcada anisotropía de las imágenes, tienen implicaciones directas en el procesamiento posterior. En radiómica, el espaciado debe homogeneizarse para garantizar la coherencia en el cálculo de características, y la falta de isotropía entre planos justifica la extracción de características basada en cortes bi-dimensionales. En *Deep Learning*, por su parte, las dimensiones espaciales condicionan el preprocesamiento necesario para adaptar las imágenes al tamaño de entrada del modelo. Estos aspectos se describirán en detalle en las secciones posteriores de la metodología.

Segmentaciones

Las segmentaciones de la glándula prostática tienen un papel fundamental en este estudio, ya que permiten restringir el análisis a la región anatómica de interés, excluyendo el tejido circundante potencialmente irrelevante. Para evaluar el impacto de esta estrategia, se comparan dos configuraciones de entrada: una basada en las imágenes axiales completas y otra en la que se aplica la máscara de segmentación para limitar el análisis exclusivamente a la glándula prostática. Se espera que esta reducción del ruido en las imágenes de entrada contribuya a mejorar el rendimiento de los modelos, al centrar el aprendizaje en las áreas anatómicamente más relevantes para la clasificación de la severidad del cáncer de próstata.

Cada segmentación se representa mediante una máscara binaria, donde los vóxeles que pertenecen a la glándula prostática toman el valor 1 y los vóxeles restantes el valor 0. Estas máscaras presentan las mismas dimensiones espaciales que las secuencias T2W. Para asegurar la correspondencia espacial con el resto de secuencias, se aplica un remuestreo que adapta las máscaras al espacio de cada imagen –como en la extracción de características radiómicas– o, alternativamente, todas las imágenes y la máscara a un espacio común de referencia –como en el enfoque de *Deep Learning*–.

En la Figura 3.4 se muestra un ejemplo visual del proceso de segmentación. A la izquierda, se presenta una imagen T2W, en la que se visualiza la imagen original completa. En el centro, se muestra la correspondiente máscara binaria de segmentación, donde los vóxeles pertenecientes a la próstata aparecen destacados en blanco. A la derecha, se representa el resultado de aplicar la máscara sobre la imagen T2W original, dejando visibles únicamente los tejidos pertenecientes a la glándula prostática y eliminando el resto de la anatomía.




Figura 3.4: Ejemplo visual del proceso de segmentación en una imagen T2W. Se representa la imagen original, la máscara de la segmentación y la imagen resultante tras aplicar la máscara.

3.1.2. Datos clínicos

De entre las variables clínicas disponibles en el conjunto de datos, en este trabajo se utiliza exclusivamente la variable binaria que indica la presencia o ausencia de cáncer de próstata clínicamente significativo, que servirá como variable objetivo. Aunque otras variables como la edad del paciente, el valor del PSA, la densidad del PSA o el volumen prostático podrían aportar información relevante para la estratificación diagnóstica, su incorporación queda fuera del alcance de este estudio, orientado a evaluar la capacidad de los modelos para discriminar entre cáncer clínicamente significativo e indolente basándose exclusivamente en las imágenes de resonancia magnética, sin apoyo de información clínica adicional.

Por su parte, el grado ISUP, que clasifica la severidad del cáncer de próstata en una escala de 0 a 5, se descartó como variable objetivo debido al elevado desbalanceo en su distribución. Como se muestra en la Figura 3.5, la mayoría de los casos se concentran en el nivel 0, mientras que los niveles superiores presentan un número muy reducido de muestras, lo que afectaría negativamente al proceso de entrenamiento y dificultaría la construcción de modelos robustos para la clasificación multiclase.




Figura 3.5: Distribución de casos en función del grado ISUP.

Por este motivo, se adopta un enfoque de clasificación binaria, distinguiendo entre casos negativos (ISUP 0 o 1) y casos positivos (ISUP ≥ 2). Aunque esta nueva variable mantiene un cierto desequilibrio entre clases —como se observa en la Figura 3.6—, la distribución es más equilibrada que en la clasificación original por grados ISUP, lo que facilita el entrenamiento de los modelos de clasificación. No obstante, este desequilibrio sigue suponiendo un desafío que será tenido en cuenta tanto en la configuración experimental como en la interpretación de los resultados.




Figura 3.6: Distribución de casos en función de la presencia o ausencia de csPCa.

3.2 Análisis radiómico

El enfoque radiómico desarrollado en este trabajo sigue las recomendaciones propuestas por la European Society of Medical Imaging Informatics (EuSoMII), desarrolladas en la guía *ESR Essentials: Radiomics—Practice Recommendations*, elaborada por Santinha et al. (2025). Este documento recoge un conjunto de recomendaciones metodológicas orientadas a garantizar la reproducibilidad de los análisis basados en radiómica, abarcando todas las etapas del flujo de trabajo: desde el preprocesamiento de las imágenes y la extracción de características, hasta el desarrollo, validación y explicación de los modelos predictivos. Adicionalmente, para asegurar una adecuada implementación de estas directrices, parte del código original publicado junto con la guía se ha empleado como punto de partida, adaptándolo posteriormente para ajustarse a las elecciones metodológicas y objetivos específicos del presente estudio.

Siguiendo este marco de referencia, la metodología aplicada se estructura en varias fases, que se resumen de forma esquemática en la Figura 3.7. La primera etapa corresponde al preprocesamiento de las imágenes (Sección 3.2.1), donde se aplican técnicas orientadas a mejorar la calidad de los datos y a garantizar la correcta localización de las segmentaciones en cada secuencia. A continuación, se lleva a cabo la extracción de características radiómicas (Sección 3.2.2), que se realiza por separado para cada una de las tres secuencias de resonancia magnética. Esta etapa se aborda mediante dos enfoques: uno que considera únicamente la glándula prostática y otro que emplea la imagen completa.

En ambos casos, se aplican distintos filtros y se generan conjuntos de características que describen cuantitativamente la información presente en las imágenes. Finalmente, en la fase de modelado (Sección 3.2.3), se construyen y validan distintos modelos de *Machine Learning* utilizando la concatenación de los conjuntos de características extraídos de cada secuencia de resonancia magnética, manteniendo por separado los enfoques de imagen completa y glándula prostática. La optimización se realiza únicamente sobre el modelo que presenta el mejor rendimiento.




Figura 3.7: Resumen del enfoque metodológico propuesto en el análisis radiómico. Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

3.2.1. Preprocesamiento de las imágenes

El preprocesamiento constituye una etapa fundamental en el flujo de trabajo radiómico, ya que permite minimizar las fuentes de variabilidad presentes en las imágenes de resonancia magnética, mejorando así la reproducibilidad de las características extraídas. En este estudio se han aplicado dos pasos fundamentales: la corrección del campo de sesgo (*bias field correction*) y la reducción de ruido mediante filtrado anisotrópico (*anisotropic diffusion*). Adicionalmente, se realizó un remuestreo espacial de las máscaras para garantizar su correcta correspondencia con la geometría de cada secuencia.

Corrección del campo de sesgo

La corrección del campo de sesgo tiene como objetivo eliminar una señal suave de baja frecuencia no deseada, conocida como *bias field*, que afecta a las imágenes de resonancia magnética y que se origina debido a inhomogeneidades en los campos magnéticos del escáner. Esta señal difumina la imagen, reduce el contenido de alta frecuencia —como bordes y contornos— y altera la distribución de niveles de gris, haciendo que un mismo tejido presente distintas intensidades según su localización espacial (Juntu et al. 2005).

Para mitigar estas inhomogeneidades, en este trabajo se ha aplicado el algoritmo *N4 Bias Field Correction*, disponible en la librería *SimpleITK*. Tras su aplicación, las intensidades de las imágenes se vuelven más homogéneas para un mismo tipo de tejido, reduciendo el impacto de artefactos inducidos por el escáner, lo que tiene un impacto significativo en la estabilidad de las características radiómicas (Stamoulou et al. 2022).

A modo ilustrativo, en la Figura 3.8 se muestra el efecto de la corrección del campo de sesgo sobre imágenes T2 ponderadas. Aunque visualmente las diferencias entre la imagen original y la homogeneizada son sutiles, la imagen de diferencia permite apreciar mejor la corrección aplicada. Este mismo preprocesamiento se ha aplicado a las otras dos secuencias utilizadas en el estudio.




Figura 3.8: Efecto de la corrección del campo de sesgo en imágenes T2W.

Reducción de ruido mediante filtrado anisotrópico

Sobre las imágenes homogeneizadas, se aplica un proceso de reducción de ruido basado en difusión anisotrópica, que actúa como un filtro de paso bajo selectivo: suaviza las regiones homogéneas eliminando el ruido de alta frecuencia, pero preserva los bordes y detalles estructurales (Insight Toolkit 2023). De este modo, evita la pérdida de información relevante como los contornos de lesiones o límites anatómicos. Este método resulta especialmente adecuado para secuencias de resonancia magnética propensas al ruido, como DWI y ADC, aunque también puede mejorar la nitidez general en imágenes T2W.

En este trabajo, se ha utilizado el filtro *CurvatureAnisotropicDiffusionImageFilter* de la librería *SimpleITK*, que implementa una variante de la difusión anisotrópica clásica. A diferencia del método tradicional de Perona-Malik, esta implementación basada en curvatura ofrece menor sensibilidad al contraste, lo que permite preservar estructuras y detalles más finos en las imágenes. Aunque cada iteración requiere aproximadamente el doble de tiempo de procesamiento que la difusión anisotrópica basada en gradiente, este algoritmo generalmente necesita menos iteraciones para alcanzar resultados aceptables, lo que compensa parcialmente esta desventaja computacional (Insight Toolkit 2025).

Como ejemplo representativo de este proceso, la Figura 3.9 muestra el resultado del suavizado mediante difusión anisotrópica por curvatura aplicado a imágenes DWI. Se presentan la imagen homogeneizada, la suavizada y la imagen de diferencia, donde se aprecian las regiones en las que se ha eliminado ruido de alta frecuencia.




Figura 3.9: Efecto del suavizado por difusión anisotrópica por curvatura en imágenes DWI.

Remuestreo espacial de las máscaras

Una vez preprocesadas las imágenes, es necesario garantizar también la correcta correspondencia espacial entre las máscaras de segmentación y las distintas secuencias de resonancia magnética. Dado que las máscaras originales presentan las dimensiones de las imágenes T2W, su uso directo sobre secuencias con diferente resolución espacial —como DWI o ADC— provocaría un desajuste entre la región segmentada y el tejido correspondiente en la imagen, lo que introduciría errores en la extracción de características radiómicas.

Para evitar esta incoherencia espacial, en los experimentos basados en la glándula prostática se aplica un proceso de remuestreo que adapta cada máscara a la resolución y tamaño de la secuencia correspondiente. Este remuestreo se realiza mediante interpolación por vecino más cercano (utilizando la función *sitkNearestNeighbor* de la librería *SimpleITK*), una técnica que garantiza la preservación de los valores discretos de la máscara (0 para el fondo y 1 para la glándula), evitando la aparición de valores no binarios que podrían distorsionar los contornos o modificar el volumen de la región de interés.

El efecto de este proceso puede observarse en la Figura 3.10, donde se representa una imagen DWI junto con la máscara original —definida sobre la secuencia T2W—, la versión remuestreada a la resolución de la DWI, y el resultado final tras aplicar dicha máscara sobre la imagen original. Se aprecia cómo el remuestreo permite mantener la coherencia espacial entre la segmentación y la secuencia analizada, lo que resulta fundamental para garantizar una extracción precisa y localizada de las características radiómicas.

En cambio, cuando se emplea el enfoque basado en la imagen completa, este remuestreo no resulta necesario, ya que no se emplea una segmentación anatómica explícita. En su lugar, se utiliza una máscara binaria de unos con las dimensiones exactas de cada secuencia, de forma que todo el volumen visible se considera región de interés para la extracción de características.




Figura 3.10: Ejemplo visual del proceso de segmentación en una imagen DWI. Se representa la imagen original, la máscara de la segmentación, la máscara de la segmentación remuestreada y la imagen resultante tras aplicar la máscara.

3.2.2. Extracción de características radiómicas

Tras el preprocesamiento de las imágenes se procede a la extracción de características radiómicas. Esta etapa busca transformar la información contenida en las imágenes preprocesadas en descriptores cuantitativos que caracterizan las propiedades morfológicas y texturales de los tejidos. Para ello, se ha utilizado la librería PyRadiomics (Griethuysen et al. 2017), ampliamente empleada en estudios de radiómica por su flexibilidad y conformidad con las directrices del *Image Biomarker Standardisation Initiative* (Zwanenburg, Leger et al. 2016), lo que garantiza la estandarización y reproducibilidad de los descriptores generados.

Como se ha mencionado anteriormente, el proceso de extracción se ha implementado considerando dos configuraciones de entrada: la imagen completa y la glándula prostática exclusivamente, con el fin de evaluar la influencia de limitar el análisis únicamente al tejido anatómico relevante. Cada configuración se aplica de forma independiente sobre las tres modalidades de resonancia magnética consideradas en este trabajo, dando como resultado un total de seis conjuntos de características (2 configuraciones $\times$ 3 secuencias). A continuación, se detallan los parámetros utilizados en la extracción, así como los filtros aplicados a las imágenes y los tipos de características extraídas.

Configuración de la extracción de características

La configuración del proceso de extracción de características radiómicas requiere definir diversos parámetros que influyen directamente en la calidad y reproducibilidad de los descriptores obtenidos. En este trabajo, dichos parámetros se han adaptado individualmente para cada una de las tres modalidades de resonancia magnética, teniendo en cuenta las particularidades inherentes a cada tipo de imagen.

En la Tabla 3.1 se presenta un resumen de los principales parámetros empleados en este estudio, diferenciados por modalidad. A continuación, se justifica su configuración, profundizando en aquellos parámetros que requieren cálculos específicos para su determinación.

Normalización y ajuste de intensidades

- Normalización (normalize): Aplicada a DWI y T2W debido a que presentan intensidades relativas que varían entre diferentes escáneres y configuraciones de adquisición. No se aplica en ADC, ya que sus valores reflejan magnitudes físicas absolutas que deben preservarse sin alteración.

- Escala de normalización (`normalizeScale`) y desplazamiento (`voxelArrayShift`): Para las imágenes DWI y T2W, después de la normalización, las intensidades se multiplican por 100 para ampliar el rango y permitir la selección de un *binWidth* que genere un número adecuado de intervalos. Posteriormente, se aplica un desplazamiento positivo de 300 unidades con el fin de eliminar valores negativos y evitar problemas en el cálculo de descriptores sensibles a este tipo de valores.

Extracción en 2D

Dada la marcada anisotropía de las imágenes —observada previamente en la Figura 3.2— la extracción de características se ha realizado de forma bidimensional sobre cortes axiales (`force2D` activado con `force2Ddimension = 0`), sin realizar remuestreo isotrópico en 3D —proceso que puede introducir artefactos de interpolación y alterar la textura original de la imagen—, lo que permite preservar con mayor fidelidad la información contenida en cada corte.

Remuestreo espacial

Las imágenes se remuestrean a un espaciado uniforme definido mediante el parámetro `resampledPixelSpacing`, calculado a partir de la resolución media observada para cada modalidad (Figura 3.3). En concreto, se utiliza un espaciado más fino para T2W (en torno a $[0.42, 0.42, 0]$ mm), dada su mayor resolución anatómica, y un espaciado de aproximadamente $[1.85, 1.85, 0]$ mm para ADC y DWI, acorde a su menor resolución espacial. El valor 0 en la tercera dimensión indica que no se aplica remuestreo entre cortes, en línea con la extracción bidimensional establecida. En todos los casos, la interpolación se realiza mediante el método B-Spline (`interpolator`), que ofrece un buen equilibrio entre calidad y eficiencia (Meijering 2002).

Discretización de intensidades

El ancho de discretización (`binWidth`) define el tamaño de los intervalos utilizados para construir histogramas y discretizar los niveles de intensidad de la imagen. Se calculó a partir del rango promedio de intensidades (`firstorder:Range`) de cada modalidad, seleccionando un valor que produjera aproximadamente 64 bins, dentro del rango sugerido en la literatura (16–128 bins), el cual ha mostrado una buena reproducibilidad sin diferencias significativas en las características extraídas dentro de este intervalo (Santinha et al. 2025 cit. Tixier et al. 2011). De acuerdo con este criterio, los valores finales de `binWidth` utilizados fueron 61.27 para ADC, 37.05 para DWI y 11.93 para T2W.

Validación de la máscara y eficiencia computacional

- Pre-recorte (`preCrop`): Se activa para todas las modalidades, limitando la imagen al área cubierta por la máscara de segmentación. Esto optimiza notablemente el rendimiento computacional al reducir la memoria utilizada y agilizar el procesamiento posterior.
- Corrección de máscara (`correctMask`) y tolerancia geométrica (`geometryTolerance`): Estos parámetros aseguran la coherencia espacial entre la máscara y la imagen. Se ha habilitado la corrección automática de pequeñas incoherencias y establecido una tolerancia geométrica de 10^3 . Este valor elevado no afecta a la precisión del análisis, ya que se realiza un remuestreo previo y la extracción de características se fuerza en cortes 2D, lo que asegura la coherencia espacial entre la máscara y la imagen.

Parámetro	ADC	DWI	T2W
normalize	false	true	true
normalizeScale	–	100	100
voxelArrayShift	–	300	300
preCrop	true	true	true
resampledPixelSpacing	[1.85, 1.85, 0]	[1.85, 1.85, 0]	[0.42, 0.42, 0]
interpolator	B-Spline	B-Spline	B-Spline
force2D	true	true	true
force2Ddimension	0	0	0
geometryTolerance	10 ³	10 ³	10 ³
correctMask	true	true	true
binWidth	61.27	37.05	11.93

Tabla 3.1: Configuración de los parámetros de PyRadiomics para cada modalidad de imagen.

Aplicación de filtros de imágenes

En este trabajo, se han aplicado diversos filtros a las imágenes, con el objetivo de mejorar la cuantificación de características y patrones clínicamente relevantes antes de la extracción de descriptores (Santinha et al. 2025 cit. Whybra et al. 2024). Este proceso permite resaltar estructuras específicas como bordes, texturas o regiones homogéneas, facilitando la detección de patrones que podrían no ser evidentes en las imágenes originales.

Aunque la aplicación de filtros incrementa considerablemente el número de características extraídas, resultados recientes de Demircioğlu (2022) han mostrado que combinar características extraídas de imágenes originales y filtradas puede ser beneficioso, ya que este enfoque logra un rendimiento predictivo similar o incluso superior al obtenido utilizando únicamente las características de las imágenes originales.

Los filtros aplicados en este estudio se ilustran en la Figura 3.11, mostrando su efecto sobre una imagen T2W, y se describen a continuación:

- **Original:** Imagen sin modificaciones; las características se extraen directamente de los valores originales de intensidad.
- **LoG (Laplacian of Gaussian):** Filtro que resalta bordes y estructuras pequeñas mediante una convolución Gaussiana seguida de un operador Laplaciano, con valores de sigma de 0.6, 2 y 3 para detectar estructuras en distintos tamaños y niveles de detalle.
- **Wavelet:** Aplicación de transformada wavelet con descomposición en dos niveles, capturando simultáneamente patrones de textura en distintas frecuencias (altas frecuencias para detalles finos y bajas frecuencias para estructuras más globales).
- **Square y SquareRoot:** Transformaciones no lineales que modifican el contraste local y ajustan el rango dinámico de intensidades. Square potencia las regiones de alta intensidad y SquareRoot resalta detalles en zonas de baja intensidad.
- **Logarithm:** Compresión de los rangos altos de intensidad, aumentando la visibilidad de detalles en zonas oscuras y de menor contraste.
- **Exponential:** Amplifica las diferencias en valores de intensidad más elevados, resaltando áreas brillantes y generando mayor contraste en zonas con valores de gris más altos.




Figura 3.11: Ejemplo del efecto de los filtros aplicados sobre una imagen T2W. Se muestran la imagen original y los resultados tras aplicar los filtros LoG, Exponential, Logarithm, Square, SquareRoot y Wavelet.

Tipos de características extraídas

Una vez finalizadas las etapas previas del flujo de trabajo, se realizó la extracción de características radiómicas tanto sobre las imágenes originales como sobre las transformadas mediante los filtros aplicados. Estas características se agrupan en seis categorías según la clasificación de la librería PyRadiomics, y sus descripciones se han sintetizado a partir de las definiciones establecidas por la *Image Biomarker Standardisation Initiative* (Zwanenburg, Leger et al. 2016):

- **Shape Features:** Describen las propiedades geométricas de la región de interés, como volumen, área de superficie, esfericidad o compacidad. Se calculan directamente sobre la forma de la máscara segmentada, sin considerar intensidades de la imagen.

- **First-Order Features:** Calculan estadísticas basadas únicamente en la distribución de intensidades de la imagen, sin tener en cuenta la relación espacial entre píxeles. Incluyen medidas como la media, desviación estándar, curtosis, asimetría y entropía.
- **GLCM (Grey Level Co-occurrence Matrix):** Evalúan la frecuencia con la que ocurren combinaciones de intensidades discretizadas en píxeles adyacentes.
- **GLRLM (Grey Level Run Length Matrix):** Analizan la longitud de secuencias consecutivas de píxeles con la misma intensidad en una dirección determinada.
- **GLSZM (Grey Level Size Zone Matrix):** Evalúan las zonas homogéneas de intensidades discretizadas, considerando su tamaño y la frecuencia con que aparecen.
- **NGTDM (Neighbouring Grey Tone Difference Matrix):** Calculan la diferencia de intensidad entre un píxel central y la media de sus vecinos.
- **GLDM (Grey Level Dependence Matrix):** Miden la dependencia entre intensidades de píxeles, evaluando cuántos vecinos de un píxel central presentan valores de intensidad similares.

3.2.3. Entrenamiento, evaluación y optimización de modelos

La etapa de modelado parte de la construcción de una estructura de datos unificada que integra las características extraídas de las tres secuencias de resonancia magnética (T2W, DWI y ADC), manteniendo por separado los enfoques de imagen completa y glándula prostática. Esta estrategia permite garantizar una comparación rigurosa entre los enfoques de radiómica y *Deep Learning*, asegurando que los modelos evaluados en cada enfoque trabajen con la misma información de entrada.

Como posible alternativa, se contempló entrenar modelos independientes para cada secuencia y combinar sus salidas mediante técnicas de *ensemble*. Sin embargo, esta opción no solo ofreció un rendimiento ligeramente inferior en una evaluación inicial, sino que además complicaba la interpretabilidad de las predicciones. Con base en estas consideraciones, se descartó dicha alternativa y se adoptó la concatenación directa de las características.

Una vez establecida la estrategia de concatenación, se procede al entrenamiento, validación y optimización de los modelos de *Machine Learning*. La fase inicial incluye el entrenamiento y evaluación de distintos clasificadores mediante validación cruzada estratificada por paciente, utilizando la estructura de características previamente descrita. Posteriormente, se procede a la optimización de los hiperparámetros del modelo que, según los resultados obtenidos en la comparación descrita en la Sección 3.4, presente el mejor rendimiento, empleando técnicas de búsqueda bayesiana y realizando, además, un análisis de calibración de las probabilidades estimadas. La metodología aplicada para abordar la explicabilidad de las predicciones se detalla en la Sección 3.5.

Entrenamiento y evaluación de modelos

Selección de variables

Como resultado de la concatenación de las características extraídas de las tres secuencias de resonancia magnética, y considerando la aplicación de múltiples filtros durante la fase de extracción, se obtiene un conjunto de datos de elevada dimensionalidad. Este gran número de variables (más de 4000), en relación con el tamaño de la muestra (1500

casos), puede inducir problemas de sobreajuste y afectar negativamente a la capacidad de generalización de los modelos.

Para estudiar cómo afecta la elevada dimensionalidad al rendimiento de los clasificadores, se plantean dos escenarios experimentales:

- **Uso de todas las características:** se entrenan modelos utilizando la totalidad de las variables disponibles, con el objetivo de evaluar la capacidad de los modelos para gestionar directamente la alta dimensionalidad sin aplicar técnicas de reducción.
- **Selección de las características más discriminativas:** se realiza una selección basada en pruebas estadísticas, con el objetivo de reducir la dimensionalidad y limitar el riesgo de sobreajuste.

En caso de aplicar la selección de variables, se lleva a cabo un procedimiento univariante que evalúa de forma independiente la capacidad de cada característica para discriminar entre las clases. Este procedimiento sigue los siguientes pasos:

1. **Prueba de normalidad.** Como primer paso, se analiza la distribución de cada variable mediante el test de Shapiro–Wilk. Esta prueba permite determinar si es adecuado utilizar un test paramétrico o no paramétrico en la comparación de grupos:
 - Si el p-valor es superior a 0.05, se asume normalidad en la variable y se aplica un test paramétrico, más adecuado cuando los datos siguen una distribución normal.
 - Si el p-valor es igual o inferior a 0.05, se considera que la variable no sigue una distribución normal y se recurre a una prueba no paramétrica.
2. **Comparación de grupos.** Una vez establecida la naturaleza de la distribución, se analiza la capacidad de cada variable para diferenciar entre los grupos no-cSPCa y cSPCa.
 - En variables con distribución normal, se aplica el test t de Student, que permite comparar las medias entre ambos grupos.
 - Si no se cumple la normalidad, se utiliza el test de Mann–Whitney U, adecuado para comparar medianas sin requerir supuestos sobre la forma de la distribución.

El p-valor obtenido en esta fase cuantifica la evidencia estadística de que la variable presenta diferencias entre los grupos.

3. **Selección final de variables.** Las variables se ordenan según su p-valor, obteniendo así un listado como el mostrado en la Tabla 3.2, que presenta un extracto con las cinco primeras variables más discriminativas obtenidas en un caso concreto. Ciertas métricas calculadas junto con el p-valor, como el umbral de decisión óptimo, la sensibilidad, la especificidad y el AUC de cada variable, no se muestran en la tabla ya que no se utilizan en el proceso de selección de variables, aunque pueden tener relevancia clínica o ser de interés en análisis complementarios.

Una vez ordenadas, se seleccionan las variables que presentan mayor evidencia de diferenciación entre grupos (menores p-valores), aplicando un límite máximo de una variable por cada 15 observaciones disponibles. Dado que el conjunto de datos incluye 1500 casos, este criterio permite seleccionar como máximo 100 variables.

Variable	...	p-value
dwi_square_ngtdm_Strength	...	1.85E-48
dwi_log-sigma-3-mm-3D_firstorder_Skewness	...	7.79E-41
dwi_exponential_glcml_Imc1	...	1.13E-38
dwi_exponential_ngtdm_Strength	...	1.19E-37
dwi_exponential_glszm_GrayLevelNonUniformityNormalized	...	2.14E-37
...	...	...

Tabla 3.2: Ejemplo de salida del proceso de selección de variables (extracto con las 5 primeras variables ordenadas por p-valor).

Modelos evaluados

Independientemente de si se utilizan todas las variables disponibles o se aplica previamente un proceso de selección, se consideran distintos modelos de *Machine Learning* para abordar la tarea de clasificación a partir de las características radiómicas extraídas. En concreto, se entrenan y evalúan los siguientes algoritmos: *Support Vector Machine*, Regresión Logística, *Random Forest*, *Naive Bayes*, *K-Nearest Neighbors* y *Gradient Boosting*.

Para asegurar que estos modelos trabajen con datos adecuados y evitar que factores como la disparidad de escalas o la falta de variabilidad en algunas características afecten al proceso de aprendizaje, se aplican las siguientes transformaciones sobre los datos:

- **Estandarización de características.** Las características radiómicas extraídas pueden presentar escalas de magnitud muy diferentes, lo que puede afectar negativamente a determinados algoritmos de clasificación. Por este motivo, se aplica una estandarización mediante normalización *z-score*, transformando las variables para que presenten media cero y desviación estándar unitaria. De este modo, se garantiza que todas las características contribuyan de forma comparable al ajuste de los modelos, evitando que aquellas con rangos numéricos mayores dominen el comportamiento del clasificador.
- **Eliminación de variables con varianza nula.** Se descartan aquellas variables que presentan varianza nula, es decir, que tienen un valor constante en todos los casos. Estas variables no aportan información relevante para la discriminación entre clases y su inclusión no solo es irrelevante, sino que puede introducir redundancia en los datos y afectar negativamente a la eficiencia computacional.

Procedimiento de validación

El rendimiento de los modelos se evalúa mediante validación cruzada estratificada por paciente, utilizando la función *StratifiedGroupKFold*, de la librería *scikit-learn*. Este procedimiento asegura que cada fold mantenga una distribución de clases similar a la del conjunto de datos completo y, además, que los casos correspondientes a un mismo paciente no se distribuyan entre los conjuntos de entrenamiento y validación. Esta restricción es especialmente importante, ya que un mismo paciente puede aportar más de un caso al conjunto de datos, y su separación entre particiones podría inducir un sesgo optimista en la evaluación debido a la posible similitud entre sus muestras.

Siguiendo esta metodología, se aplica un esquema de 5 particiones ($K=5$), repitiendo el proceso un total de 10 veces con distintas semillas de aleatorización. De este modo, se entrenan 50 clasificadores por cada modelo considerado, lo que permite obtener estimaciones más estables y robustas del rendimiento, reduciendo la influencia de particiones específicas.

Para cada uno de los clasificadores entrenados, se calculan y registran las siguientes métricas de evaluación:

- Área bajo la curva ROC (AUC).
- *F1-Score* (binario y macro).
- *Accuracy* y *balanced accuracy*.
- Coeficiente de correlación de Matthews (MCC).
- Kappa de Cohen.
- Sensibilidad y especificidad.
- Valores predictivos positivo (PPV) y negativo (NPV).
- Métricas por clase: precisión, recall, *F1-Score* y *accuracy*.

Además, se almacenan las predicciones y probabilidades estimadas por los modelos, permitiendo la posterior generación de análisis complementarios. En particular, se construyen curvas ROC tanto para el fold con mejor AUC (fold óptimo) como para el fold cuyo AUC es más cercano a la mediana (fold representativo).

Optimización del modelo seleccionado

Una vez entrenados todos los modelos y comparados sus resultados mediante las técnicas descritas en la Sección 3.4, se selecciona el clasificador que presenta el mejor rendimiento global, atendiendo a criterios como el AUC, la sensibilidad, la especificidad y el análisis de las curvas ROC. Sobre este modelo se aplica un proceso de optimización, evaluación y calibración con el objetivo de mejorar su desempeño final y ajustar adecuadamente sus probabilidades de predicción.

Optimización de hiperparámetros

Tras seleccionar el modelo a optimizar, se procede a ajustar sus hiperparámetros con el objetivo de mejorar su capacidad predictiva. Para este fin, se recurre a la búsqueda bayesiana, una estrategia que modela de forma probabilística la función de evaluación de los hiperparámetros y utiliza esta información para seleccionar de forma eficiente las configuraciones más prometedoras (Wu et al. 2019). A diferencia de métodos como la búsqueda exhaustiva (*grid search*), que evalúan de forma sistemática todas las combinaciones posibles, o la búsqueda aleatoria, que explora el espacio sin un criterio dirigido, la búsqueda bayesiana aprovecha el conocimiento adquirido en las iteraciones previas para guiar de forma inteligente la exploración. Esto permite encontrar configuraciones óptimas con un menor número de evaluaciones.

Siguiendo este planteamiento, la optimización de hiperparámetros se realiza con la función *BayesSearchCV* de la librería *scikit-optimize*, aplicando validación cruzada estratificada por paciente para asegurar la robustez del proceso. La métrica principal de referencia es el AUC, aunque se calculan y monitorizan otras métricas complementarias. El espacio de búsqueda definido para cada modelo se detalla en la Tabla 3.3.

Modelo	Hiperparámetro	Rango/Valores
SVM	C (Regularización)	$[10^{-4}, 10^3]$
	kernel	{linear, rbf, poly}
	gamma	$[10^{-4}, 10^3]$
	coef0	[0, 1]
Regresión Logística	C (Regularización)	$[10^{-4}, 10^3]$
	penalty	{l1, l2, elasticnet}
	l1_ratio	[0.1, 0.9]
Random Forest	n_estimators	{50, ..., 1024}
	max_depth	{1, ..., 10}
	max_features	{sqrt, log2, None}
	min_samples_split	{2, ..., 20}
Naive Bayes	-	No aplica
KNN	n_neighbors	{2, ..., 8}
	weights	{uniform, distance}
Gradient Boosting	n_estimators	{50, ..., 1024}
	learning_rate	$[10^{-4}, 0.1]$
	max_depth	{1, ..., 10}
	subsample	[0.5, 1.0]
	max_features	{sqrt, log2, None}

Tabla 3.3: Espacio de búsqueda de hiperparámetros definido para cada modelo.

Evaluación en el conjunto de test

Una vez optimizados los hiperparámetros, se evalúa el modelo resultante sobre el conjunto de validación, calculando métricas como el AUC, exactitud, sensibilidad, especificidad, F1-score, Kappa de Cohen, coeficiente de correlación de Matthews (MCC) y valores predictivos positivo y negativo. Además, se genera la correspondiente matriz de confusión para analizar visualmente los aciertos y errores de clasificación. Esta evaluación se realiza antes de aplicar cualquier proceso de calibración, permitiendo comparar posteriormente el impacto de dicho ajuste en las probabilidades de predicción.

Calibración del modelo

Tras evaluar el modelo optimizado, se lleva a cabo un proceso de calibración con el objetivo de ajustar las probabilidades estimadas y mejorar su utilidad en la toma de decisiones clínicas. Una adecuada calibración permite que las probabilidades predichas reflejen de forma precisa la probabilidad real de que un caso pertenezca a la clase positiva o a la clase negativa, facilitando así la correcta interpretación de los resultados y la toma de decisiones diagnósticas.

Con este objetivo, se aplica la técnica de Platt Scaling, que ajusta una función sigmoide sobre las salidas del clasificador y ha demostrado ser eficaz, especialmente en contextos con tamaños de muestra limitados, donde métodos más complejos como la calibración isotónica pueden inducir sobreajuste (Niculescu-Mizil y Caruana 2005). En consecuen-

cia, la calibración se lleva a cabo mediante la función *CalibratedClassifierCV* de la librería *scikit-learn* empleando el método *sigmoid*, utilizando validación cruzada interna con 5 particiones para estimar los parámetros de la función de calibración.

Como parte de este procedimiento, se generan curvas de calibración antes y después de la aplicación de la técnica, permitiendo visualizar de forma gráfica la mejora en la correspondencia entre las probabilidades predichas y las frecuencias observadas. Además, se determina el umbral de decisión óptimo mediante la maximización del F1-score, lo que permite equilibrar la sensibilidad y la especificidad del modelo en función del comportamiento observado en los datos de validación.

Por último, se reevalúa el modelo sobre el conjunto de validación utilizando el umbral óptimo calculado y se genera la matriz de confusión correspondiente, facilitando la interpretación visual del comportamiento del modelo tras la calibración.

3.3 Deep Learning

La metodología seguida para el desarrollo de modelos basados en *Deep Learning*, implementada con la librería *MONAI* (Cardoso et al. 2022), se resume en la Figura 3.12, que presenta las principales etapas del proceso. El flujo de trabajo comienza con el preprocesamiento de las imágenes (Sección 3.3.1), donde, inicialmente, se aplican técnicas de homogeneización espacial sobre cada secuencia de forma independiente, como el remuestreo y el ajuste de dimensiones, seguidas de la normalización de intensidades. Una vez completadas estas transformaciones, las diferentes modalidades se concatenan en un único tensor multicanal. Finalmente, en determinados casos, se aplica aumento de datos para mejorar la capacidad de generalización de los modelos. Además, de la misma manera que en el análisis radiómico, se consideran dos configuraciones en función de la región de la imagen utilizada: imagen completa o exclusivamente la glándula prostática. A continuación, se presentan las arquitecturas consideradas (Sección 3.3.2) y el procedimiento de entrenamiento y validación aplicado (Sección 3.3.3), siguiendo un esquema de validación cruzada muy similar al empleado en el análisis radiómico.




Figura 3.12: Resumen del enfoque metodológico propuesto en el análisis con *Deep Learning*.

Diagrama elaborado por el autor a partir de las etapas descritas en el presente capítulo.

Las siguientes fuentes, en orden, corresponden a las imágenes de las arquitecturas: Huang et al. (2018), Insightful TScript (s.f.), Dosovitskiy et al. (2021), T. Ahmed y Sabab (2020)

3.3.1. Preprocesamiento de las imágenes

De la misma manera que en radiómica, el preprocesamiento de las imágenes constituye un paso fundamental en la metodología de *Deep Learning*. Durante este proceso, se aplican de forma secuencial las transformaciones necesarias sobre cada secuencia, con el objetivo de estandarizar su resolución y escala de intensidades antes del entrenamiento. A continuación, según la estrategia experimental, se restringe o no la región de interés a la glándula prostática, se concatenan las modalidades y, en algunos casos, se incorporan técnicas de aumento de datos para enriquecer el conjunto de entrenamiento.

Remuestreo espacial: `ResampleToMatchd`

El primer paso consiste en alinear las secuencias de resonancia magnética ADC y DWI con la secuencia T2W, que se toma como referencia espacial. Esta operación garantiza que todas las secuencias compartan el mismo sistema de coordenadas físicas, permitiendo que la información anatómica contenida en cada una de ellas se corresponda de forma precisa en el espacio. La interpolación utilizada es de tipo bilineal, ya que ofrece un compromiso adecuado entre calidad de imagen y eficiencia computacional, generando transiciones más graduales entre píxeles que el método de vecino más cercano sin requerir los cálculos extensos de técnicas más complejas como la interpolación spline (Patil 2018).

Redimensionado de las imágenes: `Resized`

Una vez remuestreadas, las imágenes se redimensionan a un tamaño común de $128 \times 128 \times 32$ voxels, mediante la operación `Resized`. Esta transformación tiene como objetivo adaptar las dimensiones de entrada al tamaño requerido por las arquitecturas de *Deep Learning*, garantizando que todas las muestras presenten el mismo tamaño espacial.

La elección de estas dimensiones permite conservar la información estructural necesaria para el aprendizaje de patrones discriminativos, evitando al mismo tiempo la generación de tensores excesivamente grandes que dificulten la eficiencia del proceso. Esta configuración se ajusta a las dimensiones promedio observadas en las imágenes T2W (véase Figura 3.2), aplicando una reducción axial y un aumento moderado en la profundidad que asegura la cobertura completa del volumen prostático incluso en los casos con mayor número de cortes.

Normalización de intensidades: `ScaleIntensityd`

Tras ser ajustadas espacialmente, las imágenes se someten a una normalización de intensidades mediante la transformación `ScaleIntensityd`, que reescala todos los valores al rango unitario $[0, 1]$. Esta operación es fundamental para garantizar la coherencia en los datos de entrada, ya que cada secuencia de resonancia magnética presenta rangos y distribuciones de intensidad distintas. Además, esta etapa del preprocesado es especialmente útil en escenarios con conjuntos de datos pequeños —como el utilizado en el presente estudio—, donde se ha observado una mejora en el rendimiento de los modelos de *Deep Learning* al aplicar técnicas de normalización (Albert et al. 2023).

Aplicación de la máscara prostática: `MaskIntensityd`

Para aquellos experimentos en los que el análisis se restringe exclusivamente a la glándula prostática, se aplica la transformación `MaskIntensityd`, utilizando como referencia la segmentación de dicha región, previamente remuestreada y redimensionada

para garantizar su correspondencia espacial con las imágenes procesadas. Esta operación consiste en anular los valores de intensidad fuera de la glándula, lo que permite eliminar información irrelevante de los tejidos circundantes. Al limitar el análisis a la región anatómica de interés, se reduce el ruido en las imágenes y se favorece que los modelos aprendan patrones discriminativos específicos del tejido prostático.

Concatenación de secuencias: ConcatItemsd

Finalmente, tras completar los pasos anteriores, las tres secuencias de resonancia magnética (T2W, ADC y DWI) se combinan mediante la transformación `ConcatItemsd`, dando lugar a un único tensor multicanal con dimensiones $3 \times 128 \times 128 \times 32$, que se emplea como entrada directa para los modelos de *Deep Learning*. Este enfoque permite a los modelos procesar de forma conjunta las distintas secuencias, mejorando su capacidad predictiva al explotar la información anatómica y funcional complementaria que aportan.

Aumento de datos

Con el objetivo de aumentar la variabilidad del conjunto de entrenamiento y reducir el riesgo de sobreajuste, algunas configuraciones experimentales incluyen una fase adicional de aumento de datos, tal como se recoge en la Tabla 3.4. Esta etapa se basa en la aplicación de transformaciones aleatorias sobre las imágenes —como rotaciones, traslaciones, alteraciones de intensidad o adición de ruido— que, al introducir variaciones sintéticas, permiten simular escenarios de adquisición diversos y mejorar la capacidad del modelo para generalizar a nuevos casos.

3.3.2. Arquitecturas de los modelos entrenados

En este trabajo se han evaluado seis arquitecturas de *Deep Learning* implementadas en la librería MONAI, todas ellas compatibles con imágenes tridimensionales gracias al parámetro `spatial_dims=3`. La Tabla 3.4 recoge los modelos utilizados en cada configuración experimental. A continuación, se describe brevemente la estructura de cada modelo.

DenseNet121

DenseNet121, propuesta por Huang et al. (2018), es una red neuronal convolucional profunda de 121 capas, organizada en cuatro bloques densos conectados mediante capas de transición. Su principal característica es la conectividad densa, mediante la cual cada capa recibe como entrada la concatenación de todos los mapas de características generados por las capas anteriores, en lugar de limitarse a la salida de la capa inmediatamente anterior. Así, la capa ℓ integra la información de todas las capas desde la 0 hasta la $\ell - 1$, y aporta nuevas representaciones —reguladas por una tasa de crecimiento— que se transmiten a las siguientes. Las capas de transición, compuestas por convoluciones 1×1 y operaciones de *average pooling*, permiten reducir progresivamente la dimensionalidad de los mapas de activación y controlar el crecimiento del número de parámetros. Esta arquitectura fomenta una reutilización eficiente de las características y un flujo de gradientes más estable, lo que da lugar a modelos más compactos, menos propensos al desvanecimiento del gradiente y con una menor carga computacional que otras redes convolucionales profundas de rendimiento equivalente.

ResNet

ResNet, desarrollada por He et al. (2015), introduce el aprendizaje residual mediante conexiones de salto (*skip connections*), que permiten construir redes profundas sin comprometer la estabilidad del entrenamiento. En su variante básica —la empleada en este estudio— cada bloque está compuesto por dos capas convolucionales consecutivas: la primera va seguida de una operación de *Batch Normalization* y una activación ReLU, mientras que la segunda solo se acompaña de una normalización. A esto se añade una *skip connection* que suma directamente la entrada del bloque, x , a la salida tras la segunda convolución. La activación ReLU se aplica después de esta suma, completando la operación residual. De este modo, el bloque aprende una función $F(x)$ que se combina con la entrada original, dando lugar a una salida final de la forma $F(x) + x$. Esta estructura facilita la optimización de redes profundas y permite mejorar el rendimiento a medida que aumenta la profundidad, superando problemas como el desvanecimiento del gradiente, la dificultad de convergencia y la degradación del rendimiento observados en arquitecturas convencionales sin *skip connections*.

EfficientNet-B0

EfficientNet-B0, planteada por Tan y Le (2020), es el modelo base de la familia EfficientNet, que introdujo un enfoque de escalado compuesto (*compound scaling*) para ampliar redes convolucionales de forma equilibrada en profundidad, anchura y resolución. Esta arquitectura fue obtenida mediante búsqueda automática (*neural architecture search*), una técnica que explora de forma sistemática distintas configuraciones arquitectónicas para optimizar el rendimiento en tareas específicas. Su estructura se basa en bloques MBConv (*Mobile Inverted Bottleneck Convolution*), desarrollados por Sandler et al. (2019), a los que se integran módulos de atención Squeeze-and-Excitation (SE), introducidos por J. Hu et al. (2019).

EfficientNet-B7 y B8

EfficientNet-B7 y EfficientNet-B8 son variantes ampliadas de la arquitectura base EfficientNet-B0, obtenidas mediante el mismo principio de escalado compuesto. Ambas mantienen la estructura basada en bloques MBConv con atención Squeeze-and-Excitation, pero incorporan un mayor número de capas, canales y resolución de entrada.

EfficientNet-B7 representa una ampliación sustancial del modelo base, mientras que EfficientNet-B8 incrementa aún más la resolución y la anchura respecto a B7, lo que permite capturar patrones más complejos a costa de un mayor número de parámetros y mayor demanda computacional.

Vision Transformer (ViT)

El modelo Vision Transformer (ViT), propuesto por Dosovitskiy et al. (2021), adapta el esquema de codificación de los Transformers al dominio de las imágenes. Para ello, divide la imagen en pequeños parches de tamaño fijo (por ejemplo, 16×16), aplana cada parche y lo proyecta a un espacio de embeddings mediante una transformación lineal. A estos vectores se les añade una codificación posicional que preserva la información espacial, y el conjunto se introduce en un codificador Transformer estándar compuesto por capas de atención múltiple y bloques MLP con normalización y conexiones residuales.

Configuración	Modelo	Transformaciones
base-densenet	DenseNet121	-
base-resnet	ResNet	-
base-vit	ViT	-
base-efficientnet	EfficientNetBN (b0)	-
base-efficientnet-b7	EfficientNetBN (b7)	-
base-efficientnet-b8	EfficientNetBN (b8)	-
config1	DenseNet121	Flip, Rotate90, Affine, GaussianNoise
config2	ResNet	Flip, Rotate90, Affine, ScaleIntensity
config3	ViT	Flip, Affine, GaussianSmooth, ShiftIntensity
config4	EfficientNetBN (b0)	Flip, Rotate90, ScaleIntensity, GaussianSmooth
config5	EfficientNetBN (b7)	GaussianNoise, AdjustContrast, HistogramShift
config6	EfficientNetBN (b8)	BiasField, ScaleIntensity, GaussianSmooth
config7	ResNet	GaussianSmooth, ShiftIntensity, AdjustContrast
config8	DenseNet121	AdjustContrast, GaussianNoise, ScaleIntensity

Tabla 3.4: Resumen de las arquitecturas de *Deep Learning* consideradas y las transformaciones de *data augmentation* aplicadas en cada configuración experimental. Para una descripción completa de las configuraciones y sus parámetros, véase el Anexo B.

3.3.3. Entrenamiento y evaluación de los modelos

A partir del conjunto de tensores multicanal generados al final del preprocesamiento, se procede al entrenamiento y evaluación de los modelos de *Deep Learning*. Aunque se ha intentado mantener una estrategia metodológica alineada con la empleada en el análisis radiómico —utilizando las mismas métricas de evaluación y una validación cruzada estratificada por paciente—, el elevado coste computacional asociado al entrenamiento de redes profundas ha obligado a reducir el número de ejecuciones.

Entrenamiento de los modelos

El entrenamiento de los modelos se realiza siguiendo un esquema de validación cruzada estratificada por paciente con $K = 5$ particiones mediante la función *StratifiedGroupKFold* de *scikit-learn*. Cada uno de los cinco folds se entrena durante un máximo de 100 épocas, aplicando un mecanismo de *early stopping* con una paciencia de 30 épocas, que permite detener el proceso si no se observa mejora en el AUC de validación. El tamaño de lote se fija en 2 muestras y se emplea el optimizador Adam con una tasa de aprendizaje de 1×10^{-5} . Como función de pérdida se utiliza *CrossEntropyLoss*, ajustando manualmente los pesos asignados a cada clase en función de su frecuencia en el conjunto de entrenamiento, con el objetivo de mitigar el desbalanceo presente en la variable objetivo (véase Figura 3.6).

Durante el entrenamiento, se registra el modelo con mejor AUC en validación para cada fold, que posteriormente se guarda como modelo óptimo para ese split. Al finalizar el proceso completo de validación cruzada, se selecciona como modelo global el que haya obtenido el mejor AUC en cualquiera de los folds, y se almacena como modelo representativo de la configuración evaluada.

Evaluación de los modelos

El conjunto de métricas empleadas para evaluar el rendimiento de los modelos de *Deep Learning* coincide exactamente con el utilizado en el análisis radiómico (véase Sección 3.2.3). Esta decisión permite garantizar la comparabilidad entre ambos enfoques.

3.4 Comparación del rendimiento

Tras el entrenamiento de los modelos de *Machine Learning* y *Deep Learning*, se procede a una evaluación comparativa de sus rendimientos. Este análisis se basa en recomendaciones metodológicas ampliamente aceptadas para la comparación de clasificadores, como las propuestas por Demšar (2006) y Rainio et al. (2024), que aconsejan el uso de técnicas estadísticas no paramétricas cuando se comparan valores de la métrica de evaluación obtenidos en distintos subconjuntos de prueba —por ejemplo, los folds de la validación cruzada—.

La evaluación se organiza en tres niveles: (i) la comparación entre modelos dentro de cada enfoque, (ii) el análisis del impacto de la región anatómica considerada —imagen completa frente a glándula prostática—, y (iii) la comparación global entre los enfoques metodológicos de radiómica y *Deep Learning*.

3.4.1. Comparación entre modelos de radiómica

Con el objetivo de evaluar si existen diferencias significativas en el rendimiento de los clasificadores considerados en el enfoque radiómico, se ha utilizado el test de Friedman como prueba global, calculado sobre los valores del AUC en validación obtenidos en los distintos folds de la validación cruzada. Este procedimiento se alinea con las recomendaciones metodológicas previamente mencionadas, según las cuales la comparación de múltiples modelos de clasificación binaria basada en valores del AUC calculados sobre varios subconjuntos de prueba debe abordarse mediante dicho test.

Si el resultado del test de Friedman indica la existencia de diferencias significativas, se procede a identificar qué pares de modelos difieren entre sí mediante comparaciones post-hoc. Para ello, se aplica el test de Wilcoxon para muestras pareadas, junto con una corrección de Holm para controlar el error asociado a las comparaciones múltiples.

3.4.2. Comparación entre modelos de *Deep Learning*

El análisis estadístico realizado para comparar los modelos de *Deep Learning* sigue el mismo procedimiento descrito en la sección anterior. Sin embargo, debido a la menor cantidad de observaciones disponibles por modelo —resultado de emplear una validación cruzada sin repetición con cinco folds—, en este caso para las comparaciones post-hoc se incorpora además el cálculo del tamaño del efecto mediante la *d* de Cohen. Esta medida permite cuantificar la magnitud de las diferencias entre modelos en relación con la desviación típica de sus valores pareados, proporcionando una estimación independiente del tamaño muestral (Sullivan y Feinn 2012). Aun así, la escasa cantidad de datos por modelo obliga a interpretar los resultados con prudencia, dada la posible inestabilidad de las estimaciones.

Adicionalmente, ante la ya mencionada escasez de observaciones por modelo, y con el objetivo de obtener una visión complementaria al análisis basado en métricas de rendimiento, se realiza también una comparación estadística sobre las probabilidades estimadas por cada modelo, que permite identificar posibles diferencias significativas en la forma en que estos asignan probabilidades a cada clase. Con este fin, utilizando los modelos guardados durante el entrenamiento de cada fold, se generan predicciones sobre los correspondientes conjuntos de validación; a partir de las cuales se obtienen las probabilidades estimadas para cada muestra, sobre las que se aplican los mismos procedimientos estadísticos que en los análisis anteriores.

3.4.3. Impacto de la región anatómica

Con el objetivo de evaluar si restringir la información a la glándula prostática repercute en el rendimiento de los modelos, se compara, para cada configuración de *Deep Learning* y cada clasificador radiómico, el AUC en validación obtenido al utilizar la imagen completa frente al obtenido con la región prostática.

Para ello, se aplica el test de Wilcoxon para muestras pareadas, tanto en su versión bilateral —que permite detectar diferencias significativas sin asumir a priori cuál de los dos enfoques ofrece un mejor rendimiento— como en su versión unilateral, formulada con la hipótesis alternativa de que el rendimiento al emplear únicamente la glándula es superior al obtenido con la imagen completa, con el objetivo de valorar si esta restricción permite mejorar los resultados. En el caso de los modelos de *Deep Learning*, dado el reducido número de observaciones disponibles por configuración, se añade también el cálculo del tamaño del efecto mediante la *d* de Cohen sobre las diferencias pareadas del AUC. No obstante, al igual que en la comparación entre modelos de *Deep Learning*, estos valores deben interpretarse con cautela, ya que las estimaciones pueden resultar inestables en contextos con tan pocos datos.

3.4.4. Comparación entre enfoques metodológicos

Por último, se realiza una comparación entre los dos enfoques metodológicos considerados —radiómica y *Deep Learning*—, utilizando para cada uno el modelo seleccionado a partir de los análisis realizados en sus respectivas secciones. Dado que en radiómica se llevan a cabo múltiples repeticiones de la validación cruzada, mientras que en *Deep Learning* solo se ejecuta una, la comparación se restringe al primer *repeat* del enfoque radiómico, que emplea la misma semilla y, por tanto, genera las mismas particiones que se utilizan en los modelos de *Deep Learning*, lo que permite garantizar la comparabilidad directa entre los resultados de cada fold.

Una vez determinados los modelos a comparar, con el fin de aportar una primera aproximación estadística a la comparación entre enfoques, se aplica el test de Wilcoxon para muestras pareadas con dos colas sobre los cinco pares de valores de AUC —uno por fold—, para evaluar si existen diferencias estadísticamente significativas entre ellos. Dichos valores se obtienen a partir de las probabilidades predichas en el test externo de cada fold. Además, dada la limitada cantidad de observaciones disponibles, se calcula el tamaño del efecto mediante la *d* de Cohen sobre las diferencias pareadas, como estimación complementaria del grado de discrepancia entre enfoques. No obstante, de nuevo, conviene ser prudente al interpretar los resultados debido al escaso tamaño muestral.

De forma complementaria, y con un carácter puramente exploratorio, se incluye también una comparación entre enfoques basada en la observación de distintas métricas de evaluación —como la sensibilidad, la especificidad o el propio AUC, entre otros— con el objetivo de analizar de forma general las diferencias en el rendimiento de los modelos representativos de ambos enfoques.

3.5 Interpretabilidad de los modelos

La última etapa metodológica del presente estudio aborda la interpretabilidad de las predicciones generadas por los modelos entrenados. Este aspecto constituye un elemento clave en sistemas de apoyo al diagnóstico, ya que permite comprender qué características o regiones específicas de las imágenes influyen en las decisiones de los modelos, facilitando así su aceptación y uso en el contexto clínico.

Este análisis se aplica sobre los modelos seleccionados a partir de los análisis realizados en sus respectivas secciones. En cada caso, se emplea el modelo representativo del enfoque correspondiente, elegido en función de su rendimiento en validación y de los criterios establecidos para cada metodología.

A continuación, se detallan las técnicas específicas de XAI empleadas para realizar este análisis en cada enfoque.

Técnicas de XAI aplicadas al enfoque radiómico

Para el análisis del modelo radiómico, se emplean dos técnicas complementarias de explicabilidad, aplicadas de forma independiente sobre los conjuntos de entrenamiento y test con el fin de evaluar la consistencia de los resultados obtenidos: SHAP (*SHapley Additive exPlanations*) y LIME (*Local Interpretable Model-agnostic Explanations*).

En primer lugar, se aplica SHAP, un método basado en la teoría de juegos cooperativos que asigna a cada característica una importancia específica para cada predicción individual. La aplicación de SHAP sigue los siguientes pasos:

1. **Selección del *explainer*.** Se escoge el objeto *explainer* adecuado en función del clasificador empleado en el modelo radiómico: *TreeExplainer* para modelos basados en árboles, *LinearExplainer* para modelos lineales, o *KernelExplainer* como alternativa general.
2. **Cálculo de valores SHAP.** A partir del *explainer* seleccionado, se calculan los valores SHAP para cada instancia del conjunto de datos, obteniendo un vector que cuantifica la contribución individual de cada característica a la probabilidad asignada por el modelo a la clase positiva.
3. **Análisis estadístico entre valores SHAP y clase.** Se realiza un análisis estadístico mediante el test no paramétrico de Mann-Whitney U para comparar la distribución de los valores SHAP entre la clase positiva y la negativa para cada característica. Para mitigar el efecto de las comparaciones múltiples, se aplica la corrección de Holm.
4. **Visualización de resultados.** Finalmente, se generan diversas representaciones gráficas para facilitar la interpretación de los resultados. En primer lugar, se crea un *beeswarm plot*, que muestra la distribución de los valores SHAP por característica junto con un código de color que indica el valor original de cada variable, revelando cómo su magnitud influye en la predicción. A continuación, se emplea un *heatmap* para representar, por instancia, los valores SHAP de las características más relevantes, organizando las muestras por clase. Esto permite identificar diferencias en la contribución de dichas variables entre ambos grupos.

Como técnica complementaria y confirmatoria, se aplica LIME, que proporciona explicaciones locales y permite identificar de forma individual qué características específicas influyen en cada predicción. A partir de estas explicaciones locales generadas para cada instancia, se construye una visualización global —similar al *beeswarm plot*— en la que se aplica una normalización logarítmica intra-variable. Esta transformación permite ajustar la escala de los valores originales de cada característica, de modo que la codificación de color refleje su magnitud relativa dentro de cada variable, lo que facilita la comparación con los resultados obtenidos mediante SHAP.

Técnicas de XAI aplicadas al enfoque de Deep Learning

En el caso del modelo basado en *Deep Learning*, se han explorado distintas técnicas de interpretabilidad visual, incluyendo GradCAM, Guided Backpropagation y variantes combinadas. Sin embargo, finalmente solo se ha empleado *Occlusion Sensitivity*, al ser la única que ha ofrecido resultados clínicamente interpretables.

Esta técnica genera dos tipos de visualizaciones. Por un lado, se crean mapas individuales para cada muestra, que permiten identificar las regiones anatómicas cuya oclusión provoca un mayor descenso en la probabilidad asignada por el modelo a la clase verdadera. Esto permite interpretar, caso por caso, qué zonas han sido más relevantes en la toma de decisiones. Por otro lado, se construyen mapas agregados por clase, obtenidos como el promedio de los mapas individuales correspondientes a cada grupo, con el objetivo de identificar las regiones anatómicas que muestran una mayor sensibilidad a la oclusión de forma consistente en cada clase.

CAPÍTULO 4

Resultados

Este capítulo presenta los resultados obtenidos a partir de los dos enfoques metodológicos desarrollados en este estudio. En primer lugar, se muestran los hallazgos del análisis radiómico (Sección 4.1), seguidos de los correspondientes al enfoque basado en *Deep Learning* (Sección 4.2). Posteriormente, se presentan los resultados de la comparación entre ambos enfoques (Sección 4.3) y, finalmente, se exponen las conclusiones derivadas del análisis de interpretabilidad (Sección 4.4).

4.1 Resultados del análisis radiómico

Esta sección detalla los resultados del análisis radiómico, incluyendo la evaluación del proceso de selección de variables, el análisis sobre la influencia de la región de entrada, la comparación entre los distintos clasificadores entrenados y, finalmente, los resultados del modelo optimizado.

4.1.1. Evaluación del proceso de selección de variables

Influencia de la selección de variables sobre el rendimiento

Al comparar los resultados obtenidos con y sin selección de variables (Tabla 4.1) —en ambos casos utilizando exclusivamente las características extraídas de la glándula prostática—, se observa que la aplicación del proceso de selección mejora ligeramente el rendimiento en la mayoría de los clasificadores evaluados. Además, cabe destacar que dicha selección reduce de forma considerable el tiempo de cómputo necesario para el entrenamiento de los modelos. Por estos motivos, todos los resultados presentados en el resto del capítulo han sido obtenidos a partir de modelos entrenados tras aplicar dicha selección.

Clasificador	AUC sin selección	AUC con selección
Random Forest	0.799321	0.808602
Gradient Boosting	0.808339	0.808016
SVM	0.805176	0.806309
Regresión Logística	0.758771	0.799179
KNN	0.694788	0.749461
Naive Bayes	0.664797	0.743111

Tabla 4.1: Comparación del AUC mediano obtenido con y sin selección previa de variables.

Caracterización de las variables seleccionadas

Como resultado del proceso de selección de variables, se identificaron las 100 características con mayor capacidad para diferenciar entre cáncer de próstata clínicamente significativo e indolente. La Tabla 4.2 resume su distribución según la secuencia de origen, el tipo de filtro aplicado y la familia de características a la que pertenecen.

En cuanto a la secuencia de origen, las variables extraídas a partir de las secuencias de difusión (DWI y ADC) representaron el 91 % del total, lo que evidencia su mayor capacidad discriminativa frente a la secuencia anatómica T2W, que únicamente aportó el 9 % de las características. En cuanto a los filtros, el más frecuente fue *exponential* (35 %), seguido por *square* y *squareroot*, que en conjunto aportaron un 24 % de las variables. Finalmente, si se analiza la familia de la que provienen estas características, se observa un claro predominio de las variables derivadas de las matrices de textura, que en conjunto (GLSZM, GLCM, GLRLM, NGTDM y GLDM) representaron el 84 % del total.

Categoría	Valor	Porcentaje
Secuencia	DWI	77 %
	ADC	14 %
	T2W	9 %
Filtro	Exponential	35 %
	Square + SquareRoot	24 %
	Laplacian of Gaussian	13 %
	Wavelet	11 %
	Logarithm	7 %
	Original	10 %
Familia	GLSZM	24 %
	GLCM	20 %
	GLRLM	17 %
	First Order	15 %
	NGTDM	13 %
	GLDM	10 %
	Shape	1 %

Tabla 4.2: Distribución de las 100 variables seleccionadas según secuencia, filtro aplicado y familia de características.

4.1.2. Influencia de la región de entrada

Con el objetivo de analizar el impacto de la región de entrada en el rendimiento de los modelos, se compararon los resultados obtenidos al entrenar cada clasificador con características extraídas de la glándula prostática frente a los obtenidos al entrenarlo con características de la imagen completa.

Tal como se recoge en la Tabla 4.3, en todos los casos el rendimiento fue superior al emplear exclusivamente la glándula prostática, con diferencias estadísticamente significativas según el test de Wilcoxon para muestras pareadas ($p < 0.001$). Además, el contraste unilateral confirmó que el rendimiento obtenido al emplear la glándula fue sistemáticamente superior al alcanzado con la imagen completa ($p = 1.000$ en todos los modelos). En consecuencia, todos los resultados presentados en el resto del capítulo corresponden a modelos entrenados exclusivamente con características de dicha región.

Modelo	Glándula	Imagen completa	p (Wilcoxon 2-colas)	p (Wilcoxon uni)
Random Forest	0.8086	0.6083	< 0.001	1.000
Gradient Boosting	0.8080	0.5905	< 0.001	1.000
SVM	0.8063	0.6358	< 0.001	1.000
Logistic Regression	0.7992	0.6204	< 0.001	1.000
KNN	0.7495	0.5601	< 0.001	1.000
Naive Bayes	0.7431	0.5651	< 0.001	1.000

Tabla 4.3: Comparación del AUC mediano en modelos radiómicos según la región de entrada.

4.1.3. Comparación entre clasificadores

Evaluación visual mediante curvas ROC

Se presenta a continuación una primera aproximación a la comparación entre los clasificadores del análisis radiómico. Para ello, se utilizan las curvas ROC obtenidas en dos escenarios: el fold con mejor AUC y el fold cuyo AUC es más próximo a la mediana del clasificador. Estas visualizaciones permiten analizar tanto el rendimiento máximo alcanzado por cada modelo como su comportamiento en un escenario promedio.

En primer lugar, la Figura 4.1a —correspondiente al fold con mejor rendimiento de cada clasificador— muestra que los modelos alcanzaron valores elevados de AUC, con puntuaciones superiores a 0.80 en todos los casos. En concreto, *Gradient Boosting*, Regresión Logística, SVM y *Random Forest* presentaron los mejores resultados (con AUCs alrededor de 0.85), mientras que KNN y *Naive Bayes* mostraron valores algo inferiores (en torno a 0.80).

Por su parte, la Figura 4.1b muestra el rendimiento de los clasificadores en el fold cuyo AUC es más próximo a la mediana. En este escenario, todos los modelos mantuvieron un rendimiento aceptable: *Random Forest*, *Gradient Boosting*, SVM y Regresión Logística alcanzaron AUCs próximos a 0.80, mientras que KNN y *Naive Bayes* obtuvieron valores en torno a 0.75.




Figura 4.1: Curvas ROC de los modelos radiómicos en el fold óptimo (a) y mediano (b).

Comparación estadística del AUC

Aunque la comparación visual ofrece una primera aproximación, resulta necesario complementar el análisis con una evaluación cuantitativa del rendimiento. Para ello, se aplicaron test estadísticos destinados a evaluar si las diferencias en el AUC de validación entre los distintos clasificadores eran estadísticamente significativas.

En primer lugar, se aplicó el test de Friedman para comprobar si existían diferencias globales en el rendimiento de los clasificadores, obteniéndose un p -valor de 1.72×10^{-36} , lo que indica la existencia de diferencias significativas entre los modelos. En consecuencia, se aplicó el test de Wilcoxon para muestras pareadas, con corrección de Holm, con el objetivo de identificar qué pares de modelos presentaban diferencias significativas. Como se observa en la Tabla 4.4, las diferencias entre los clasificadores con mejor rendimiento no resultaron significativas, salvo en el caso de Regresión Logística frente a *Random Forest* y SVM, con p -valores de 0.0273 y 0.0391 respectivamente. Además, todos estos modelos presentaron diferencias significativas frente a KNN y *Naive Bayes*, entre los cuales tampoco se observaron diferencias significativas.

Comparación	p -valor corregido	Significancia
Random Forest vs Gradient Boosting	9.27×10^{-2}	No
Random Forest vs SVM	5.11×10^{-1}	No
Random Forest vs Logistic Regression	2.73×10^{-2}	Sí
Random Forest vs KNN	2.66×10^{-14}	Sí
Random Forest vs Naive Bayes	2.66×10^{-14}	Sí
Gradient Boosting vs SVM	6.18×10^{-1}	No
Gradient Boosting vs Logistic Regression	5.11×10^{-1}	No
Gradient Boosting vs KNN	2.66×10^{-14}	Sí
Gradient Boosting vs Naive Bayes	2.66×10^{-14}	Sí
SVM vs Logistic Regression	3.91×10^{-2}	Sí
SVM vs KNN	2.66×10^{-14}	Sí
SVM vs Naive Bayes	2.66×10^{-14}	Sí
Logistic Regression vs KNN	2.66×10^{-14}	Sí
Logistic Regression vs Naive Bayes	2.66×10^{-14}	Sí
KNN vs Naive Bayes	6.18×10^{-1}	No

Tabla 4.4: Comparación por pares entre clasificadores radiómicos según el AUC (test de Wilcoxon con corrección de Holm).

Análisis de la variabilidad del AUC

Para complementar el análisis anterior, la Figura 4.2 muestra la variabilidad del AUC en validación para cada clasificador. En ella se observa que *Random Forest*, *Gradient Boosting* y SVM presentan las dispersiones más bajas (IQR ≈ 0.030 y SD ≈ 0.022), mientras que Regresión Logística muestra una variabilidad algo mayor aunque moderada (IQR = 0.028 y SD = 0.023). En contraste, KNN y *Naive Bayes* muestran una variabilidad más elevada (IQR alrededor de 0.043 y SDs próximas a 0.028 y 0.030 respectivamente).




Figura 4.2: Distribución del AUC en validación por clasificador radiómico.

Comparación de métricas complementarias

Con el objetivo de completar la comparación del rendimiento de los clasificadores radiómicos, se analizaron métricas complementarias que proporcionan información adicional relevante desde una perspectiva clínica. La Tabla 4.5 muestra la mediana, para cada clasificador, de seis métricas de evaluación: *F1 macro*, *Balanced Accuracy*, sensibilidad, especificidad, y los valores predictivos positivo (PPV) y negativo (NPV).

A partir de estos resultados, se concluye que Regresión Logística y SVM presentan el comportamiento global más equilibrado, destacando especialmente en *F1 macro* (aproximadamente 0.70), *Balanced Accuracy* (alrededor de 0.72) y sensibilidad (0.714 y 0.706 respectivamente), junto con una buena especificidad (en torno a 0.75). Por otro lado, *Random Forest* y *Gradient Boosting* destacaron especialmente por su alta especificidad (superior a 0.89), aunque mostraron una sensibilidad relativamente baja (inferior a 0.49).

En cuanto a la fiabilidad clínica de las predicciones, medida mediante los valores predictivos, todos los clasificadores obtuvieron valores elevados de NPV, siendo Regresión Logística y SVM los modelos con mejor rendimiento (NPV cercanos a 0.87). En contraste, los valores de PPV fueron moderados en todos los casos, aunque *Random Forest* y *Gradient Boosting* mostraron los mejores resultados en esta métrica (alrededor de 0.64).

Finalmente, KNN y *Naive Bayes* presentaron resultados generalmente inferiores en todas las métricas consideradas, confirmando la tendencia observada en los análisis previos basados en el AUC.

Clasificador	F1 macro	Balanced Accuracy	Sensibilidad	Especificidad	PPV	NPV
SVM	0.7083	0.7273	0.7056	0.7635	0.5442	0.8630
Regresión Logística	0.6994	0.7222	0.7143	0.7419	0.5155	0.8697
Gradient Boosting	0.6916	0.6806	0.4855	0.8905	0.6376	0.8167
Random Forest	0.6766	0.6638	0.4190	0.9114	0.6461	0.7996
KNN	0.6698	0.6599	0.4348	0.8841	0.5909	0.8013
Naive Bayes	0.6456	0.6723	0.6768	0.6828	0.4574	0.8418

Tabla 4.5: Métricas de evaluación medianas para los distintos clasificadores radiómicos (ordenados por F1 macro).

4.1.4. Optimización y evaluación del modelo final

Tras la comparación de clasificadores presentada en la sección anterior, se seleccionó la Regresión Logística como el modelo candidato para la optimización final. Esta elección se fundamenta en su rendimiento equilibrado y en propiedades que lo hacen especialmente adecuado en entornos clínicos. No obstante, esta decisión podría haber sido distinta en función del contexto de uso y de los objetivos clínicos específicos —aspectos que serán discutidos en detalle en el Capítulo 5—.

El primer motivo que respalda esta elección es que, aunque modelos como SVM o *Random Forest* obtuvieron un AUC ligeramente superior al de Regresión Logística —diferencias que, de hecho, resultaron estadísticamente significativas—, la Regresión Logística fue el único clasificador que alcanzó una sensibilidad superior a 0.71; un aspecto especialmente relevante en el ámbito clínico, ya que una mayor sensibilidad disminuye la probabilidad de pasar por alto tumores clínicamente significativos. Además, mostró un rendimiento equilibrado en el resto de métricas, con una *balanced accuracy* cercana a 0.72, una especificidad del 74 % y el mayor NPV entre todos los modelos evaluados (0.8697).

En conjunto, estos resultados respaldan la elección de la Regresión Logística para llevar a cabo el proceso de optimización, cuyos resultados se presentan a continuación.

Optimización del modelo

Tras ajustar el modelo mediante búsqueda bayesiana, utilizando el AUC como métrica objetivo, la configuración óptima de hiperparámetros fue a una regularización tipo ℓ_2 con $C = 0.211$. La validación cruzada empleada durante este ajuste mostró una capacidad discriminativa consistente ($AUC = 0.786 \pm 0.019$), así como un *balanced accuracy* aceptable (0.710 ± 0.018). En cambio, la puntuación $F1$ fue sensiblemente inferior (0.581 ± 0.027), probablemente debido al desequilibrio de clases presente en el conjunto de datos.

Una vez optimizado, el modelo fue evaluado sobre el conjunto de prueba, alcanzando un AUC de 0.847 y una *balanced accuracy* de 0.794. Estas métricas se complementan con los resultados derivados de la matriz de confusión (Figura 4.3), que reflejan una sensibilidad del 77.6 % y una especificidad del 81.2 %. Este equilibrio indica que el modelo es eficaz tanto en la detección de casos positivos como en la clasificación correcta de casos negativos. En este sentido, destaca el valor predictivo negativo, que alcanzó un 90.3 %, lo que indica que, si el modelo predice que un paciente no tiene cáncer clínicamente significativo, es muy probable que esa predicción sea correcta.

A pesar de estos buenos resultados, el valor predictivo positivo resultó más moderado (61.7 %), al igual que la puntuación $F1$ (0.688). Esta aparente discrepancia entre sensibilidad (elevada) y PPV (moderado) se debe a que evalúan aspectos distintos: mientras la primera mide la capacidad de detectar casos positivos reales, el PPV refleja la fiabilidad de las predicciones positivas. En contextos con clases desbalanceadas —como el del presente estudio—, es común obtener un PPV más bajo incluso con una sensibilidad elevada, debido a la menor prevalencia de la clase positiva en los datos, lo que aumenta el impacto relativo de los falsos positivos en esta métrica. Como consecuencia, la puntuación $F1$, que combina sensibilidad y PPV mediante su media armónica, se ve limitada por el valor más bajo del PPV, situándose en un nivel moderado pese a la alta sensibilidad.




Figura 4.3: Matriz de confusión correspondiente a la evaluación del modelo de Regresión Logística sin calibración sobre el conjunto de prueba.

Calibración del modelo

Una vez optimizado, con el objetivo de mejorar la interpretación de las probabilidades estimadas, se calibró el modelo mediante Platt scaling. La comparación de las curvas de calibración antes y después del ajuste (Figura 4.4) muestra varios cambios relevantes. En




Figura 4.4: Curvas de calibración del modelo antes y después del ajuste de probabilidad.

la versión previa, la línea negra se mantiene sistemáticamente por debajo de la diagonal de calibración perfecta: desde las probabilidades más bajas hasta las más altas el modelo sobre-estima la probabilidad de un diagnóstico positivo. Tras aplicar Platt scaling, los tres primeros tramos siguen algo por debajo de la diagonal pero la diferencia respecto a la calibración ideal se reduce; a partir de 0.35 la curva cruza la línea de referencia y se coloca levemente por encima hasta aproximadamente 0.65, reflejando ahora una ligera sub-confianza. A partir de 0.75 se observa un descenso puntual, y el bin final ($\approx 0.85\text{--}0.90$) alcanza prácticamente el 100 % de aciertos. Este comportamiento indica que el Platt scaling logró equilibrar mejor las predicciones del modelo, reduciendo la sobreestimación sistemática inicial y acercando la curva a la calibración ideal.

Estas mejoras cualitativas se ven también reflejadas en las métricas obtenidas. El error de calibración esperado (ECE) disminuyó de 0.149 a 0.090, lo que supone una reducción del 39.6 % en la discrepancia media entre las probabilidades predichas y la frecuencia real observada. Por su parte, la pérdida de Brier —métrica que integra calibración y capacidad de discriminación mediante el error cuadrático entre las probabilidades pronosticadas y los resultados observados— pasó de 0.162 a 0.143 (-11.7 %), lo que indica no solo una mejora en la calibración, sino también en la calidad de las probabilidades estimadas.

Tras la calibración, se procedió a ajustar el umbral de decisión para maximizar la puntuación $F1$ en el conjunto de prueba. Debido al desequilibrio entre clases, el umbral estándar (0.5) no garantizaba un buen compromiso entre precisión y sensibilidad, por lo que se evaluaron distintos valores entre 0.1 y 0.9. El valor 0.30 fue el que ofreció el mejor rendimiento, con un $F1$ de 0.681 frente a 0.571 obtenido con el umbral por defecto.

Una vez completado el proceso de calibración y la posterior optimización del umbral de decisión, se evaluó nuevamente el modelo sobre el conjunto de prueba. Como se resume en la Tabla 4.6, la capacidad discriminativa del clasificador se mantiene inalterada ($AUC = 0.847$) —como cabía esperar dado que la calibración es una transformación monótona que preserva el orden de las puntuaciones—. En cuanto al resto de métricas, se observan variaciones leves. La sensibilidad se redujo moderadamente (-0.023), mientras que la especificidad mejoró ligeramente ($+0.009$), lo que refleja un intercambio habitual al modificar el umbral: se detectan algo menos de positivos, pero se reducen los falsos positivos. En esta misma línea, el valor predictivo positivo aumentó ligeramente ($+0.004$), indicando una mayor fiabilidad en las predicciones positivas, mientras que el valor predictivo negativo descendió levemente (-0.008), aunque se mantuvo en niveles elevados (0.895). Finalmente, tanto la *balanced accuracy* como la puntuación $F1$ disminuyeron en 0.007, una diferencia mínima que no afecta al rendimiento global del modelo.

Métrica	Modelo sin calibrar	Modelo calibrado con umbral optimizado	Variación
AUC	0.847	0.847	0.000
F1	0.688	0.681	-0.007
Balanced Accuracy	0.794	0.787	-0.007
Sensibilidad	0.776	0.753	-0.023
Especificidad	0.812	0.821	+0.009
PPV	0.617	0.621	+0.004
NPV	0.903	0.895	-0.008

Tabla 4.6: Comparación de métricas del modelo en el conjunto de prueba antes y después de aplicar calibración y optimización del umbral de decisión.

En resumen, estos resultados confirman que el proceso de calibración y ajuste del umbral preserva la calidad predictiva del modelo, mientras mejora la fiabilidad de las probabilidades predichas y optimiza el equilibrio entre sensibilidad y especificidad. En contextos clínicos donde los falsos positivos tienen mayor impacto que los falsos negativos, este equilibrio puede resultar preferible al modelo sin ajustar.

4.2 Resultados del enfoque de *Deep Learning*

Esta sección presenta los resultados obtenidos con el enfoque de *Deep Learning*, comenzando por el análisis del impacto que tiene la elección de la región de entrada sobre el rendimiento de los modelos. Tras ello, se comparan las distintas configuraciones entrenadas —las cuales pueden consultarse en la Tabla 3.4— con el objetivo de identificar aquella que ofrece el mejor rendimiento.

4.2.1. Influencia de la región de entrada

De forma análoga al análisis realizado en el enfoque radiómico, se evaluó la influencia de la región de entrada en el rendimiento de los modelos de *Deep Learning*. Para ello, se compararon los valores de AUC obtenidos al entrenar cada configuración con imágenes restringidas a la glándula prostática frente a los obtenidos utilizando la imagen completa.

Es importante recalcar que, en esta comparación, el AUC se obtuvo mediante procedimientos distintos para cada enfoque. En el caso de la glándula prostática, se disponía de las predicciones generadas por cada modelo para los cinco folds de validación, lo que permitió calcular el AUC a partir de las probabilidades predichas. En cambio, en el caso de la imagen completa no fue posible generar dichas predicciones, por lo que el AUC empleado corresponde al mejor valor registrado durante el entrenamiento de cada fold. Esta diferencia implica que los AUCs correspondientes a la imagen completa pueden estar sesgados al alza.

Pese a esto, como se puede observar en la Tabla 4.7, el rendimiento obtenido al entrenar los modelos sobre la glándula prostática fue superior en la mayoría de las configuraciones evaluadas. Esta tendencia se refleja tanto en la diferencia de AUC como en los valores del tamaño del efecto, con nueve de las catorce configuraciones presentando una magnitud grande ($\text{Cohen's } d \geq 0.8$), a las que se suman una configuración con magnitud media y dos con magnitud pequeña. No obstante, cabe mencionar que ninguna de las comparaciones fue estadísticamente significativa según el test de Wilcoxon ($p > 0.05$), debido al reducido número de observaciones disponibles por configuración.

En base a estos resultados, el resto del análisis presentado en este capítulo se centra exclusivamente en modelos entrenados sobre la glándula prostática.

Configuración	Glándula	Imagen completa	Cohen's d	Magnitud
base-densenet	0.7374	0.6748	2.640	Grande
base-resnet	0.7297	0.6019	2.064	Grande
base-vit	0.5000	0.5586	-2.322	Grande
base-efficientnet	0.6420	0.6324	0.326	Pequeña
base-efficientnet-b7	0.6628	0.6366	0.903	Grande
base-efficientnet-b8	0.6379	0.6270	0.067	Despreciable
config1	0.7533	0.7127	2.489	Grande
config2	0.7415	0.6445	2.170	Grande
config3	0.6503	0.5349	0.496	Pequeña
config4	0.6755	0.6239	1.502	Grande
config5	0.6524	0.6226	0.509	Media
config6	0.6947	0.6201	1.180	Grande
config7	0.7009	0.6276	1.366	Grande
config8	0.7356	0.6688	1.680	Grande

Tabla 4.7: Comparación del AUC en modelos de *Deep Learning* según la región de entrada.

4.2.2. Comparación entre configuraciones

Análisis descriptivo del AUC

Como punto de partida para la comparación entre configuraciones, se describe brevemente el rendimiento obtenido por cada una de ellas. La Figura 4.5 muestra, para cada configuración, la distribución de los valores de AUC en validación; mientras que la Tabla 4.7 recoge sus respectivas medianas (columna *Glándula*).

Entre todas las configuraciones evaluadas, sobresalieron *config1*, *config2*, *base-densenet*, *config8* y *base-resnet*, que alcanzaron los AUC más altos —todas ellas con valores iguales o superiores a 0.73—. A continuación, se sitúan *config7*, *config6* y *config4*, seguidas de otras configuraciones basadas en *EfficientNet*, cuyo rendimiento fue más limitado. En el extremo opuesto se encuentra *base-vit*, con un valor constante de 0.5 —posiblemente porque esta arquitectura requiere más datos para alcanzar un rendimiento competitivo—.

Al analizar las arquitecturas empleadas, se observó que los modelos basados en *DenseNet121* y *ResNet* tendieron a alcanzar los mejores resultados, tanto en sus versiones base como en aquellas combinadas con técnicas de *data augmentation* (*config1*, *config2*, *config7*, *config8*). En el caso de *EfficientNet*, sus distintas variantes presentaron un rendimiento similar, con valores que oscilan entre 0.6379 y 0.6947, todos ellos claramente por debajo de los mejores resultados. Por su parte, *ViT* mostró de un rendimiento equivalente al azar en su versión base, y aunque experimentó una mejora considerable tras aplicar *data augmentation*, sigue siendo claramente inferior al alcanzado por otras arquitecturas.

Por último, al considerar las transformaciones aplicadas, se observó que las configuraciones con mejor rendimiento —como *config1* y *config2*— combinaron variaciones geométricas con ajustes de intensidad. En cambio, aquellas que aplicaron solo transformaciones de intensidad —como *config7* o *config8*— tendieron a obtener un rendimiento ligeramente inferior. Esto podría indicar que una combinación de ambos tipos de transformaciones resulta más beneficiosa para la capacidad de generalización de los modelos.

Comparación estadística del AUC

Aunque el análisis descriptivo proporciona una primera aproximación, resulta necesario complementarlo con una evaluación cuantitativa del rendimiento. Para ello, se aplicaron pruebas estadísticas con el objetivo de determinar si las diferencias en el AUC de validación entre las distintas configuraciones eran estadísticamente significativas.




Figura 4.5: Distribución del AUC de validación por modelo de *Deep Learning*

En primer lugar, se aplicó el test de Friedman para comprobar si existían diferencias globales en el rendimiento de las configuraciones, obteniéndose un p -valor de 3.43×10^{-5} , lo que indica la existencia de diferencias estadísticamente significativas en el AUC entre al menos algunas de las configuraciones. En consecuencia, se aplicó el test de Wilcoxon para muestras pareadas, con corrección de Holm, con el objetivo de identificar qué pares de modelos presentaban diferencias significativas. Sin embargo, ninguna de estas comparaciones resultó estadísticamente significativa, posiblemente debido al reducido número de muestras disponibles.

Para complementar este análisis, se calcularon los tamaños del efecto mediante el estadístico de Cohen's d , cuyos valores se recogen en la Figura 4.6. En ella, pueden visualizarse con claridad las diferencias de magnitud entre cada par de configuraciones. Por ejemplo, *config1* presenta tamaños del efecto moderados al compararse con otras configuraciones con buen rendimiento —como *config2*, *base-densenet* o *config8*—, mientras que las diferencias con configuraciones con peores resultados —como *config5* o *base-efficientnet*— alcanzan valores notablemente más elevados.




Figura 4.6: Mapa de calor de los tamaños del efecto (Cohen's d) para las comparaciones pareadas entre configuraciones.

Distribución de las probabilidades predichas

Como complemento al análisis del AUC, se evaluó la distribución de las probabilidades de clasificación para la clase positiva generadas por cada configuración. Gracias a este análisis, además de evaluar el rendimiento, fue posible analizar cómo cada modelo distribuye sus probabilidades de predicción.

Análisis descriptivo

En primer lugar, se realizó un análisis descriptivo a partir de la información contenida en la Figura 4.7, que muestra la distribución de probabilidades predichas para cada configuración. Como se puede observar, estas presentan comportamientos diversos en la forma en que asignan dichas probabilidades.

En particular, *config1* y *config5* destacaron por presentar distribuciones equilibradas, con medianas de 0.275 y 0.259 respectivamente, y rangos intercuartílicos amplios (0.708 y 0.679), lo que indica un uso efectivo del rango de probabilidades disponible. Estas características sugieren que ambas configuraciones logran un buen equilibrio, siendo capaces de identificar tanto casos negativos (con probabilidades bajas) como casos positivos (con probabilidades altas), sin mostrar un sesgo excesivo hacia ninguna de las dos clases.

En el extremo opuesto, las configuraciones basadas en *EfficientNet* (*base-efficientnet*, *base-efficientnet-b7*, *base-efficientnet-b8*, *config6*, *config7*, *config8*) presentaron un comportamiento ultra-conservador, con medianas muy bajas (0.003-0.041). Esto indica una marcada tendencia a clasificar la mayoría de casos como negativos, asignando probabilidades muy bajas a la clase positiva incluso en muestras que podrían pertenecer realmente a dicha categoría.

Un caso particularmente problemático fue *base-vit*, que mostró una distribución con mediana exactamente en 0.5 y desviación estándar nula, indicando que este modelo asigna probabilidades constantes a todos los casos —comportamiento equivalente a una predicción aleatoria—. De la misma manera, *config3* también mostró una mediana de 0.5, aunque con una mayor variabilidad, sugiriendo una tendencia sistemática hacia la indecisión en un alto porcentaje de casos.




Figura 4.7: Distribución de las probabilidades asignadas a la clase positiva por cada configuración de *Deep Learning*.

Comparación estadística

Para determinar si las diferencias observadas en las distribuciones probabilísticas eran estadísticamente significativas, se aplicó el test de Friedman. El resultado fue un p -valor prácticamente nulo, lo que confirma la existencia de diferencias significativas entre al menos un par de configuraciones.

Dado este resultado, se procedió a realizar comparaciones post-hoc mediante el test de Wilcoxon para muestras pareadas con corrección de Holm. Los resultados, visualizados en la Figura 4.8, evidenciaron la existencia tanto de comparaciones con diferencias significativas como de grupos de configuraciones con comportamientos estadísticamente equivalentes.

En particular, *config1* mostró diferencias significativas con respecto a todas las demás configuraciones. En contraste, resulta especialmente notable la equivalencia estadística entre *config5* y *base-densenet*, así como entre *config4* y *base-resnet* ($p = 1.000$ en ambos casos), lo que indica que, pese a presentar medianas diferentes, estas configuraciones generan distribuciones probabilísticas estadísticamente indistinguibles.

Asimismo, el conjunto de configuraciones identificadas como ultra-conservadoras en el análisis descriptivo se dividió en dos grupos estadísticamente equivalentes: por un lado, *config6*, *config7*, *config8* y *base-efficientnet-b8*, y por otro, *base-efficientnet-b7* y *base-efficientnet*.




Figura 4.8: Mapa de calor de los p -valores obtenidos al comparar la distribución de probabilidades predichas entre configuraciones de *Deep Learning*

Comparación de métricas complementarias

Con el objetivo de completar la comparación del rendimiento de las configuraciones de *Deep Learning*, se analizaron métricas complementarias que proporcionan información adicional relevante desde una perspectiva clínica. La Tabla 4.8 muestra, para cada configuración, las mismas métricas evaluadas previamente en el análisis radiómico.

Los resultados obtenidos confirman los patrones observados en la distribución de probabilidades. En particular, *config1*, que mostró la distribución probabilística más equilibrada, logró el mejor rendimiento en términos de *Balanced Accuracy* (0.675), resultado de una sensibilidad (0.726) y especificidad (0.741) elevadas. Además, alcanzó el valor más alto de NPV (0.847), aunque con un PPV moderado (0.507), pero aún así superior al de la mayoría de configuraciones.

Clasificador	F1 macro	Balanced Accuracy	Sensibilidad	Especificidad	PPV	NPV
base-densenet	0.6696	0.6649	0.5795	0.7685	0.5062	0.8122
base-efficientnet-b7	0.5570	0.5611	0.4318	0.8178	0.4396	0.7436
base-efficientnet-b8	0.5432	0.5470	0.2738	0.8476	0.4091	0.7458
base-efficientnet	0.5670	0.5645	0.3059	0.8505	0.4182	0.7532
base-resnet	0.6331	0.6289	0.4353	0.8131	0.4933	0.7989
base-vit	0.2199	0.5000	1.0000	0.0000	0.2819	0.0000
config1	0.6689	0.6752	0.7262	0.7407	0.5067	0.8468
config2	0.6291	0.6229	0.4048	0.8411	0.4957	0.7826
config3	0.4172	0.5000	0.6905	0.7059	0.2953	0.7157
config4	0.5818	0.5778	0.3095	0.7963	0.4333	0.7633
config5	0.5901	0.5935	0.6364	0.6905	0.3978	0.7945
config6	0.6076	0.6051	0.3690	0.8505	0.4921	0.7635
config7	0.5823	0.5784	0.3095	0.8472	0.4419	0.7593
config8	0.6352	0.6290	0.3690	0.8925	0.5818	0.7837

Tabla 4.8: Métricas de evaluación medianas para las distintas configuraciones de *Deep Learning*.

Por su parte, las configuraciones ultra-conservadoras —basadas en *EfficientNet*— presentaron el patrón esperado de alta especificidad (0.839 ± 0.018) pero baja sensibilidad (0.337 ± 0.084). Este comportamiento refleja su tendencia a clasificar sistemáticamente los casos como negativos, como se evidenció en sus distribuciones probabilísticas para la clase positiva, con medianas extremadamente bajas.

Un hallazgo especialmente relevante es el comportamiento de los pares de configuraciones que mostraron distribuciones probabilísticas estadísticamente equivalentes. Tanto *config5* vs *base-densenet* como *config4* vs *base-resnet* presentaron diferencias notables en rendimiento (*F1 macro*: 0.590 vs 0.670, y 0.582 vs 0.633, respectivamente), sugiriendo que distribuciones probabilísticas equivalentes pueden traducirse en capacidades discriminativas diferentes.

Finalmente, las configuraciones con comportamientos probabilísticos problemáticos también mostraron un rendimiento limitado. Entre ellas, *base-vit*, con probabilidades constantes, obtuvo una especificidad nula y un *Balanced Accuracy* de 0.5, reflejando un comportamiento equivalente al azar. De forma similar, *config3* alcanzó la misma *Balanced Accuracy*, aunque con mayor especificidad (0.706).

4.2.3. Selección del modelo final

Tras el exhaustivo análisis presentado en las secciones anteriores, se seleccionó *config1* como el modelo candidato para la comparación con el enfoque radiómico. Esta decisión se fundamenta en que dicha configuración alcanzó el mejor AUC mediano (0.753), el mejor *Balanced Accuracy* (0.675), la sensibilidad más alta (0.726) —excluyendo *base-vit*—, una especificidad aceptable (0.741) y el mejor valor predictivo negativo (0.847), además de presentar la distribución probabilística más equilibrada.

4.3 Comparación entre enfoques

4.3.1. Comparación de los mejores modelos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis ege-

stas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

4.3.2. Análisis complementario

4.4 Resultados del análisis de interpretabilidad

4.4.1. Modelo radiómico: SHAP y LIME

4.4.2. Modelo *Deep Learning*: Occlusion Sensitivity

CAPÍTULO 5

Discusión

CAPÍTULO 6

Conclusiones y trabajos futuros

Conclusiones, yendo objetivo por objetivo viendo el grado de cumplimiento... Incluir en algún punto que he aprendido (quizá estructurarlo como conclusiones profesionales [buscar palabra exacta], y conclusiones personales [que he aprendido y que he utilizado del grado en el TFG])

6.1 Legado

Destacar que contribuye este proyecto y cómo los beneficiarios sacarán partido de él.

6.2 Relación del trabajo desarrollado con los estudios cursados

Realizar un ejercicio de introspección que incluya un análisis de la relación de los estudios realizados con el trabajo desarrollado por el alumno.

competencias transversales

6.3 Trabajos futuros

En este apartado se puede presentar una lista de: - Fleclos que le hubiera gustado al alumno acabar en este trabajo pero que no ha podido ser porque se acababa el tiempo disponible para la realización del TFG. - Líneas de desarrollo que se abren para aplicar estos resultados a otras áreas. - Ampliaciones o mejoras tanto de eficiencia como de funcionalidades del trabajo realizado

Cosas:

- Modelos híbridos
- Relación entre las características abstractas generadas por las CNN (capas ocultas) y las características radiómicas
- Combinación de características para la visualización

Bibliografía

- Ahmed, Hashim U et al. (feb. de 2017). «Diagnostic accuracy of multiparametric MRI and TRUS biopsy in prostate cancer (PROMIS): a paired validating confirmatory study». En: *The Lancet* 389.10071, págs. 815-822. ISSN: 0140-6736. DOI: 10.1016/S0140-6736(16)32401-1 (cit. en p. 2).
- Ahmed, Tashin y Noor Sabab (sep. de 2020). *Classification and Understanding of Cloud Structures via Satellite Images with EfficientUNet*. Preprint, ESSOAr. DOI: 10.1002/essoar.10507423.1. URL: <https://doi.org/10.1002/essoar.10507423.1> (cit. en p. 39).
- Albert, Steffen et al. (2023). «Comparison of Image Normalization Methods for Multi-Site Deep Learning». En: *Applied Sciences* 13.15, pág. 8923. ISSN: 2076-3417. DOI: 10.3390/app13158923 (cit. en p. 40).
- Aldoj, Nader et al. (2020). «Semi-automatic classification of prostate cancer on multiparametric MR imaging using a multi-channel 3D convolutional neural network». En: *European Radiology* 30.2, págs. 1243-1253. ISSN: 1432-1084. DOI: 10.1007/s00330-019-06417-z (cit. en p. 18).
- Alpert, Paul F. (2018). «New Evidence for the Benefit of Prostate-specific Antigen Screening: Data From 400,887 Kaiser Permanente Patients». En: *Urology* 118, págs. 119-126. ISSN: 0090-4295. DOI: <https://doi.org/10.1016/j.urology.2018.02.049>. URL: <https://www.sciencedirect.com/science/article/pii/S0090429518303765> (cit. en p. 1).
- Alqahtani, Saeed (nov. de 2024). «Systematic Review of AI-Assisted MRI in Prostate Cancer Diagnosis: Enhancing Accuracy Through Second Opinion Tools». En: *Diagnostics* 14.22, pág. 2576. ISSN: 2075-4418. DOI: 10.3390/diagnostics14222576. URL: <https://doi.org/10.3390/diagnostics14222576> (cit. en p. 4).
- Baliyan, Vinit et al. (2016). «Diffusion Weighted Imaging: Technique and Applications». En: *World Journal of Radiology* 8.9. PMID: 27721941, PMCID: PMC5039674, págs. 785-798. DOI: 10.4329/wjr.v8.i9.785. URL: <https://doi.org/10.4329/wjr.v8.i9.785> (cit. en p. 9).
- Bertelli, Elena et al. (2021). «Machine and Deep Learning Prediction Of Prostate Cancer Aggressiveness Using Multiparametric MRI». En: *Frontiers in Oncology* 11. ISSN: 2234-943X. DOI: 10.3389/fonc.2021.802964 (cit. en p. 19).
- Boesen, Lars (feb. de 2017). «Multiparametric MRI in detection and staging of prostate cancer». En: *Danish Medical Journal* 64.2, B5327. ISSN: 2245-1919 (cit. en p. 2).

- Bray, F. et al. (mayo de 2024). «Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries». En: *CA: A Cancer Journal for Clinicians* 74.3, págs. 229-263. DOI: 10.3322/caac.21834 (cit. en p. 1).
- Broadhouse, Katelyn M. (2019). «The Physics of MRI and How We Use It to Reveal the Mysteries of the Mind». En: *Frontiers for Young Minds* 7, pág. 23. DOI: 10.3389/frym.2019.00023. URL: <https://kids.frontiersin.org/articles/10.3389/frym.2019.00023> (cit. en p. 8).
- Cai, Jason C. et al. (2024). «Fully Automated Deep Learning Model to Detect Clinically Significant Prostate Cancer at MRI». En: *Radiology* 312.2, e232635. DOI: 10.1148/radiol.232635. eprint: <https://doi.org/10.1148/radiol.232635>. URL: <https://doi.org/10.1148/radiol.232635> (cit. en p. 3).
- Cardoso, M. Jorge et al. (2022). *MONAI: An Open-Source Framework for Deep Learning in Healthcare*. arXiv: 2211.02701 [cs.LG]. URL: <https://arxiv.org/abs/2211.02701> (cit. en p. 39).
- Castillo, Jose M. et al. (2021). «Classification of Clinically Significant Prostate Cancer on Multi-Parametric MRI: A Validation Study Comparing Deep Learning and Radiomics». En: *Cancers* 14.1, pág. 12. ISSN: 2072-6694. DOI: 10.3390/cancers14010012. URL: <https://www.mdpi.com/2072-6694/14/1/12> (cit. en p. 19).
- Chaddad, Ahmad et al. (2018). «Predicting Gleason Score of Prostate Cancer Patients Using Radiomic Analysis». En: *Frontiers in Oncology* 8, pág. 630. DOI: 10.3389/fonc.2018.00630 (cit. en p. 17).
- Chen, Tong et al. (2019). «Prostate Cancer Differentiation and Aggressiveness: Assessment With a Radiomic-Based Model vs. PI-RADS v2». En: *Journal of Magnetic Resonance Imaging* 49.3, págs. 875-884. ISSN: 1522-2586. DOI: 10.1002/jmri.26243 (cit. en p. 17).
- Cuocolo, Renato et al. (2019). «Machine learning applications in prostate cancer magnetic resonance imaging». En: *European Radiology Experimental* 3.1, pág. 35. DOI: 10.1186/s41747-019-0109-2. URL: <https://doi.org/10.1186/s41747-019-0109-2> (cit. en p. 10).
- Dall'Era, Marc A. et al. (2012). «Active Surveillance for Prostate Cancer: A Systematic Review of the Literature». En: *European Urology* 62.6, págs. 976-983. ISSN: 0302-2838. DOI: <https://doi.org/10.1016/j.eururo.2012.05.072>. URL: <https://www.sciencedirect.com/science/article/pii/S0302283812006914> (cit. en p. 1).
- Demircioğlu, Aydin (sep. de 2022). «The Effect of Preprocessing Filters on Predictive Performance in Radiomics». En: *European Radiology Experimental* 6.1, pág. 40. ISSN: 2509-9280. DOI: 10.1186/s41747-022-00294-w. URL: <https://doi.org/10.1186/s41747-022-00294-w> (cit. en p. 32).
- Demirel, Hüseyin Cihan y John Warren Davis (mar. de 2018). «Multiparametric magnetic resonance imaging: Overview of the technique, clinical applications in prostate biopsy and future directions». En: *Turkish Journal of Urology* 44.2, págs. 93-102. ISSN: 2149-3235. DOI: 10.5152/tud.2018.56056. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5832385/> (cit. en pp. 2, 7).

- Demšar, Janez (2006). «Statistical Comparisons of Classifiers over Multiple Data Sets». En: *Journal of Machine Learning Research* 7.1, págs. 1-30. URL: <http://jmlr.org/papers/v7/demsar06a.html> (cit. en p. 44).
- Dosovitskiy, Alexey et al. (2021). *An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale*. arXiv: 2010.11929 [cs.CV]. URL: <https://arxiv.org/abs/2010.11929> (cit. en pp. 13, 39, 42).
- Elmaoğlu, M. y A. Çelik (2012). «MRI Physics». En: *MRI Handbook: MR Physics, Patient Positioning, and Protocols*. Springer. Cap. 3, págs. 25-46. DOI: 10.1007/978-1-4614-1096-6_3 (cit. en p. 9).
- Epstein, Jonathan I. et al. (sep. de 2005). «The 2005 International Society of Urological Pathology (ISUP) Consensus Conference on Gleason Grading of Prostatic Carcinoma». En: *The American Journal of Surgical Pathology* 29.9, págs. 1228-1242. DOI: 10.1097/01.pas.0000173646.99337.b1 (cit. en p. 7).
- Fehr, Duc et al. (2015). «Automatic classification of prostate cancer Gleason scores from multiparametric magnetic resonance images». En: *Proceedings of the National Academy of Sciences of the United States of America* 112.46. ISSN: 1091-6490. DOI: 10.1073/pnas.1505935112 (cit. en p. 17).
- Ghai, Sangeet y Masoom A. Haider (jul. de 2015). «Multiparametric-MRI in diagnosis of prostate cancer». En: *Indian Journal of Urology* 31.3. Review article, págs. 194-201. DOI: 10.4103/0970-1591.159606 (cit. en p. 8).
- Gillies, Robert J. et al. (2016). «Radiomics: Images Are More than Pictures, They Are Data». En: *Radiology* 278.2. PMID: 26579733, págs. 563-577. DOI: 10.1148/radiol.2015151169. URL: <https://doi.org/10.1148/radiol.2015151169> (cit. en p. 11).
- Gleason, D. F. y G. T. Mellinger (ene. de 1974). «Prediction of prognosis for prostatic adenocarcinoma by combined histological grading and clinical staging». En: *The Journal of Urology* 111.1, págs. 58-64. DOI: 10.1016/s0022-5347(17)59889-4 (cit. en p. 7).
- Goodfellow, Ian et al. (2016). *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press. Cap. 9 (cit. en p. 12).
- Griethuysen, J. J. M. van et al. (2017). «Computational Radiomics System to Decode the Radiographic Phenotype». En: *Cancer Research* 77.21, e104-e107. DOI: 10.1158/0008-5472.CAN-17-0339. URL: <https://doi.org/10.1158/0008-5472.CAN-17-0339> (cit. en p. 30).
- Grisales, Jesús Alejandro Alzate (dic. de 2024). *Diseño basado en inteligencia artificial de la detección del cáncer de próstata clínicamente significativo a través de imágenes de resonancia magnética*. Trabajo Fin de Máster, Universitat Politècnica de València, Máster Universitario en Ingeniería Biomédica. URL: <https://riunet.upv.es/handle/10251/212676> (cit. en p. 13).
- Hajian-Tilaki, Karimollah (2013). «Receiver Operating Characteristic (ROC) Curve Analysis for Medical Diagnostic Test Evaluation». En: *Caspian Journal of Internal Medicine* 4.2, págs. 627-635 (cit. en p. 14).
- He, Kaiming et al. (2015). *Deep Residual Learning for Image Recognition*. arXiv: 1512.03385 [cs.CV]. URL: <https://arxiv.org/abs/1512.03385> (cit. en p. 42).

- Herneth, Andreas M. et al. (2003). «Apparent Diffusion Coefficient: A Quantitative Parameter for In Vivo Tumor Characterization». En: *European Journal of Radiology* 45.3, págs. 208-213. ISSN: 0720-048X. DOI: 10.1016/S0720-048X(02)00310-8. URL: <https://www.sciencedirect.com/science/article/pii/S0720048X02003108> (cit. en p. 9).
- Holzinger, Andreas et al. (2017). *What do we need to build explainable AI systems for the medical domain?* arXiv: 1712.09923 [cs.AI]. URL: <https://arxiv.org/abs/1712.09923> (cit. en p. 3).
- Hu, Jie et al. (2019). *Squeeze-and-Excitation Networks*. arXiv: 1709.01507 [cs.CV]. URL: <https://arxiv.org/abs/1709.01507> (cit. en p. 42).
- Hu, Lei et al. (2024). «Development and Validation of a Deep Learning Model to Reduce the Interference of Rectal Artifacts in MRI-based Prostate Cancer Diagnosis». En: *Radiology: Artificial Intelligence* 6.2, e230362. DOI: 10.1148/ryai.230362 (cit. en p. 18).
- Huang, Gao et al. (2018). *Densely Connected Convolutional Networks*. arXiv: 1608.06993 [cs.CV]. URL: <https://arxiv.org/abs/1608.06993> (cit. en pp. 39, 41).
- Insight Toolkit (2023). *itk::AnisotropicDiffusionFunction — ITK 5.3.0 Doxygen Documentation*. Consultado el 04 de mayo de 2025. URL: https://docs.itk.org/projects/doxygen/en/v5.3.0/classitk_1_1AnisotropicDiffusionFunction.html (cit. en p. 28).
- Insight Toolkit (2025). *itk::CurvatureNDAnisotropicDiffusionFunction — ITK Doxygen Documentation*. Consultado el 04 de mayo de 2025. URL: https://docs.itk.org/projects/doxygen/en/stable/classitk_1_1CurvatureNDAnisotropicDiffusionFunction.html (cit. en p. 28).
- Insightful TScript (s.f.). *ResNet - Understanding the Revolutionary Neural Network Architecture for Deep Learning*. Consultado el 18 de mayo de 2025. URL: <https://insightfultscript.com/collections/programming/neural-network/resnet/> (cit. en p. 39).
- Juntu, Jaber et al. (2005). «Bias Field Correction for MRI Images». En: *Computer Recognition Systems*. Ed. por Marek Kurzyński et al. Berlin, Heidelberg: Springer Berlin Heidelberg, págs. 543-551. ISBN: 978-3-540-32390-7. DOI: 10.1007/3-540-32390-2_64 (cit. en p. 27).
- Kele, Petra G. y Eric J. van der Jagt (2010). «Diffusion weighted imaging in the liver». En: *World Journal of Gastroenterology* 16.13. PMID: 20355235, PMCID: PMC2848365, págs. 1567-1576. DOI: 10.3748/wjg.v16.i13.1567. URL: <https://doi.org/10.3748/wjg.v16.i13.1567> (cit. en p. 9).
- Khosravi, Pegah et al. (2021). «A Deep Learning Approach to Diagnostic Classification of Prostate Cancer Using Pathology-Radiology Fusion». En: *Journal of Magnetic Resonance Imaging* 54.2, págs. 462-471. DOI: 10.1002/jmri.27599 (cit. en p. 18).
- Koh, Dow-Mu y David J. Collins (2007). «Diffusion-weighted MRI in the Body: Applications and Challenges in Oncology». En: *AJR. American Journal of Roentgenology* 188.6, págs. 1622-1635. ISSN: 0361-803X. DOI: 10.2214/AJR.06.1403. URL: <https://doi.org/10.2214/AJR.06.1403> (cit. en p. 9).
- Lambin, Philippe et al. (2012). «Radiomics: Extracting More Information from Medical Images Using Advanced Feature Analysis». En: *European Journal of Cancer* 48.4,

- págs. 441-446. ISSN: 0959-8049. DOI: 10.1016/j.ejca.2011.11.036. URL: <https://doi.org/10.1016/j.ejca.2011.11.036> (cit. en pp. 9, 10).
- LeCun, Yann, Yoshua Bengio et al. (mayo de 2015). «Deep learning». En: *Nature* 521.7553, págs. 436-444. ISSN: 1476-4687. DOI: 10.1038/nature14539. URL: <https://doi.org/10.1038/nature14539> (cit. en p. 12).
- LeCun, Yann, Bernhard Boser et al. (1989). «Backpropagation Applied to Handwritten Zip Code Recognition». En: *Neural Computation* 1.4, págs. 541-551. DOI: 10.1162/neco.1989.1.4.541 (cit. en p. 12).
- Li, Qing et al. (2014). «Medical image classification with convolutional neural network». En: *2014 13th International Conference on Control Automation Robotics & Vision (ICARCV)*, págs. 844-848. DOI: 10.1109/ICARCV.2014.7064414 (cit. en p. 3).
- Litjens, Geert et al. (2017). «A survey on deep learning in medical image analysis». En: *Medical Image Analysis* 42, págs. 60-88. ISSN: 1361-8415. DOI: 10.1016/j.media.2017.07.005 (cit. en p. 12).
- Lomas, D. J. y D. J. Ahmed (jun. de 2020). «All change in the prostate cancer diagnostic pathway». En: *Nature Reviews Clinical Oncology*. DOI: 10.1038/s41571-020-0332-z. URL: <https://doi.org/10.1038/s41571-020-0332-z> (cit. en p. 1).
- Lundberg, Scott y Su-In Lee (2017). *A Unified Approach to Interpreting Model Predictions*. arXiv: 1705.07874 [cs.AI]. URL: <https://arxiv.org/abs/1705.07874> (cit. en p. 15).
- Matoso, A. y J. I. Epstein (ene. de 2019). «Defining clinically significant prostate cancer on the basis of pathological findings». En: *Histopathology* 74.1, págs. 135-145. DOI: 10.1111/his.13712 (cit. en pp. 1, 7).
- Mayerhoefer, Marius E et al. (2020). «Introduction to radiomics». En: *Journal of Nuclear Medicine* 61.4, págs. 488-495 (cit. en p. 3).
- McNeal, John E. et al. (dic. de 1988). «Zonal distribution of prostatic adenocarcinoma. Correlation with histologic pattern and direction of spread». En: *The American Journal of Surgical Pathology* 12.12, págs. 897-906. DOI: 10.1097/00000478-198812000-00001 (cit. en p. 9).
- Mehrtash, Alireza et al. (2017). «Classification of Clinical Significance of MRI Prostate Findings Using 3D Convolutional Neural Networks». En: *Proceedings of SPIE—the International Society for Optical Engineering*. Vol. 10134, 101342A. DOI: 10.1117/12.2277123 (cit. en p. 18).
- Meijering, Erik (2002). «A Chronology of Interpolation: From Ancient Astronomy to Modern Signal and Image Processing». En: *Proceedings of the IEEE* 90.3, págs. 319-342. DOI: 10.1109/5.993400 (cit. en p. 31).
- Merriell, Samuel W. D. et al. (feb. de 2022). «Systematic review and meta-analysis of the diagnostic accuracy of prostate-specific antigen (PSA) for the detection of prostate cancer in symptomatic patients». En: *BMC Medicine* 20.1, pág. 54. DOI: 10.1186/s12916-021-02230-y. URL: <https://doi.org/10.1186/s12916-021-02230-y> (cit. en p. 1).

- Molnar, Christoph (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Disponible en: <https://christophm.github.io/interpretable-ml-book/>. Lulu.com (cit. en p. 15).
- Mustafa A. Mafraji (nov. de 2023). *Magnetic Resonance Imaging*. Consultado el 22 de abril de 2025. Merck Manual Professional Version. URL: <https://www.merckmanuals.com/professional/special-subjects/principles-of-radiologic-imaging/magnetic-resonance-imaging> (cit. en pp. 8, 9).
- Naji, Leen et al. (2018). «Digital Rectal Examination for Prostate Cancer Screening in Primary Care: A Systematic Review and Meta-Analysis». En: *The Annals of Family Medicine* 16.2, págs. 149-154. DOI: 10.1370/afm.2205. eprint: <https://www.annfammed.org/content/16/2/149.full.pdf>. URL: <https://www.annfammed.org/content/16/2/149> (cit. en p. 2).
- NCI (2025a). *Adenocarcinoma*. <https://www.cancer.gov/publications/dictionaries/cancer-terms/def/adenocarcinoma>. Consultado el 12 de abril de 2025 (cit. en p. 7).
- NCI (2025b). *Epithelial*. <https://www.cancer.gov/publications/dictionaries/cancer-terms/def/epithelial>. Consultado el 12 de abril de 2025 (cit. en p. 7).
- Niculescu-Mizil, Alexandru y Rich Caruana (2005). «Predicting Good Probabilities with Supervised Learning». En: *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*. ICML '05. Bonn, Germany: Association for Computing Machinery, págs. 625-632. ISBN: 1595931805. DOI: 10.1145/1102351.1102430. URL: <https://doi.org/10.1145/1102351.1102430> (cit. en p. 38).
- Nieto-Morales, M.L. et al. (2014). «El esquema de biopsia transrectal puede predecir la gradación histológica incorrecta del cáncer de próstata». En: *Radiología* 56.4, págs. 322-327. ISSN: 0033-8338. DOI: 10.1016/j.rx.2012.05.009. URL: <https://www.elsevier.es/es-revista-radiologia-119-articulo-el-esquema-biopsia-transrectal-puede-S003383381200183X> (cit. en p. 2).
- Oh, W. K. et al. (2003). «Biology of Prostate Cancer». En: *Holland-Frei Cancer Medicine*. Ed. por D. W. Kufe et al. 6.ª ed. Hamilton (ON): BC Decker. URL: <https://www.ncbi.nlm.nih.gov/books/NBK13217/> (cit. en p. 7).
- Pai, Abhishek et al. (abr. de 2023). «Magnetic Resonance Imaging Physics». En: *StatPearls [Internet]*. Actualizado el 2 de abril de 2023. Treasure Island (FL): StatPearls Publishing. URL: <https://www.ncbi.nlm.nih.gov/books/NBK564320/> (cit. en p. 8).
- Patel, Pritesh y Aytakin Oto (2016). «Magnetic Resonance Imaging of the Prostate, Including Pre- and Postinterventions». En: *Seminars in Interventional Radiology* 33.3, págs. 186-195. DOI: 10.1055/s-0036-1586144. URL: <https://doi.org/10.1055/s-0036-1586144> (cit. en p. 9).
- Patil, Malini (sep. de 2018). «Interpolation Techniques in Image Resampling». En: *International Journal of Engineering and Technology* 7, págs. 567-570. DOI: 10.14419/ijet.v7i3.34.19383 (cit. en p. 40).
- Rainio, Oona et al. (2024). «Evaluation Metrics and Statistical Tests for Machine Learning». En: *Scientific Reports* 14.1, pág. 6086. DOI: 10.1038/s41598-024-56706-x. URL: <https://doi.org/10.1038/s41598-024-56706-x> (cit. en p. 44).

- Ribeiro, Marco Tulio et al. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. arXiv: 1602.04938 [cs.LG]. URL: <https://arxiv.org/abs/1602.04938> (cit. en p. 15).
- Rizzo, Stefania et al. (2018). «Radiomics: the facts and the challenges of image analysis». En: *European Radiology Experimental* 2.1, pág. 36. ISSN: 2509-9280. DOI: 10.1186/s41747-018-0068-z. URL: <https://doi.org/10.1186/s41747-018-0068-z> (cit. en pp. 9, 11).
- Saha, A. et al. (jul. de 2024). «Artificial intelligence and radiologists in prostate cancer detection on MRI (PI-CAI): an international, paired, non-inferiority, confirmatory study». En: *The Lancet Oncology* 25.7, págs. 879-887. DOI: 10.1016/S1470-2045(24)00220-1. URL: [https://doi.org/10.1016/S1470-2045\(24\)00220-1](https://doi.org/10.1016/S1470-2045(24)00220-1) (cit. en p. 21).
- Saha, Anindo et al. (2022). *Artificial Intelligence and Radiologists at Prostate Cancer Detection in MRI: The PI-CAI Challenge (Study Protocol)*. DOI: 10.5281/zenodo.6667655. URL: <https://doi.org/10.5281/zenodo.6667655> (cit. en p. 22).
- Sandler, Mark et al. (2019). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. arXiv: 1801.04381 [cs.CV]. URL: <https://arxiv.org/abs/1801.04381> (cit. en p. 42).
- Santinha, João et al. (mar. de 2025). «ESR Essentials: Radiomics—Practice Recommendations by the European Society of Medical Imaging Informatics». En: *European Radiology* 35.3, págs. 1122-1132. DOI: 10.1007/s00330-024-11093-9 (cit. en pp. 26, 31, 32).
- Schoots, Ivo G (feb. de 2018). «MRI in early prostate cancer detection: how to manage indeterminate or equivocal PI-RADS 3 lesions?» En: *Translational Andrology and Urology* 7.1, págs. 70-82. ISSN: 2223-4691. DOI: 10.21037/tau.2017.12.31. URL: <https://doi.org/10.21037/tau.2017.12.31> (cit. en p. 2).
- Shamshad, Fahad et al. (2023). «Transformers in medical imaging: A survey». En: *Medical Image Analysis* 88, pág. 102802. ISSN: 1361-8415. DOI: 10.1016/j.media.2023.102802 (cit. en p. 13).
- Srigley, John R. et al. (sep. de 2016). «One is the new six: The International Society of Urological Pathology (ISUP) patient-focused approach to Gleason grading». En: *Canadian Urological Association Journal* 10.9-10, págs. 339-341. DOI: 10.5489/cuaj.4146 (cit. en p. 7).
- Stamoulou, Elisavet et al. (nov. de 2022). «Harmonization Strategies in Multicenter MRI-Based Radiomics». En: *Journal of Imaging* 8.11, pág. 303. DOI: 10.3390/jimaging8110303 (cit. en p. 27).
- Stec, Nadia et al. (abr. de 2018). «A Systematic Review of Fatigue in Radiology: Is It a Problem?» En: *AJR. American Journal of Roentgenology* 210.4, págs. 799-806. ISSN: 1546-3141. DOI: 10.2214/AJR.17.18613. URL: <https://doi.org/10.2214/AJR.17.18613> (cit. en p. 2).
- Sullivan, Gail M y Richard Feinn (2012). «Using effect size—or why the P value is not enough». En: *Journal of graduate medical education* 4.3, págs. 279-282. DOI: 10.4300/JGME-D-12-00156.1 (cit. en p. 44).

- Tan, Mingxing y Quoc V. Le (2020). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. arXiv: 1905.11946 [cs.LG]. URL: <https://arxiv.org/abs/1905.11946> (cit. en p. 42).
- Tharwat, Alaa (2021). «Classification assessment methods». En: *Applied Computing and Informatics* 17.1, págs. 168-192. DOI: 10.1016/j.aci.2018.08.003 (cit. en pp. 13, 14).
- Timmeren, Janita E. van et al. (2020). «Radiomics in Medical Imaging—“How-to” Guide and Critical Reflection». En: *Insights into Imaging* 11.1, pág. 91. DOI: 10.1186/s13244-020-00887-2. URL: <https://doi.org/10.1186/s13244-020-00887-2> (cit. en p. 10).
- Tixier, Florent et al. (2011). «Intratumor Heterogeneity Characterized by Textural Features on Baseline ¹⁸F-FDG PET Images Predicts Response to Concomitant Radiochemotherapy in Esophageal Cancer». En: *Journal of Nuclear Medicine* 52.3, págs. 369-378. ISSN: 0161-5505. DOI: 10.2967/jnumed.110.082404. eprint: <https://jnm.snmjournals.org/content/52/3/369.full.pdf>. URL: <https://jnm.snmjournals.org/content/52/3/369> (cit. en p. 31).
- Turkbey, Baris et al. (sep. de 2019). «Prostate Imaging Reporting and Data System Version 2.1: 2019 Update of Prostate Imaging Reporting and Data System Version 2». En: *European Urology* 76.3. Epub 2019 Mar 18, págs. 340-351. DOI: 10.1016/j.eururo.2019.02.033 (cit. en p. 8).
- Vignati, A. et al. (2015). «Texture features on T2-weighted magnetic resonance imaging: new potential biomarkers for prostate cancer aggressiveness». En: *Physics in Medicine and Biology* 60.7, págs. 2685-2701. ISSN: 1361-6560. DOI: 10.1088/0031-9155/60/7/2685 (cit. en p. 17).
- Whybra, Philip et al. (2024). «The Image Biomarker Standardization Initiative: Standardized Convolutional Filters for Reproducible Radiomics and Enhanced Clinical Insights». En: *Radiology* 310.2, e231319. DOI: 10.1148/radiol.231319. eprint: <https://doi.org/10.1148/radiol.231319>. URL: <https://doi.org/10.1148/radiol.231319> (cit. en p. 32).
- Wibmer, Andreas et al. (2015). «Haralick texture analysis of prostate MRI: utility for differentiating non-cancerous prostate from prostate cancer and differentiating prostate cancers with different Gleason scores». En: *European Radiology* 25.10, págs. 2840-2850. DOI: 10.1007/s00330-015-3701-8 (cit. en p. 17).
- Wichtmann, Barbara D. et al. (2023). «Influence of Image Processing on Radiomic Features From Magnetic Resonance Imaging». En: *Investigative Radiology* 58.3. URL: https://journals.lww.com/investigativeradiology/fulltext/2023/03000/influence_of_image_processing_on_radiomic_features.3.aspx (cit. en p. 10).
- Woźnicki, Piotr et al. (jul. de 2020). «Multiparametric MRI for Prostate Cancer Characterization: Combined Use of Radiomics Model with PI-RADS and Clinical Parameters». En: *Cancers* 12.7, pág. 1767. ISSN: 2072-6694. DOI: 10.3390/cancers12071767. URL: <https://doi.org/10.3390/cancers12071767> (cit. en pp. 3, 16).
- Wu, Jia et al. (2019). «Hyperparameter Optimization for Machine Learning Models Based on Bayesian Optimization». En: *Journal of Electronic Science and Technology* 17.1, págs. 26-40. ISSN: 1674-862X. DOI: 10.11989/JEST.1674-862X.80904120. URL: <https://www.sciencedirect.com/science/article/pii/S1674862X19300047> (cit. en p. 37).

- Yang, Chunguang et al. (2024). «Deep learning model for the detection of prostate cancer and classification of clinically significant disease using multiparametric MRI in comparison to PI-RADS score». En: *Urologic Oncology: Seminars and Original Investigations* 42.5, 158.e17-158.e27. ISSN: 1078-1439. DOI: 10.1016/j.urolonc.2024.01.021 (cit. en p. 18).
- Zeiler, Matthew D y Rob Fergus (2013). *Visualizing and Understanding Convolutional Networks*. arXiv: 1311.2901 [cs.CV]. URL: <https://arxiv.org/abs/1311.2901> (cit. en p. 16).
- Zhang, Huanhuan y Yufei Qie (2023). «Applying Deep Learning to Medical Imaging: A Review». En: *Applied Sciences* 13.18. ISSN: 2076-3417. DOI: 10.3390/app131810521 (cit. en p. 12).
- Zhao, Litao et al. (2023). «Predicting clinically significant prostate cancer with a deep learning approach: a multicentre retrospective study». En: *European Journal of Nuclear Medicine and Molecular Imaging* 50.3, págs. 727-741. ISSN: 1619-7089. DOI: 10.1007/s00259-022-06036-9. URL: <https://doi.org/10.1007/s00259-022-06036-9> (cit. en p. 18).
- Zwanenburg, Alex, Stefan Leger et al. (2016). «Image Biomarker Standardisation Initiative: Feature Definitions». En: *arXiv preprint abs/1612.07003*. arXiv: 1612.07003. URL: <http://arxiv.org/abs/1612.07003> (cit. en pp. 10, 11, 30, 33).
- Zwanenburg, Alex, Martin Vallières et al. (mayo de 2020). «The Image Biomarker Standardization Initiative: Standardized Quantitative Radiomics for High-Throughput Image-based Phenotyping». En: *Radiology* 295.2, págs. 328-338. DOI: 10.1148/radiol.2020191145. URL: <https://doi.org/10.1148/radiol.2020191145> (cit. en p. 10).

APÉNDICE A

Glosario de acrónimos

- AUC** *Area Under the ROC Curve.* 3
- CNN** *Convolutional Neural Networks.* 3
- csPCa** *Clinically Significant Prostate Cancer.* 1, 4
- DCE** *Dynamic Contrast-Enhanced Imaging.* 2
- DL** *Deep Learning.* 3, 5
- DWI** *Diffusion-weighted imaging.* 2, 8
- IA** *Inteligencia Artificial.* 3, 4
- ML** *Machine Learning.* 3
- PCa** *Prostate Cancer.* 1
- PSA** *Prostate Specific Antigen.* 1–3
- RMmp** *Resonancia Magnética Multiparamétrica.* 2–5
- T2W** *T2 weighted image.* 2
- TRUS** *Transrectal Ultrasound guided prostate biopsy.* 1, 2
- XAI** *Explainable Artificial Intelligence.* 5

APÉNDICE B

Configuraciones experimentales en *Deep Learning*

Este anexo recoge los detalles completos de cada una de las configuraciones empleadas en el entrenamiento de modelos de *Deep Learning*, incluyendo la arquitectura utilizada y las transformaciones de aumento de datos aplicadas, junto con sus parámetros específicos.

base-densenet

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2

base-resnet

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]

base-vit

Modelo	ViT
Parámetros del modelo	spatial_dims=3, in_channels=3, img_size=[128,128,32], patch_size=[16,16,8], classification=True, num_classes=2

base-efficientnet

Modelo	EfficientNetBN (b0)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b0

base-efficientnet-b7

Modelo	EfficientNetBN (b7)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b7

base-efficientnet-b8

Modelo	EfficientNetBN (b8)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b8

config1

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2
Transformación	Parámetros
RandFlipd	prob=0.2, spatial_axis=0
RandRotate90d	prob=0.2
RandAffined	prob=0.2, rotate_range=[0.1, 0.1, 0.1], translate_range=[0.1, 0.1, 0.1]
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1

config2

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]
Transformación	Parámetros
RandFlipd	prob=0.4, spatial_axis=1
RandRotate90d	prob=0.4
RandAffined	prob=0.2, rotate_range=[0.05, 0.05, 0.05], translate_range=[0.05, 0.05, 0.05]
RandScaleIntensityd	prob=0.3, factors=0.1

config3

Modelo	ViT
Parámetros del modelo	spatial_dims=3, in_channels=3, img_size=[128,128,32], patch_size=[16,16,8], classification=True, num_classes=2
Transformación	Parámetros
RandFlipd	prob=0.4, spatial_axis=2
RandAffined	prob=0.3, rotate_range=[0.1, 0.1, 0.1], translate_range=[0.1, 0.1, 0.1]
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]
RandShiftIntensityd	prob=0.2, offsets=[-0.05, 0.05]

config4

Modelo	EfficientNetBN (b0)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b0
Transformación	Parámetros
RandFlipd	prob=0.3, spatial_axis=0
RandRotate90d	prob=0.3
RandScaleIntensityd	prob=0.3, factors=0.1
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]

config5

Modelo	EfficientNetBN (b7)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b7
Transformación	Parámetros
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1
RandAdjustContrastd	prob=0.3, gamma=[0.7,1.5]
RandHistogramShiftd	prob=0.3, num_control_points=5

config6

Modelo	EfficientNetBN (b8)
Parámetros del modelo	spatial_dims=3, in_channels=3, num_classes=2, model_name=efficientnet-b8
Transformación	Parámetros
RandBiasFieldd	prob=0.3, coeff_range=[0.0, 0.5]
RandScaleIntensityd	prob=0.3, factors=0.1
RandGaussianSmoothd	prob=0.2, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]

config7

Modelo	ResNet
Parámetros del modelo	spatial_dims=3, n_input_channels=3, num_classes=2, block=basic, layers=[2,2,2,2], block_inplanes=[64,64,128,256]
Transformación	Parámetros
RandGaussianSmoothd	prob=0.3, sigma_x=[0.5,1.0], sigma_y=[0.5,1.0], sigma_z=[0.5,1.0]
RandShiftIntensityd	prob=0.3, offsets=[-0.1, 0.1]
RandAdjustContrastd	prob=0.3, gamma=[0.8,1.2]

config8

Modelo	DenseNet121
Parámetros del modelo	spatial_dims=3, in_channels=3, out_channels=2
Transformación	Parámetros
RandAdjustContrastd	prob=0.4, gamma=[0.5,1.5]
RandGaussianNoised	prob=0.2, mean=0.0, std=0.1
RandScaleIntensityd	prob=0.3, factors=0.1

APÉNDICE C

Objetivos de Desarrollo Sostenible

Grado de relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS)

En 2015, la Organización de las Naciones Unidas aprobó la Agenda 2030 para el Desarrollo Sostenible, un marco global compuesto por 17 Objetivos de Desarrollo Sostenible (ODS) que buscan hacer frente a retos como la pobreza, la desigualdad y el cambio climático. La Universitat Politècnica de València (UPV), en su compromiso con estos objetivos, promueve su incorporación en la investigación y la formación académica. En este contexto, la memoria del Trabajo Fin de Grado representa una oportunidad para analizar la relación del trabajo realizado con los ODS.

A continuación, se presenta una tabla que relaciona este trabajo con los ODS, indicando el grado de contribución en cada caso:

Objetivos de Desarrollo Sostenible	Alto	Medio	Bajo	No procede
ODS 1. Fin de la pobreza.				X
ODS 2. Hambre cero.				X
ODS 3. Salud y bienestar.	X			
ODS 4. Educación de calidad.				X
ODS 5. Igualdad de género.				X
ODS 6. Agua limpia y saneamiento.				X
ODS 7. Energía asequible y no contaminante.				X
ODS 8. Trabajo decente y crecimiento económico.				X
ODS 9. Industria, innovación e infraestructuras.		X		
ODS 10. Reducción de las desigualdades.			X	
ODS 11. Ciudades y comunidades sostenibles.				X
ODS 12. Producción y consumo responsables.				X
ODS 13. Acción por el clima.				X
ODS 14. Vida submarina.				X
ODS 15. Vida de ecosistemas terrestres.				X
ODS 16. Paz, justicia e instituciones sólidas.				X
ODS 17. Alianzas para lograr objetivos.		X		

Tabla C.1: Grado de relación del trabajo con los ODS

Reflexión sobre la relación del TFG con los ODS

Empieza a escribir aquí tu reflexión. Aproximadamente entre 500 y 1500 palabras. Se espera que puedas relacionar tu TFG con alguno (o varios) ODS. En el caso de no poder relacionarse, deberás explicar por qué no es posible hacerlo y/o identificar aquellos ODS que en menor grado podrían tener alguna relación con el trabajo. Recuerda borrar toda esta frase.

ODS 3: Salud y bienestar → Este trabajo tiene un impacto directo en la mejora de la salud y el bienestar al desarrollar herramientas para la clasificación de la severidad del cáncer de próstata. La optimización de modelos radiómicos y de Deep Learning puede contribuir a diagnósticos más precisos y a una mejor toma de decisiones clínicas, favoreciendo el acceso a tecnologías avanzadas en el ámbito de la salud.

ODS 9: Industria, innovación e infraestructuras → La aplicación de inteligencia artificial en el análisis de imágenes médicas representa un avance en innovación tecnológica dentro del sector sanitario.

ODS 17: Alianzas para lograr los objetivos → La integración de modelos de IA en el ámbito clínico requiere colaboración entre investigadores, profesionales médicos y desarrolladores de tecnología. Este trabajo fomenta la cooperación interdisciplinaria para mejorar la eficacia de los sistemas de diagnóstico.

ODS 10: Reducción de las desigualdades → Aunque el trabajo no aborda directamente la reducción de desigualdades, el desarrollo de herramientas accesibles y explicables en el ámbito de la salud podría facilitar el acceso a diagnósticos avanzados en distintos entornos médicos.